

分类号	xxxx
UDC	xxxx

学校代码	xxxx
密 级	公开

硕士学位论文

基于 xxxxxxx 分析

学位申请人姓名	xxxxxx
---------	--------

学位申请人学号	xxxxxxxx
---------	----------

专业（领域）名称	xxxxxxxx
----------	----------

学 位 类 别	xxxxxx
---------	--------

学院（部、研究院）	xxxxxx
-----------	--------

导 师 姓 名	xxxxxx
---------	--------

二〇二四年五月

XXX 大学 学位论文原创性声明

本人郑重声明：所呈交的学位论文基于 xxxx 与 xxxx 分析 是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律后果由本人承担。

论文作者签名：

日期： 年 月 日

XXX 大学 学位论文使用授权说明

本学位论文作者完全了解深圳大学关于收集、保存、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属深圳大学。学校有权保留学位论文并向国家主管部门或其他机构送交论文的电子版和纸质版，允许论文被查阅和借阅。本人授权深圳大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（涉密学位论文在解密后适用本授权书）

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘要

随着激光焊接技术在精密制造领域的广泛应用，焊接质量的在线检测与控制日益重要。光学相干断层扫描（OCT）技术凭借其非接触、高分辨率和实时成像的优势，已成为激光焊接熔池检测的重要手段，而语义分割是实现熔池区域精确提取的关键环节。然而，受散斑噪声干扰目标识别、边界模糊降低分割精度、目标与背景对比度不足导致欠分割或过分割等因素影响，现有基于卷积的分割模型难以同时满足全局语义理解与边界精确刻画的需求。针对上述问题，本文提出一种基于改进 DeepLabV3+ 的 OCT 图像语义分割方法。

本文方法以 DeepLabV3+ 编码器—解码器架构为基础，结合空洞空间金字塔池化（ASPP）实现多尺度上下文聚合，并引入全局与局部两类注意力增强机制。具体而言，在 ASPP 输出后嵌入 TR（Transformer Routing）模块，采用双层路由注意力机制结合 Top-K 稀疏选择策略，在可控计算开销下增强长程依赖建模能力，提升对目标整体结构与上下文关系的表征；在解码器高低层特征融合后引入 SAE（Spatial Attention Enhancement）模块，通过坐标注意力编码空间位置信息与通道注意力强化判别性特征响应，改善细长结构与模糊边界处的分割质量。此外，采用交叉熵损失与 Dice 损失的加权组合以缓解类别不平衡带来的训练偏置。

在包含 912 张训练图像与 228 张测试图像的 OCT 数据集上进行实验验证。结果表明，所提方法的 mIoU 达到 0.911，较基线 DeepLabV3+ 提升 7.1%；目标类别 IoU 达到 0.826，提升 16.3%；边界精度指标 HD95 降至 10.68，较基线降低 12.6%。消融实验显示，SAE 模块单独使用可提升 mIoU 5.9%，TR 模块单独使用可提升 3.9%，两者联合使用产生协同效应。上述结果表明，TR 与 SAE 的联合引入能够在统一的编码器—解码器框架内兼顾全局语义建模与局部边界增强，为 OCT 图像的高精度语义分割提供一种有效实现途径。

关键词： 语义分割；DeepLabV3+；注意力机制；OCT 图像；激光焊接

ABSTRACT

With the widespread application of laser welding technology in precision manufacturing, online inspection and quality control of welding processes have become increasingly important. Optical Coherence Tomography (OCT), with its advantages of non-contact measurement, high resolution, and real-time imaging, has emerged as a promising technique for laser welding molten pool detection, where semantic segmentation plays a crucial role in accurate extraction of molten pool regions. However, existing convolution-based segmentation models struggle to simultaneously achieve global semantic understanding and precise boundary delineation, due to challenges such as speckle noise interfering with target recognition, blurred boundaries reducing segmentation accuracy, and insufficient target-background contrast leading to under- or over-segmentation. To address these issues, this thesis proposes an improved DeepLabV3+-based method for OCT image semantic segmentation.

Built upon the DeepLabV3+ encoder-decoder architecture with Atrous Spatial Pyramid Pooling (ASPP) for multi-scale context aggregation, the proposed approach introduces both global and local attention enhancement mechanisms. Specifically, a TR (Transformer Routing) module is inserted after ASPP, employing a bi-level routing attention mechanism combined with Top-K sparse selection strategy to enhance long-range dependency modeling under controllable computational cost, thereby improving the representation of overall target structures and contextual relationships. Additionally, an SAE (Spatial Attention Enhancement) module is applied after decoder feature fusion, utilizing coordinate attention to encode spatial position information and channel attention to strengthen discriminative feature responses, thus improving segmentation quality at elongated structures and ambiguous boundaries. A weighted combination of cross-entropy loss and Dice loss is further adopted to mitigate training bias caused by class imbalance.

Experiments on an OCT dataset with 912 training images and 228 test images demonstrate that the proposed method achieves an mIoU of 0.911, outperforming the

baseline DeepLabV3+ by 7.1%; the target class IoU reaches 0.826, with an improvement of 16.3%; and the boundary precision metric HD95 decreases to 10.68, representing a 12.6% reduction. Ablation studies show that the SAE module alone improves mIoU by 5.9%, the TR module alone by 3.9%, and their joint usage produces a synergistic effect. These results indicate that the joint integration of TR and SAE can balance global semantic modeling and local boundary enhancement within a unified encoder–decoder framework, providing an effective solution for high-precision OCT image segmentation in practical industrial scenarios.

Key words: Semantic Segmentation; DeepLabV3+; Attention Mechanism; OCT Image; Laser Welding

目 录

摘 要	I
ABSTRACT	II
符号和缩略语说明	VI
第一章 绪论	1
1.1 研究背景及意义	1
1.1.1 OCT 图像噪声特性及处理方法研究现状	2
1.1.2 图像语义分割算法研究现状	4
1.1.3 图像预处理	6
1.1.4 基于 LabelMe 的熔深线段标注	6
1.1.5 数据增强策略	8
1.1.6 数据集划分与统计	10
1.2 语义分割评价指标	10
1.2.1 混淆矩阵	10
1.2.2 像素准确率与平均像素准确率	11
1.2.3 交并比与平均交并比	11
1.2.4 Dice 系数	12
1.2.5 模型效率指标	12
1.3 本章小结	13
第二章 基于全局注意力机制的 DeepLabV3+ 模型改进	15
2.1 DeepLabV3+ 模型的工作原理	15
2.1.1 空洞卷积	16
2.1.2 ASPP 模块	17
2.1.3 编码器-解码器结构	18
2.2 模型的设计与改进	18
2.2.1 模型的改进动机	18
2.2.2 Transformer 注意力模块 (TR) 设计	19
2.2.3 混合损失函数设计	22
2.2.4 改进模型整体结构	22
2.3 实验结果与分析	23
2.3.1 实验环境与参数配置	23
2.3.2 消融实验	24

2.3.3 对比实验	25
2.4 本章小结	26
第三章 基于空间感知增强的 DeepLabV3+ 模型优化	28
3.1 空间感知增强模块 (SAE) 的设计	28
3.1.1 改进动机	28
3.1.2 SAE 模块原理与结构	29
3.1.3 SAE 模块集成方式	33
3.2 改进模型的整体结构	33
3.2.1 完整模型架构	33
3.2.2 各模块协同机制	34
3.3 综合实验与分析	35
3.3.1 消融实验	35
3.3.2 与主流方法对比实验	36
3.3.3 可视化分析	37
3.3.4 效率分析	38
3.4 本章小结	39
第四章 总结与展望	41
4.1 总结	41
4.2 展望	42
参考文献	43
致谢	46
攻读硕士学位期间的研究成果	47

符号和缩略语说明

OCT	光学相干断层扫描 (Optical Coherence Tomography)
ASPP	空洞空间金字塔池化 (Atrous Spatial Pyramid Pooling)
TR	变换器路由 (Transformer Routing)
SAE	空间注意力增强 (Spatial Attention Enhancement)
mIoU	平均交并比 (Mean Intersection over Union)
IoU	交并比 (Intersection over Union)
FCN	全卷积网络 (Fully Convolutional Network)
CNN	卷积神经网络 (Convolutional Neural Network)
ResNet	残差网络 (Residual Network)

第一章 绪论

1.1 研究背景及意义

(1) **基于光辐射的光电监测方法。**激光焊接过程中，熔池与匙孔区域会产生强烈的光辐射信号，光电监测方法正是利用这些辐射信号来反映焊接状态。高温计（Pyrometer）通过测量特定波段的热辐射强度来估计熔池/匙孔温度，具有结构简单、响应速度快等优点，被广泛用于焊接过程的温度监控与缺陷预警^[1]。光电二极管（Photodiode）可对焊接区域的反射光或等离子体辐射光进行高速采样，采样率可达数十 kHz 甚至 MHz 级别，能够捕捉焊接过程中的瞬态波动^[2]。光谱仪（Spectrometer）通过分析等离子体羽流的发射光谱，可获取元素成分与电子温度信息，为缺陷诊断提供依据。然而，光电监测方法的主要局限在于：其信号为单点测量，缺乏空间分辨信息；信号强度受匙孔开口状态、金属蒸汽遮挡、飞溅等因素影响显著，导致信号与熔深之间的映射关系复杂且可迁移性差。

(2) **基于热成像的红外监测方法。**红外热像仪（Infrared Thermal Camera）能够直观呈现焊接区域的温度场分布，可用于分析熔池形态、热影响区范围与温度梯度等信息。通过对红外图像的处理与分析，可以间接评估焊接质量与检测焊接缺陷。然而，红外热像仪在激光焊接监测中存在以下局限：其一，红外探测器的空间分辨率有限，难以精确刻画匙孔边界细节；其二，红外热像仪成本较高，且需要复杂的标定与校正程序；其三，测量结果反映的是表面温度分布，无法直接获取匙孔深度信息。

(3) **基于可见光成像的视觉监测方法。**高速可见光相机可获取熔池/匙孔的高分辨率二维形态图像，通过图像处理算法提取熔池轮廓、匙孔开口面积、飞溅轨迹等特征参数^[3,4]。近年来，随着深度学习技术的发展，基于卷积神经网络的焊接图像分析方法也得到了广泛研究。视觉监测方法的优势在于分辨率高、信息丰富，但其主要局限包括：相机需要在强光环境下工作，对滤光片与曝光参数要求严格；图像仅能反映熔池表面的二维形态，无法直接测量匙孔深度；图像处理流程复杂，实时性受限。

(4) **基于主动探测的层析成像方法。**与上述被动式监测方法不同，基于主动探测光束的层析成像技术可直接获取焊接区域的深度结构信息。X 射线成像技术具有强大的穿透能力，可实时观察匙孔内部形态与熔池流动，是研究激光深熔焊

物理机制的重要手段^[5]。然而，X射线源设备体积庞大、成本高昂，且存在辐射安全隐患，难以在工业产线上大规模部署。光学相干层析成像（OCT）作为另一种主动探测技术，凭借其高轴向分辨率（可达微米级）、非接触测量、可穿透焊接烟尘与金属蒸汽等优势，近年来受到学术界与工业界的广泛关注^[2,6,7]。OCT可通过测量光束直接获取匙孔底部的反射信息，从而为熔深在线测量提供直接的几何依据^[8,9]。

（5）多传感器融合监测方法。单一传感器往往难以全面表征复杂的焊接过程，因此多传感器融合监测成为近年来的研究热点。通过综合利用光电信号、热成像、可见光图像与声发射信号等多源信息，并借助机器学习算法进行特征融合与决策，可以实现更全面、更可靠的焊接质量评估与缺陷检测^[10,11]。预测与健康管理局（Prognostics and Health Management, PHM）技术为多传感器融合监测提供了系统性的理论框架与实施方法^[11]。然而，多传感器融合系统存在成本高、集成复杂、实时性受限等问题，且不同传感器之间的时空配准与信息融合算法仍是研究难点。

表 1-1 总结了上述激光焊接过程光学检测技术的特点与局限性。综合比较可见，OCT 技术在直接测量匙孔深度结构方面具有独特优势，被认为是实现熔深在线测量与闭环控制的最具前景手段之一。然而，OCT 图像存在散斑噪声强、目标对比度低、边界模糊等特点，使得匙孔区域的稳定、精确提取仍是亟待解决的关键技术问题。

表 1-1 激光焊接过程光学检测技术对比

检测技术	检测对象	优点	局限性
高温计	匙孔/熔池温度	结构简单、响应快	无空间分辨信息
光电传感器	辐射/反射光强	采样率高、成本低	需复杂参数标定
光谱仪	等离子体成分	可诊断元素信息	信号解释复杂
红外热像仪	温度场分布	直观呈现温度场	分辨率低、成本高
可见光相机	熔池/匙孔形态	分辨率高、信息丰富	仅表面二维信息
X 射线成像	匙孔内部结构	穿透力强	辐射危害、成本高
OCT	匙孔深度结构	微米分辨率、非接触	信号处理复杂

1.1.1 OCT 图像噪声特性及处理方法研究现状

光学相干层析成像（OCT）是一种基于低相干干涉原理的层析成像技术。其基本工作原理是：将宽带低相干光源发出的光束分为参考臂和样品臂，样品臂光束经

过被测物体反射后与参考臂光束发生干涉，通过分析干涉信号的强度与相位变化，可重建被测物体沿轴向的结构信息^[2]。根据干涉信号的处理方式不同，OCT 系统可分为时域 OCT (TD-OCT) 和频域 OCT (FD-OCT)，后者具有更高的灵敏度与成像速度，是目前的主流技术路线。

然而，作为一种相干成像技术，OCT 固有地存在散斑噪声 (Speckle Noise) 问题。散斑噪声的产生机制主要包括：**(1) 相干叠加效应**，来自样品内部不同散射体的反射光发生相干叠加，形成随机的干涉图样；**(2) 多次散射效应**，光在非均匀介质中的多次散射导致光程差的随机变化；**(3) 系统噪声**，探测器热噪声、光源波动等系统因素也会引入额外噪声^[2]。在 OCT 图像中，散斑噪声常表现为遍布图像的随机颗粒纹理，不仅降低了图像的信噪比与对比度，还会模糊组织/材料的边界结构，影响后续的定量分析与测量精度。研究表明，OCT 散斑噪声的统计特性与被测物体的微结构特征密切相关，其分布通常服从瑞利分布或更复杂的概率模型。

针对 OCT 图像的噪声抑制与质量增强问题，国内外研究者提出了多种处理方法，大体可分为以下几类：

(1) 传统滤波与变换域方法。早期的 OCT 去噪研究多采用经典的图像滤波方法，如中值滤波、均值滤波、高斯滤波等。为克服简单滤波导致的边缘模糊问题，研究者引入了各向异性扩散滤波、双边滤波等边缘保持滤波器。在变换域方法中，小波变换去噪通过在不同尺度上分离信号与噪声来实现去噪；非局部均值 (Non-Local Means, NLM) 方法利用图像的自相似性进行去噪；BM3D 算法将块匹配与协同滤波相结合，在多种图像去噪任务中取得了优异效果^[2]。这些方法在一定程度上可改善 OCT 图像的视觉质量，但在噪声抑制与边界保持之间往往难以取得理想平衡。

(2) 硬件或多帧复合策略。从系统层面，研究者提出了多种基于硬件或采集策略的散斑抑制方法。多帧复合技术通过对同一位置采集多帧图像并进行平均或复合，利用散斑的随机性实现噪声平滑；角度复合技术通过多角度采集来降低散斑相关性；频率复合技术则利用宽带光源的不同频率成分进行复合^[2]。这些方法可有效提升图像信噪比，但往往以牺牲成像速度或增加系统复杂度为代价，难以满足激光焊接过程监测对实时性的严格要求。

(3) 基于深度学习的去噪方法。近年来，深度学习技术在图像去噪领域取得了

突破性进展。研究者将卷积神经网络(CNN)、残差学习、自编码器(Autoencoder)、生成对抗网络(GAN)等技术应用于 OCT 图像去噪,通过在大量数据上学习噪声分布与结构特征的映射关系,实现端到端的噪声去除与细节恢复。相比传统方法,深度学习去噪方法在处理复杂噪声分布与保持结构细节方面展现出更强的能力。然而,这些方法通常需要大量配对的噪声/清洁图像进行监督训练,而在实际工业场景中获取高质量的“真实干净”标签往往十分困难。

上述去噪方法为改善 OCT 图像的可视化质量与测量精度提供了有效途径。然而,在激光焊接 OCT 匙孔分割这一特定任务中,存在以下制约因素:**其一**,匙孔区域呈现弱边界、细长深孔、形态快速变化等特点,单纯追求去噪可能导致边界过度平滑、细节信息损失甚至几何形变;**其二**,“先去噪再分割/测量”的两阶段串联流程增加了系统复杂度与推理延迟,去噪阶段的误差可能传播并放大至后续分割环节;**其三**,在线闭环控制对实时性要求严格,复杂的预处理流程难以满足毫秒级响应的需求。

基于上述分析,本文不将“去噪”作为独立的预处理步骤,而是将散斑噪声与工况干扰视为成像环境的固有组成部分,探索**端到端的抗噪语义分割**方法。核心思路是:通过在分割网络内部显式增强全局上下文建模能力与局部边界细节表达能力,使模型在噪声干扰条件下仍能稳定学习匙孔的语义结构与轮廓特征,从流程架构上减少对额外预处理的依赖,实现从原始 OCT 图像到匙孔语义掩膜的直接映射。

1.1.2 图像语义分割算法研究现状

图像语义分割旨在为输入图像的每个像素赋予语义类别标签,是计算机视觉领域的核心任务之一^[12]。从技术演进角度,深度学习语义分割方法大体经历了以下发展阶段:

(1) **基于全卷积网络的端到端分割**。Long 等^[13]提出全卷积网络(FCN),首次将图像分类网络改造为逐像素预测结构,奠定了深度语义分割的基础。在此基础上,SegNet^[14]采用对称的编码器-解码器架构,通过最大池化索引进行上采样,在保持空间信息的同时降低了参数量;U-Net^[15]引入跳跃连接融合多尺度特征,在医学影像分割中取得优异效果。

(2) **多尺度上下文建模方法**。为捕获不同感受野范围的上下文信息,Yu

等^[16]提出空洞卷积（Dilated/Atrous Convolution），在不增加参数的情况下扩大感受野；DeepLab 系列^[17-20]通过空洞空间金字塔池化（ASPP）融合多尺度特征，DeepLabV3+ 进一步结合编码器-解码器结构，在精度与效率间取得平衡；PSPNet^[21]则采用金字塔池化模块聚合全局上下文。高分辨率网络 HRNet^[22]在整个网络中保持高分辨率表示，有效提升了边界与细节刻画能力。

（3）注意力机制与 Transformer 方法。为建模长程依赖与突出关键区域特征，注意力机制被广泛引入分割任务。SE 模块^[23]通过通道注意力重校准特征响应；CBAM^[24]结合通道与空间注意力实现双维度特征增强；Non-local^[25]通过自注意力机制捕获像素间的全局依赖关系；DANet^[26]同时建模位置注意力与通道注意力以捕获全局依赖；CCNet^[27]通过十字交叉注意力降低计算复杂度；ECA-Net^[28]提出高效通道注意力模块以实现轻量化设计；Coordinate Attention^[29]在轻量化约束下嵌入位置信息以增强空间感知能力。近年来，Vision Transformer^[30]被引入视觉任务，Swin Transformer^[31]通过移动窗口机制实现高效的层次化视觉表示；SETR^[32]首次将纯 Transformer 架构用于语义分割；SegFormer^[33]设计了高效的 Transformer 分割架构；Mask2Former^[34]通过掩码注意力实现通用图像分割；TransUNet^[35]等混合架构将 Transformer 与 CNN 结合，在医学影像分割中展现出优异的全局建模能力。

（4）实时与轻量化分割网络。面向工业在线检测等实时性要求较高的场景，BiSeNet V2^[36]、ICNet^[37]、Lite-HRNet^[38]等轻量化网络通过双分支设计或特征金字塔策略在速度与精度间寻求平衡^[39]。

1.1.3 图像预处理

原始 OCT 图像存在噪声干扰、对比度不足等问题，需要进行预处理以提升图像质量。本研究采用的预处理流程主要包括以下步骤：

(1) **图像裁剪**：原始 OCT 图像包含较大的无效区域，为减少计算量并突出感兴趣区域（Region of Interest, ROI），首先对图像进行裁剪，去除边缘的无效信息，保留包含熔深信号的核心区域。

(2) **噪声抑制**：OCT 图像中存在散斑噪声等干扰，本研究采用中值滤波方法进行去噪处理。中值滤波能够在保留边缘信息的同时有效抑制椒盐噪声和散斑噪声，滤波窗口大小设置为 3×3 。

(3) **对比度增强**：为提高熔深区域与背景的区分度，采用直方图均衡化方法对图像进行对比度增强。增强后的图像熔深线段边界更加清晰，有利于后续的标注和分割。

(4) **尺寸调整**：将预处理后的图像统一调整为 512×512 像素，采用双线性插值方法进行缩放，以满足深度学习模型的输入尺寸要求。

(5) **归一化处理**：将图像像素值从 $[0, 255]$ 归一化到 $[0, 1]$ 范围，以加速模型收敛并提高训练稳定性。


预处理前后的图像效果对比如图 1-1 所示，可以看出预处理后图像的噪声明显减少，熔深区域的对比度显著提升。

1.1.4 基于 LabelMe 的熔深线段标注


本研究采用基于 Python 语言开发的开源图像标注工具 LabelMe 进行语义分割标签的制作。与传统的图像处理软件相比，LabelMe 的主要优势在于操作便捷、效率较高。该工具配备了多样化的功能，拥有直观的用户界面，能够轻松上手，精确地完成图像标注任务。LabelMe 的标注界面如图 1-2 所示，其直观易用的特点一目了然。

(1) **标注类别定义**：本研究采用二分类语义分割策略，定义了以下两个标注类别：① 熔深线段（Weld_Depth），表示焊接熔池底部的深度轮廓区域，是本研究的主要分割目标；② 背景（Background），即除熔深线段外的所有区域，未标注区域自动作为背景处理。

(2) **标注流程**：在运用 LabelMe 软件开展图像手动标注工作时，具体操作流



(a) 原始图像



(b) 预处理后图像

图 1-1 预处理效果对比




图 1-2 LabelMe 标注界面

程如下：1. 打开存有原始 OCT 图像的文件夹；2. 在工具栏上点击”创建多边形”按钮；3. 沿熔深区域轮廓紧密绘制多边形，对图像中熔深线段的轮廓予以标注；4. 完成标注后，为每个轮廓选定对应的类别标签（Weld_Depth）；5. 将标注信息保存为 JSON 格式文件；6. 使用 LabelMe 提供的转换脚本（labelme_json_to_dataset）将 JSON 文件批量转换为 PNG 格式的掩码图像，供深度学习模型训练使用。

（3）标注质量控制：为确保标注质量，采用双人交叉验证的方式进行质量控制。首先由标注人员完成初始标注，随后由第二人进行检查和修正。对于存在争议的样本，由两人协商确定最终标注结果。完成标注后，还需仔细检查以下事项：图片名称是否准确、格式是否正确、标注是否完整，以及是否存在未标注的图像等情况。

标注样例如图 1-3 所示，展示了原始 OCT 图像与对应标注掩码的对比效果。




图 1-3 标注样例展示

1.1.5 数据增强策略

由于原始标注图像数量有限（约 200 张），为扩充训练数据并提升模型的泛化能力，本研究采用了多种数据增强策略。数据增强操作在线进行，即在每个训练批次中随机应用以下变换，最终将数据集扩充至 1000 余张图像。

数据增强策略的具体配置如表 1-2 所示。

（1）几何变换：包括随机水平翻转、随机垂直翻转、随机旋转和随机缩放等操作，用于增加数据的空间多样性，提升模型对不同方向和尺度目标的适应能力。

（2）光学变换：包括亮度调整、对比度调整和高斯噪声添加等操作，用于模拟不同光照条件和噪声水平下的图像，增强模型对图像质量变化的鲁棒性。

数据增强的效果示例如图 1-4 所示。

表 1-2 数据增强策略配置

增强类型	增强方法	参数设置
几何变换	随机水平翻转	概率 0.5
	随机垂直翻转	概率 0.5
	随机旋转	角度范围 $[-15^{\circ}, +15^{\circ}]$
	随机缩放	缩放比例 $[0.8, 1.2]$
光学变换	亮度调整	调整范围 $[0.8, 1.2]$
	对比度调整	调整范围 $[0.8, 1.2]$
	高斯噪声	概率 0.3，标准差 0.02




图 1-4 数据增强效果示例

1.1.6 数据集划分与统计

为科学评估模型性能，本研究将数据集按照 8:1:1 的比例划分为训练集、验证集和测试集。划分时遵循以下原则：（1）时序连续性，来自同一焊接序列的图像不跨集划分，避免信息泄露；（2）分布一致性，确保三个子集中不同工况下的样本比例基本一致；（3）随机性，在满足上述约束的前提下，采用随机采样方式进行划分。

与公开语义分割数据集如 Cityscapes^[40] 相比，本数据集规模较小，但在焊接 OCT 图像这一特定领域具有重要价值。数据集的详细统计信息如表 1-3 所示。

表 1-3 焊接 OCT 图像数据集统计信息

数据集	原始图像数	增强后图像数	占比	图像尺寸
训练集	160	800	80%	512×512
验证集	20	100	10%	512×512
测试集	20	100	10%	512×512
总计	200	1000	100%	—

训练集用于模型参数的学习与优化；验证集用于超参数调优和早停策略的判断；测试集仅在模型训练完成后进行最终性能评估，以确保评估结果的客观性。

由于熔深线段在图像中所占像素比例较小，数据集存在明显的类别不平衡问题。为缓解这一问题，本研究在损失函数设计中引入了 Dice 损失，以提升模型对小目标区域的分割精度，具体将在第三章进行详细介绍。

1.2 语义分割评价指标

为了客观评估语义分割模型的性能，需要采用合适的评价指标对预测结果进行定量分析。语义分割的评价指标通常基于混淆矩阵（Confusion Matrix）计算，通过比较预测结果与真实标签之间的差异，量化模型的分割精度。本节介绍常用的语义分割评价指标及其计算方法。

1.2.1 混淆矩阵

混淆矩阵是评估分类模型性能的基础工具，用于统计预测结果与真实标签之间的对应关系。对于语义分割任务，混淆矩阵 C 是一个 $N \times N$ 的矩阵，其中 N 为类别数。矩阵元素 C_{ij} 表示真实类别为 i 、预测类别为 j 的像素数量。

基于混淆矩阵，可以计算多种评价指标。对于二分类任务（如本文的匙孔分割任务），混淆矩阵包含四个元素：真正例（True Positive, TP）、假正例（False Positive, FP）、真负例（True Negative, TN）和假负例（False Negative, FN）。

1.2.2 像素准确率与平均像素准确率

像素准确率（Pixel Accuracy, PA）是最直观的评价指标，表示正确分类的像素占总像素的比例：

$$PA = \frac{\sum_{i=0}^{N-1} C_{ii}}{\sum_{i=0}^{N-1} \sum_{j=0}^{N-1} C_{ij}} \quad (1-1)$$

其中， C_{ii} 为混淆矩阵对角线元素，表示正确分类的像素数；分母为总像素数。PA 的取值范围为 $[0, 1]$ ，值越大表示分割精度越高。PA 指标计算简单直观，适用于类别分布相对均衡的场景，但在类别不平衡的情况下（如背景像素远多于目标像素）可能产生误导性结果。

平均像素准确率（Mean Pixel Accuracy, mPA）通过计算每个类别的像素准确率并取平均，能够更好地反映模型对不同类别的分割性能：

$$mPA = \frac{1}{N} \sum_{i=0}^{N-1} \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}} \quad (1-2)$$

其中， $\frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}}$ 表示类别 i 的像素准确率。mPA 对每个类别赋予相同的权重，能够更好地评估模型在类别不平衡情况下的性能。

1.2.3 交并比与平均交并比

交并比（Intersection over Union, IoU）是语义分割任务中最常用的评价指标之一，表示预测结果与真实标签的交集与并集的比值：

$$IoU_i = \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij} + \sum_{j=0}^{N-1} C_{ji} - C_{ii}} \quad (1-3)$$

其中，分子 C_{ii} 为类别 i 的预测结果与真实标签的交集（正确预测的像素数），分母为两者的并集。IoU 指标能够同时考虑预测结果的准确性和完整性，对分割边界的精度更加敏感。对于二分类任务，IoU 的计算可简化为：

$$IoU = \frac{TP}{TP + FP + FN} \quad (1-4)$$

平均交并比（Mean Intersection over Union, mIoU）通过计算所有类别 IoU 的平均值，综合评估模型的分割性能：

$$\text{mIoU} = \frac{1}{N} \sum_{i=0}^{N-1} \text{IoU}_i \quad (1-5)$$

mIoU 是语义分割任务中最常用的评价指标，能够综合反映模型对不同类别的分割性能。在类别不平衡的情况下，mIoU 比 PA 更能准确反映模型的真实性能。本文实验部分将 mIoU 作为主要评价指标，用于评估不同方法的分割性能。

1.2.4 Dice 系数

Dice 系数（Dice Coefficient）是医学图像分割中常用的评价指标，表示预测结果与真实标签的重叠程度：

$$\text{Dice}_i = \frac{2 \cdot C_{ii}}{2 \cdot C_{ii} + \sum_{j \neq i} C_{ij} + \sum_{j \neq i} C_{ji}} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}} \quad (1-6)$$

Dice 系数的取值范围为 $[0, 1]$ ，值越大表示重叠程度越高。对于二分类任务，Dice 系数与 IoU 之间存在以下关系：

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \quad (1-7)$$

Dice 系数对分割区域的完整性更加敏感，在医学图像分割等需要精确区域分割的任务中应用广泛。本文在损失函数设计中采用了 Dice 损失，用于处理类别不平衡问题。

1.2.5 模型效率指标

除分割精度外，模型的计算效率也是评估语义分割方法的重要维度，尤其对于工业在线检测等对实时性有要求的应用场景。本文采用以下效率指标评估模型：

(1) 参数量 (Parameters, Params): 表示模型中可学习参数的总数，通常以百万 (M) 为单位。参数量反映了模型的复杂度和存储需求。参数量较大的模型通常具有更强的表达能力，但也带来更高的存储和计算开销。在实际部署中，需要根据硬件资源限制选择合适的模型规模。

(2) 推理时间 (Inference Time): 表示模型处理单张图像所需的时间, 通常以毫秒 (ms) 为单位。推理时间受模型复杂度、输入分辨率、硬件平台等因素影响。本文实验中统一在相同硬件环境下测试各方法的推理时间, 以确保对比的公平性。

在实际应用中, 通常需要综合考虑分割精度和计算效率, 在性能与资源消耗之间取得平衡。本文实验部分将同时报告 mIoU、目标类别 IoU 和 Params 等指标, 从精度和效率两个维度评估所提方法的性能。

1.3 本章小结

本章介绍了本文研究所需的相关理论与技术基础, 为后续章节的方法设计与实验分析提供了理论支撑。

首先, 本章介绍了 OCT 成像原理, 包括 OCT 技术的基本原理、技术分类以及在激光焊接中的应用。OCT 技术基于低相干干涉原理, 能够实现微米级的高分辨率层析成像, 在激光焊接场景中可用于匙孔检测和熔深测量。然而, OCT 图像存在散斑噪声、对比度低、边界模糊等特点, 使得目标区域的提取成为一项具有挑战性的任务, 这也为本文研究面向 OCT 图像的语义分割方法提供了重要动机。

其次, 本章介绍了深度学习的基础理论, 包括卷积神经网络、编码器-解码器架构以及注意力机制等核心概念。卷积神经网络通过局部连接、权值共享和池化操作, 能够有效提取图像特征; 编码器-解码器架构通过编码器提取多尺度特征、解码器恢复空间分辨率, 实现了端到端的像素级预测; 注意力机制通过动态分配权重, 使网络能够关注重要信息, 提升了模型的表达能力。这些理论基础为本文方法的设计提供了重要支撑。

再次, 本章回顾了语义分割的发展历程和关键技术, 包括全卷积网络、U-Net 架构、U-Net 变体网络 (UNet++, ResUNet) 以及 DeepLab 系列方法。其中, UNet++ 通过嵌套密集跳跃连接缓解了语义鸿沟问题, ResUNet 通过残差连接缓解了梯度消失问题, TransUNet 通过结合 Transformer 与 CNN 增强了长距离依赖建模能力。DeepLabV3+ 作为本文方法的基础框架, 通过编码器-解码器结构和 ASPP 模块, 实现了多尺度上下文信息的有效捕获。然而, 在处理 OCT 图像时, DeepLabV3+ 仍存在全局上下文信息利用不足和局部细节丢失等问题, 这为本文的改进提供了

方向。

此外，本章详细介绍了焊接 OCT 图像数据集的构建过程。针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题，本研究构建了面向熔深分割的自建数据集。数据集构建包括 OCT 图像采集、预处理（裁剪、去噪、对比度增强、尺寸调整）、基于 LabelMe 的熔深线段标注、数据增强等步骤。通过数据增强策略，将原始 200 张图像扩充至 1000 余张，并按照 8:1:1 的比例划分为训练集、验证集和测试集，为后续模型训练提供了数据基础。

最后，本章介绍了语义分割常用的评价指标，包括像素准确率、平均像素准确率、交并比、平均交并比、Dice 系数，以及参数量和推理速度等效率指标。这些评价指标从精度和效率两个维度量化模型性能，为后续章节的实验评估提供了标准。

基于本章介绍的理论基础和构建的数据集，本文将在第三章提出一种基于改进 DeepLabV3+ 的 OCT 图像语义分割方法。该方法在编码器端引入 TR 模块以增强全局上下文建模能力，在解码器端引入 SAE 模块以增强局部细节和边界信息，从而实现对熔深区域的高精度分割。第四章将基于本章介绍的评价指标，对所提方法进行全面的实验验证和性能分析。

第二章 基于全局注意力机制的 DeepLabV3+ 模型改进

激光焊接过程中，熔深是评估焊接质量的关键指标。熔深过小会导致焊接强度不足，熔深过大则可能造成焊穿或烧蚀等问题。传统的熔深测量方法依赖于破坏性金相检测或人工目视检查，效率低下且难以实现在线监测。OCT 技术的引入为激光焊接熔深的非接触式在线检测提供了新的途径，但 OCT 图像存在散斑噪声严重、对比度低、边界模糊等特点，使得熔深区域的自动化提取成为一项具有挑战性的任务。

近年来，基于深度学习的语义分割方法在图像分割领域取得了显著进展。DeepLabV3+ 作为语义分割领域的经典方法，通过编码器-解码器结构和 ASPP 模块实现了多尺度上下文信息的有效捕获^[20]。然而，在处理焊接 OCT 图像时，DeepLabV3+ 仍面临全局上下文建模不足的挑战。ASPP 模块的感受野受限与空洞卷积的局部性，难以建立长距离依赖关系，而 OCT 图像中的熔深区域呈现细长结构，需要网络理解整个图像的空间关系才能实现准确分割。

针对上述问题，本章提出了一种基于 Transformer 注意力机制的改进方案。通过在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块，利用双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力。同时，针对 OCT 图像中前景与背景类别不平衡的问题，设计了 BCE+Dice 混合损失函数。

本章结构如下：3.1 节详细介绍 DeepLabV3+ 基线模型的工作原理；3.2 节阐述模型的改进动机与 TR 模块的设计；3.3 节通过消融实验和对比实验验证所提方法的有效性；3.4 节对本章内容进行总结。

2.1 DeepLabV3+ 模型的工作原理

DeepLabV3+ 是语义分割领域的经典方法，由 Google 团队于 2018 年提出^[20]。该模型结合了空洞卷积、ASPP 模块和编码器-解码器结构，在多尺度上下文信息捕获方面表现出色。本节详细介绍 DeepLabV3+ 的核心组件，为后续改进工作奠定基础。DeepLabV3+ 的整体网络结构已在第二章图 ?? 中详细展示。

2.1.1 空洞卷积

在图像处理领域中，卷积操作是提取图像特征的基础。然而，传统的卷积操作在增加感受野的同时，会导致计算量显著增加以及图像细节的丢失。为了解决这个问题，空洞卷积（Atrous Convolution，又称扩张卷积）应运而生。

空洞卷积是一种特殊的卷积操作，其核心思想是在卷积核中插入空洞，从而在不增加计算量的前提下扩大卷积核的感受野。具体而言，空洞卷积通过在卷积核的相邻元素之间插入一定数量的空洞（即零值），使得卷积核能够在更大的范围内捕捉图像信息。空洞卷积的示意图如图 2-1 所示。




图 2-1 空洞卷积示意图^[41]

设输入特征图为 $\mathbf{F}$ ，空洞卷积核为 $\mathbf{W}$ ，空洞率为 r ，则空洞卷积的输出可表示为：

$$\mathbf{O}[i, j] = \sum_m \sum_n \mathbf{F}[i + r \cdot m, j + r \cdot n] \cdot \mathbf{W}[m, n] \quad (2-1)$$

其中， (i, j) 表示输出特征图的位置坐标， (m, n) 表示卷积核的索引。当 $r = 1$ 时，空洞卷积退化为标准卷积；当 $r > 1$ 时，卷积核的有效感受野扩大为 $(2r - 1) \times k + 1$ ，其中 k 为卷积核的原始尺寸。

在 DeepLabV3+ 模型中，空洞卷积被广泛应用于编码器特征提取阶段。通过不同空洞率的空间金字塔池化组合，编码器能够捕捉到不同尺度的图像特征，为后续的多尺度信息融合提供基础。相比于传统的池化操作，空洞卷积在扩大感受野的同时能够保持特征图的空间分辨率，避免了下采样带来的信息损失。

2.1.2 ASPP 模块

ASPP (Atrous Spatial Pyramid Pooling, 空洞空间金字塔池化) 模块是 DeepLabV3+ 的核心组件, 通过多个不同空洞率的并行分支捕获多尺度上下文信息^[19]。ASPP 模块的设计灵感来源于空间金字塔池化 (Spatial Pyramid Pooling, SPP), 但与之不同的是, ASPP 模块使用空洞卷积来替代传统的池化操作。ASPP 模块的结构如图 2-2 所示。




图 2-2 ASPP 模块结构图

本文方法采用深度可分离 ASPP 模块 (DepthwiseSeparableASPPModule), 在保持性能的同时降低计算复杂度。ASPP 模块包含 5 个并行分支: (1) 1×1 卷积分支, 用于捕获细节特征; (2) 3×3 空洞卷积分支 (dilation=12), 用于捕获局部特征; (3) 3×3 空洞卷积分支 (dilation=24), 用于捕获区域特征; (4) 3×3 空洞卷积分支 (dilation=36), 用于捕获全局特征; (5) 全局平均池化分支, 对特征图进行全局平均池化后通过 1×1 卷积恢复通道数, 用于捕获全局上下文信息。

5 个并行分支的输出特征经过通道维度拼接后, 得到多尺度特征表示, 随后通过 1×1 卷积降维, 减少特征维度并融合多尺度信息。

ASPP 模块使用深度可分离卷积降低计算复杂度。深度可分离卷积分为两个步骤: 首先进行深度卷积 (Depthwise Convolution), 对每个通道独立进行卷积操

作；然后进行点卷积（Pointwise Convolution），使用 1×1 卷积进行通道融合。深度可分离卷积的参数数量和计算量远小于标准卷积，在保持性能的同时提升了计算效率。

2.1.3 编码器-解码器结构

DeepLabV3+ 采用编码器-解码器架构，其中编码器负责提取图像的多尺度特征并捕获语义信息，解码器负责恢复空间分辨率并输出像素级预测结果^[20]。

（1）编码器：本文方法采用 ResNet18-V1c 作为骨干网络^[42,43]。ResNet18-V1c 是 ResNet 的改进版本，使用 Deep Stem 结构（三个连续的 3×3 卷积替换传统的 7×7 卷积）减少参数量并提升特征提取能力。ResNet18-V1c 包含四个阶段（Stage），逐步提取从低级到高级的特征表示，其中浅层特征保留较多细节信息用于解码器融合，深层特征送入 ASPP 模块进行多尺度上下文聚合。

（2）解码器：解码器通过上采样和特征融合操作，逐步恢复特征图的空间分辨率。首先，ASPP 模块输出的高层特征通过双线性插值上采样恢复空间分辨率；其次，编码器浅层特征通过 1×1 卷积降维以匹配高层特征的通道数；然后，将上采样后的高层特征与处理后的低层特征在通道维度进行拼接，得到融合特征，这种设计能够结合低层的细节信息和高层的语义信息，提升分割精度；最后，融合特征经过深度可分离卷积和 1×1 卷积转换为类别 logits，通过双线性插值上采样到原始图像尺寸，输出像素级类别预测结果。

DeepLabV3+ 的创新之处在于将 DeepLabV3 的输出作为编码器特征，通过解码器融合编码器的中间特征，在保持分割精度的同时提升了边界定位的准确性。本文方法以 DeepLabV3+ 为基础框架，在此基础上引入 TR 模块进一步提升分割性能。

2.2 模型的设计与改进

2.2.1 模型的改进动机

尽管 DeepLabV3+ 在通用语义分割任务中表现出色，但在处理激光焊接 OCT 图像时仍存在以下局限性，这些局限性构成了本文改进工作的直接动机。

（1）全局上下文建模不足。ASPP 模块通过不同空洞率的并行分支捕获多尺度上下文信息，但其感受野仍受限于空洞卷积的局部性，仅覆盖特征图的局部区

域。然而，OCT 图像中的熔深区域往往呈现细长结构（纵横比可达 1:10 以上），跨越图像的多个区域，需要网络理解整个图像的空间关系才能准确分割。ASPP 模块的局部感受野限制了其对全局结构的理解能力，可能导致细长熔深结构的断裂或误分割。

（2）类别不平衡问题。OCT 图像中背景区域通常占据 90% 以上的像素，而熔深目标区域仅占 5-10%。标准交叉熵损失对每个像素赋予相同权重，导致模型训练时偏向背景类别，难以充分学习前景特征。

基于上述局限性分析，本文提出针对性的改进方案：在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块，通过双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力；同时设计 BCE+Dice 混合损失函数应对类别不平衡问题。

2.2.2 Transformer 注意力模块（TR）设计

针对 DeepLabV3+ 全局上下文建模不足的问题，本文在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块。TR 模块借鉴 BiFormer 的双层路由注意力思想^[44]，通过区域级路由和 TopK 选择机制，仅对最相关的窗口进行注意力计算，在保持全局建模能力的同时将计算复杂度从 $O(n^2)$ 降低到 $O(n^2 \times k/p^2)$ 。TR 模块的结构如图 2-3 所示。

（1）模块结构。TR 模块主要包括位置编码（深度可分离卷积）、LayerNorm 归一化、双层路由注意力、MLP（扩展-压缩结构）和残差连接等组件。其中，双层路由注意力是核心创新，通过区域级路由和细粒度注意力两个阶段实现高效的全局上下文建模。

（2）双层路由注意力机制。

双层路由注意力机制是 TR 模块的核心创新，其工作流程如图 2-4 所示，具体包括以下步骤：

步骤一，窗口划分。将输入特征图按照固定的窗口大小进行划分，每个窗口包含若干特征向量，对应特征图中的空间位置。

步骤二，区域级路由。对每个窗口内的所有特征向量求平均，得到区域级查询向量 $\mathbf{Q}_{\text{region}}^{(i)}$ 和键向量 $\mathbf{K}_{\text{region}}^{(i)}$ ，其中 i 表示第 i 个窗口。区域级查询和键向量的




图 2-3 TR 模块结构图




图 2-4 双层路由注意力机制示意图

计算可表示为:

$$\mathbf{Q}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{Q}_j, \quad \mathbf{K}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{K}_j \quad (2-2)$$

其中, $\mathcal{W}_i$ 表示第 i 个窗口内的所有特征向量, $|\mathcal{W}_i|$ 表示窗口内的特征向量数量。

计算窗口间的相似度矩阵 $\mathbf{S}$, 其中 $\mathbf{S}_{ij}$ 表示第 i 个窗口与第 j 个窗口的相似度:

$$\mathbf{S}_{ij} = \frac{\mathbf{Q}_{\text{region}}^{(i)} \cdot \mathbf{K}_{\text{region}}^{(j)}}{\|\mathbf{Q}_{\text{region}}^{(i)}\| \times \|\mathbf{K}_{\text{region}}^{(j)}\|} \quad (2-3)$$

其中, $\cdot$ 表示向量内积, $\|\cdot\|$ 表示向量范数。

步骤三, TopK 路由选择。对每个窗口, 根据相似度矩阵选择 TopK 个最相关的窗口参与注意力计算。本文设置 $k = 4$, 即每个窗口选择 4 个最相关的窗口:

$$\mathcal{R}_i = \text{TopK}(\mathbf{S}_{i,:}, k = 4) \quad (2-4)$$

其中, $\mathcal{R}_i$ 表示第 i 个窗口选择的相关窗口索引集合, $\mathbf{S}_{i,:}$ 表示相似度矩阵的第 i 行。

步骤四, 细粒度注意力。在选定的窗口内进行像素级注意力计算。对于第 i 个窗口, 仅对 $\mathcal{R}_i$ 中的窗口进行注意力计算:

$$\text{Attention}(\mathbf{Q}_i, \mathbf{K}_{\mathcal{R}_i}, \mathbf{V}_{\mathcal{R}_i}) = \text{softmax} \left(\frac{\mathbf{Q}_i \mathbf{K}_{\mathcal{R}_i}^T}{\sqrt{d_k}} \right) \mathbf{V}_{\mathcal{R}_i} \quad (2-5)$$

其中, $\mathbf{Q}_i$ 、 $\mathbf{K}_{\mathcal{R}_i}$ 、 $\mathbf{V}_{\mathcal{R}_i}$ 分别表示第 i 个窗口的查询矩阵和选定窗口的键值矩阵, d_k 为键向量的维度。

(3) 复杂度分析。双层路由注意力机制通过 TopK 路由选择, 显著降低了计算复杂度。标准自注意力机制的计算复杂度为 $O(n^2)$, 其中 n 为特征图中的像素数量。双层路由注意力机制的计算复杂度为 $O(n^2 \times k/p^2)$, 其中 k 为 TopK 值, p 为窗口大小。通过窗口划分和 TopK 路由选择, 相比标准自注意力可降低约 75% 的计算量。

(4) 模块作用小结。TR 模块通过双层路由注意力机制实现三个核心功能: ① 建立特征图中任意位置之间的长距离依赖关系; ② 理解整个特征图的空间关系, 更好地处理细长结构目标; ③ 通过 TopK 路由选择降低计算复杂度。TR 模块的输出特征经过 1×1 卷积降维后, 与编码器的低层特征融合, 为后续解码器提供

增强的全局上下文信息。

2.2.3 混合损失函数设计

OCT 图像语义分割任务面临严重的类别不平衡问题：背景区域通常占据图像的 90% 以上，而熔深目标区域仅占 5-10%。传统交叉熵损失对每个像素赋予相同权重，导致模型训练时偏向背景类别。Focal Loss^[45] 通过动态调整样本权重缓解类别不平衡，但在语义分割中效果有限。因此，本文设计混合损失函数，结合二元交叉熵损失和 Dice 损失，兼顾像素级精度和区域级一致性。

(1) 二元交叉熵损失。二元交叉熵损失 (BCE Loss) 提供逐像素的梯度信号，确保模型对每个像素进行准确的类别预测：

$$L_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(p_i)) + (1 - y_i) \log(1 - \sigma(p_i))] \quad (2-6)$$

其中， N 为像素总数， $y_i \in \{0, 1\}$ 为真实标签， p_i 为预测 logits， $\sigma(\cdot)$ 为 Sigmoid 激活函数。

(2) Dice 损失。Dice 损失^[46] 关注区域重叠，对类别不平衡问题更加鲁棒：

$$L_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N \sigma(p_i) \cdot y_i + \epsilon}{\sum_{i=1}^N \sigma(p_i) + \sum_{i=1}^N y_i + \epsilon} \quad (2-7)$$

其中， $\epsilon = 10^{-5}$ 为平滑项，用于防止分母为零。Dice 损失关注预测结果与真实标签的重叠程度，能够使模型更加关注前景区域的分割精度。

(3) 组合损失函数。将 BCE 损失和 Dice 损失进行加权组合：

$$L_{\text{total}} = \lambda_1 \cdot L_{\text{BCE}} + \lambda_2 \cdot L_{\text{Dice}} \quad (2-8)$$

其中， λ_1 和 λ_2 分别为 BCE 损失和 Dice 损失的权重。BCE 损失提供逐像素的梯度信号，Dice 损失关注区域重叠，两者组合能够兼顾像素级精度和区域级一致性，从而提升分割性能。

2.2.4 改进模型整体结构

本文提出的改进模型 (DeepLabV3+ + TR) 的整体结构如图 2-5 所示。相比原始 DeepLabV3+，改进模型在 ASPP 模块之后引入了 TR 全局注意力模块。




图 2-5 改进模型（DeepLabV3+ + TR）整体结构图

改进模型的数据流可概括为：输入图像依次经过编码器特征提取、ASPP 多尺度上下文聚合、TR 全局注意力增强、解码器特征融合，最终输出像素级类别预测结果。

TR 模块的引入使模型能够在 ASPP 模块输出的多尺度特征基础上，进一步建立长距离依赖关系，增强对细长熔深结构的整体理解能力。通过 TopK 路由机制，TR 模块在提升性能的同时控制了计算开销。

2.3 实验结果与分析

为验证本文所提方法的有效性，本节在自建焊接 OCT 图像数据集上进行了系统的实验评估。实验包括消融实验和对比实验，分别用于验证 TR 模块的有效性以及改进模型与主流方法的性能对比。

2.3.1 实验环境与参数配置

(1) 实验平台。实验环境包括硬件和软件两部分。硬件方面，本文使用了高性能 GPU 和足够的内存来支持模型的训练和推理。软件方面，本文使用了 PyTorch 深度学习框架和 CUDA 加速库来实现模型训练和推理。实验环境配置如表 2-1 所示。

(2) 训练参数配置。本文采用 Adam 优化器进行模型训练，学习率采用多项式衰减策略，具体参数配置如表 2-2 所示。

表 2-1 实验环境配置

配置项	参数
GPU	NVIDIA GeForce RTX 4090D (24GB) × 1
CPU	AMD EPYC 9754 128-Core Processor (18 vCPU)
内存	60 GB
操作系统	Ubuntu 20.04 LTS
深度学习框架	PyTorch 1.10.0
分割框架	MMSegmentation
GPU 加速工具	CUDA 11.3
编程语言	Python 3.8

表 2-2 实验参数配置

参数	设置
训练迭代次数	20,000 次
批量大小	8
优化器	Adam
初始学习率	1×10^{-6}
学习率调度策略	多项式衰减 (power=0.9)
输入尺寸	512×512
评估间隔	每 500 次迭代

(3) 评价指标。本文采用语义分割领域常用的评价指标来衡量模型性能，主要包括：① mIoU（平均交并比），所有类别 IoU 的平均值，是评估分割性能的核心指标；② mAcc（平均准确率），所有类别准确率的平均值；③ mDice（平均 Dice 系数），所有类别 Dice 系数的平均值，与 IoU 类似但更关注区域重叠；④ Params（参数量），模型的参数数量，单位为 M（百万）。

2.3.2 消融实验

为验证 TR 模块的有效性,本节设计了消融实验,对比基线模型(DeepLabV3+)与引入 TR 模块后的性能差异。消融实验结果如表 2-3 所示。

表 2-3 消融实验结果

模型配置	mIoU	mAcc	mDice	参数量
DeepLabV3+（基线）	0.851	0.923	0.913	95M
DeepLabV3+ + TR	0.884	0.941	0.935	396M
提升	+3.9%	+1.9%	+2.4%	+317%

由表 2-3 可知，引入 TR 模块后，模型在 mIoU 指标上从 0.851 提升至 0.884，

提升幅度达 3.9%。这一提升主要归因于 TR 模块通过双层路由注意力机制建立了长距离依赖关系，增强了模型对全局上下文的理解能力，使得细长熔深结构能够被更完整地分割。

mAcc 和 mDice 指标分别提升了 1.9% 和 2.4%，表明 TR 模块在提升整体分割精度的同时，也改善了区域预测的一致性。虽然 TR 模块引入了额外的参数量（从 95M 增加到 396M），但考虑到性能的显著提升，这一开销是可接受的。

消融实验结果验证了 TR 模块在解决全局上下文建模不足问题上的有效性。通过在 ASPP 输出的多尺度特征上引入全局注意力机制，模型能够更好地理解图像的整体结构，从而提升对细长目标的分割精度。

2.3.3 对比实验

为进一步验证本文方法的优越性，本节将改进模型与多种主流语义分割方法进行对比，包括 U-Net、U-Net++、ResUNet、TransUNet 和原始 DeepLabV3+ 等。对比实验结果如表 3-2 所示。

表 2-4 不同模型在焊接 OCT 数据集上的性能对比

模型	mIoU	mAcc	mDice	参数量
UNet	0.805	0.878	0.880	30M
UNet++	0.751	0.905	0.837	8.8M
ResUNet	0.721	0.788	0.810	13M
TransUNet	0.810	0.963	0.884	219M
DeepLabV3+（基线）	0.851	0.923	0.913	95M
DeepLabV3+ + TR	0.884	0.941	0.935	396M

从表 3-2 可以看出，本文方法在 mIoU 指标上达到 0.884，显著优于所有对比方法。具体分析如下：

（1）与 U-Net 系列对比。相比 U-Net（mIoU=0.805），本文方法提升了 9.8%；相比 U-Net++（mIoU=0.751）和 ResUNet（mIoU=0.721），提升幅度更为显著。这表明传统的编码器-解码器架构在处理 OCT 图像时存在明显的性能瓶颈，而本文方法通过引入全局注意力机制有效解决了这一问题。

（2）与 TransUNet 对比。TransUNet 采用 Transformer 作为编码器，在 mAcc 指标上表现出色（0.963），但其 mIoU（0.810）仍低于本文方法。此外，TransUNet 的参数量（219M）较大，而本文方法在达到更高 mIoU 的同时，参数量虽有增加但性能提升更为显著。

(3) 与基线模型对比。相比 DeepLabV3+ 基线模型, 本文方法在 mIoU、mAcc、mDice 三个核心指标上均有提升, 验证了 TR 模块引入的有效性。




图 2-6 分割结果可视化对比

图 2-6 展示了不同方法在细长熔深结构上的分割结果可视化对比。从可视化结果可以看出, UNet 和 TransUNet 存在明显的断裂现象, DeepLabV3+ 基线模型虽有改善但仍存在局部不连续问题。引入 TR 模块后, 本文方法能够完整地分割细长结构, 有效避免了断裂现象。这主要得益于 TR 模块通过双层路由注意力机制建立了长距离依赖关系, 增强了模型对全局结构的理解能力, 使得模型能够综合考虑整个图像的空间关系, 从而实现更准确的分割。

2.4 本章小结

本章围绕焊接 OCT 图像语义分割任务, 从模型设计、改进方法到实验验证展开了系统性分析。针对 DeepLabV3+ 在处理 OCT 图像时全局上下文建模不足的问题, 提出了一种基于 Transformer 注意力机制的改进方案。

本章的主要工作包括: (1) 详细分析了 DeepLabV3+ 模型的工作原理, 包括空洞卷积、ASPP 模块和编码器-解码器结构, 为改进工作奠定了理论基础; (2) 设计了 TR 全局注意力模块, 通过双层路由注意力机制建立长距离依赖, 在保持全局建模能力的同时将计算复杂度降低约 75%; (3) 设计了 BCE+Dice 混合损失函数, 兼顾像素级精度和区域级一致性, 有效应对类别不平衡问题; (4) 通过消融实验和对比实验验证了所提方法的有效性, TR 模块使 mIoU 提升 3.9% (0.851→0.884), 相比 U-Net 提升 9.8%, 相比 TransUNet 提升 9.1%。

实验结果表明, TR 模块能够有效增强模型对全局上下文的建模能力, 提升对细长熔深结构的分割精度。然而, 在对分割结果的分析中发现, 模型在边界区域的细节表达能力仍有提升空间。第四章将进一步引入空间感知增强 (SAE) 模

块，通过坐标注意力机制增强模型对空间位置信息的感知能力，实现更精确的边界分割。

第三章 基于空间感知增强的 DeepLabV3+ 模型优化

在第三章中，本文针对 DeepLabV3+ 模型在处理焊接 OCT 图像时全局上下文建模不足的问题，提出了 TR（Transformer Routing）全局注意力模块，通过双层路由注意力机制有效增强了模型对长距离依赖关系的建模能力。实验结果表明，引入 TR 模块后，模型的 mIoU 从 0.851 提升至 0.884，验证了全局注意力机制对分割性能的提升作用。

然而，在实际应用中，模型仍面临空间位置信息感知不足的挑战。标准的解码器通过简单的特征拼接融合高层语义信息和低层细节信息，但未显式建模特征图中不同空间位置之间的关联。这导致在处理细长结构的熔深区域时，模型难以精确定位目标边界，尤其在边界模糊和噪声干扰的情况下，边界分割精度有待提升。

针对上述问题，本章提出了空间感知增强（Spatial Awareness Enhancement, SAE）模块。该模块的设计灵感来源于坐标注意力机制^[29]，通过显式建模特征图的空间位置关系，增强模型对目标边界和细节区域的感知能力。同时，本章将 SAE 模块与第三章提出的 TR 模块相结合，构建了完整的 DeepLabV3+ + TR + SAE 改进模型，并通过消融实验和对比实验验证其有效性。

本章结构如下：4.1 节详细介绍 SAE 模块的设计动机、原理与集成方式；4.2 节阐述改进模型的整体结构和各模块的协同机制；4.3 节通过消融实验、对比实验、可视化分析和效率分析全面验证所提方法的有效性；4.4 节对本章内容进行总结。

3.1 空间感知增强模块（SAE）的设计

本节详细介绍空间感知增强模块的设计动机、原理与集成方式。SAE 模块通过引入坐标注意力机制，显式建模特征图的空间位置关系，从而增强模型对目标边界的感知能力。

3.1.1 改进动机

在语义分割任务中，精确的边界定位是实现高质量分割的关键。对于焊接 OCT 图像而言，熔深区域往往呈现细长结构，边界对比度低且常受散斑噪声干扰，这对模型的边界分割能力提出了更高要求。

传统的解码器设计主要关注多尺度特征融合，通过跳跃连接将编码器的低层特征与解码器的高层特征进行拼接或相加。虽然这种设计能够恢复空间细节信息，但存在以下局限性：

(1) 空间位置信息丢失：在编码过程中，多次下采样操作导致空间位置信息逐渐丢失。虽然解码器通过上采样恢复空间分辨率，但位置信息的恢复程度有限。

(2) 通道权重均匀分配：传统解码器对所有通道采用均匀权重，未能区分不同通道对边界分割的贡献差异。实际上，某些通道可能包含更丰富的边界信息，应当给予更高权重。

(3) 缺乏方向性感知：对于细长结构的目标，其在水平和垂直方向上的特征分布存在显著差异。传统解码器缺乏对这种方向性差异的显式建模能力。

为了解决上述问题，本文提出在解码器端引入空间感知增强模块，通过坐标注意力机制显式建模特征图的空间位置关系，增强模型对目标边界和细节区域的感知能力。

3.1.2 SAE 模块原理与结构

注意力机制致力于模拟人类的视觉与认知系统，使网络能够智能地区分数据中主要与次要的部分，进而将注意力聚焦于关键信息之上。在深度学习领域，通道注意力机制通过学习通道间的依赖关系，能够有效增强模型对关键特征的关注度。其中，SE (Squeeze-and-Excitation) 注意力机制^[23]是通道注意力的经典代表，其核心思想在于通过全局平均池化压缩空间信息，再通过全连接层学习通道间的权重关系，最终对各通道进行自适应重标定。SE 机制主要由三个步骤组成：压缩 (Squeeze) 步骤采用全局平均池化操作，将 $H \times W \times C$ 的特征图压缩为 $1 \times 1 \times C$ 的通道描述符；激活 (Excitation) 步骤通过两个全连接层学习通道间的非线性依赖关系；标准化 (Scale) 步骤根据学习到的权重对原特征图的各通道进行缩放。

尽管 SE 机制在提升模型性能方面取得了显著成果，但它存在一个关键局限：全局池化将空间信息压缩为单一的通道描述符，因此难以保留位置信息，而位置信息对于语义分割任务中捕捉空间结构至关重要。针对这一问题，Hou 等人^[29]提出了坐标注意力 (Coordinate Attention, CA) 机制，通过将二维全局池化解耦

为一对一维特征编码操作，在保留位置信息的同时实现通道注意力的功能。

本文提出的 SAE (Spatial Awareness Enhancement) 模块融合了坐标注意力与通道注意力的优势，其结构如图 3-1 所示。如图所示，SAE 模块由三部分组成：坐标注意力分支、特征卷积层和通道注意力分支。整体工作流程可细分为坐标信息嵌入、坐标注意力生成、特征精炼和通道增强四个阶段。




图 3-1 SAE 模块结构图

(1) 坐标信息嵌入

为赋予注意力模块在水平与垂直两个方向上的位置感知能力，SAE 模块首先将全局池化解耦为两个一维特征编码过程。具体而言，采用大小为 $(H, 1)$ 和 $(1, W)$ 的池化核对每个通道沿两个方向分别进行池化。给定输入特征图 $X \in \mathbb{R}^{C \times H \times W}$ ，对于高度为 h 的第 c 个通道，其水平方向的输出为：

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i < W} x_c(h, i) \quad (3-1)$$

对于宽度为 w 的第 c 个通道，其垂直方向的输出为：

$$z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \quad (3-2)$$

其中， $z^h \in \mathbb{R}^{C \times H \times 1}$ 和 $z^w \in \mathbb{R}^{C \times 1 \times W}$ 分别表示水平和垂直方向的聚合特征。与 SE 机制采用的全局平均池化不同，上述两个变换分别沿着水平和垂直方向对特征进行聚合，生成了一对能够感知方向和位置的特征图。这两个特征图不仅嵌入了特定方向的空间信息，而且能够捕获输入特征图在各自方向上的长程依赖关系。

（2）坐标注意力生成

坐标注意力的生成遵循三大原则：追求简单高效与灵活性，充分利用精确位置信息以定位感兴趣区域，以及有效捕捉通道间的相互关系。为实现这些目标，SAE 模块将前一步生成的两个特征图沿空间维度拼接，并通过共享的 1×1 卷积进行处理，生成包含水平与垂直方向空间信息的中间特征图 f ：

$$f = \delta(F_{1 \times 1}([z^h, z^w])) \quad (3-3)$$

其中， $[\cdot, \cdot]$ 表示沿空间维度的拼接操作， δ 表示 BatchNorm 和非线性激活函数。随后，中间特征图 f 沿空间维度被切分为 f^h 和 f^w 两个张量，再分别通过两个独立的 1×1 卷积 F_h 和 F_w 进行变换，使输出通道数与输入特征图相匹配：

$$g^h = \sigma(F_h(f^h)), \quad g^w = \sigma(F_w(f^w)) \quad (3-4)$$

其中， σ 表示 Sigmoid 激活函数， $g^h \in \mathbb{R}^{C \times H \times 1}$ 和 $g^w \in \mathbb{R}^{C \times 1 \times W}$ 分别表示水平和垂直方向的注意力权重。如图 3-1 上半部分所示，坐标注意力分支首先通过 X Avg Pool 和 Y Avg Pool 分别沿水平和垂直方向聚合特征，然后经过拼接、卷积、

归一化和非线性激活后分裂为两个分支，各自通过独立的 1×1 卷积和 Sigmoid 激活生成方向性注意力权重，最后通过 Re-weight 操作对输入特征进行空间重标定。

（3）特征重标定与残差连接

将生成的注意力权重 g^h 和 g^w 应用于输入特征图的每个通道，允许根据全局信息调整每个空间位置的特征响应。坐标注意力的输出由下式给出：

$$y_c(i, j) = x_c(i, j) \times g_c^h(i) \times g_c^w(j) \quad (3-5)$$

其中， $y_c(i, j)$ 表示输出特征图第 c 个通道在位置 (i, j) 处的值。如图 3-1 所示，坐标注意力分支的输出与输入通过残差连接相加，保留原始特征信息的同时融入空间位置感知能力。

（4）特征精炼

经过坐标注意力增强后的特征进入两层 3×3 卷积模块，每层包含卷积、批归一化和 ReLU 激活函数，用于进一步精炼和融合特征表示。该模块的输出同样通过残差连接与输入相加，如图 3-1 中间部分所示。

（5）通道注意力增强

如图 3-1 下半部分所示，SAE 模块在坐标注意力之后引入了 SE 风格的通道注意力分支，采用多分支并行结构增强通道间的特征交互。具体而言，首先通过全局平均池化将特征图压缩为 $1 \times 1 \times C$ 的通道描述符；然后通过 4 个并行的全连接层（每个分支输出通道数为 C/r ， r 为压缩比）分别捕捉不同的通道依赖模式；接着将 4 个分支的输出拼接并通过另一个全连接层和 Sigmoid 激活生成最终的通道注意力权重；最后通过逐元素乘法（Scale）对特征图的各通道进行自适应重标定。

坐标注意力通过坐标轴分解策略，将二维全局空间编码解耦为水平—垂直方向的一维位置感知，增强了模型对细长结构边界的定位能力；通道注意力则通过学习通道间的依赖关系，突出判别性通道的特征响应。二者的协同作用实现了空间与通道维度的双重特征增强，使模型能够更准确地定位目标边界，在处理细长形目标和边缘模糊区域时表现出显著优势。

3.1.3 SAE 模块集成方式

SAE 模块被集成到 DeepLabV3+ 的解码器端，具体位置如图 3-2 所示。

在解码器的特征融合过程中，SAE 模块位于低层特征降维之后、与高层特征拼接之前。这一位置选择基于以下考虑：低层特征包含丰富的空间细节信息，但也包含较多噪声；在特征拼接前引入空间感知增强，可以突出边界相关的重要特征，抑制噪声干扰，从而提升后续特征融合的质量。

SAE 模块采用轻量化设计，主要包含池化操作和少量卷积层，在引入较小计算开销的同时实现显著的性能提升。

3.2 改进模型的整体结构

经过第三章和本章的改进后，最终的模型结构如图 3-2 所示。本节详细介绍改进模型的完整架构和各模块的协同机制。

3.2.1 完整模型架构




图 3-2 改进模型（DeepLabV3+ + TR + SAE）整体结构图

改进后的模型在原始 DeepLabV3+ 模型的基础上，主要包含以下优化：

(1) 编码器端引入 TR 模块：在 ASPP 模块之后引入 TR 全局注意力模块，通过双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力。

(2) 解码器端集成 SAE 模块: 在解码器的低层特征处理分支中集成 SAE 模块, 通过坐标注意力机制增强空间位置感知能力, 突出边界相关的重要特征。

(3) 混合损失函数: 采用 BCE+Dice 混合损失函数进行训练, 有效缓解类别不平衡问题, 提升模型对目标类别的分割性能。

3.2.2 各模块协同机制

TR 模块和 SAE 模块在模型中分别承担不同的功能, 形成“全局-局部”互补的协同机制:

(1) TR 模块的全局建模作用

TR 模块位于编码器端, 在 ASPP 模块之后对高层语义特征进行全局上下文增强。通过双层路由注意力机制, TR 模块能够建立长距离依赖关系, 理解图像的全局空间结构; 捕捉细长结构目标的整体形态, 避免断裂和误分割; 在全局视角下抑制噪声区域的干扰。

TR 模块通过 Top-K 区域选择策略, 优先关注与查询区域语义相关的关键区域, 在保持计算效率的同时实现有效的全局上下文建模。

(2) SAE 模块的局部增强作用

SAE 模块位于解码器端, 对低层细节特征进行空间位置感知增强。通过坐标注意力机制, SAE 模块能够显式建模特征图的空间位置关系, 增强位置敏感性; 自适应调整不同空间位置的特征权重, 突出边界区域; 在水平和垂直两个方向上分别捕捉位置信息, 适应细长结构的方向性特征。

SAE 模块以较小的计算开销实现显著的边界分割精度提升。

(3) 协同效应

TR 模块和 SAE 模块协同作用, 在编码器端增强全局结构理解能力, 在解码器端优化局部边界表示, 实现了“编码重结构、解码重细节”的优化目标。这种设计使模型能够同时处理全局和局部信息, 在保持整体分割准确性的同时, 显著提升边界分割精度。

消融实验结果表明, 单独使用 TR 模块可提升 mIoU 3.9%, 单独使用 SAE 模块可提升 mIoU 5.9%, 而同时使用两个模块可提升 mIoU 7.1%, 体现了两个模块的互补性和协同效应。

3.3 综合实验与分析

本节对所提出的 DeepLabV3+ + TR + SAE 改进模型进行全面的实验验证与分析。首先通过消融实验验证各模块的贡献，然后与主流方法进行对比实验，接着通过可视化分析定性评估分割效果，最后分析模型的计算效率。

3.3.1 消融实验

为验证各改进模块的有效性，本文设计了消融实验，通过逐项添加模块，分析各模块对模型性能的贡献。消融实验共设计 4 种配置，如表 3-1 所示。

表 3-1 消融实验结果

配置	TR 模块	SAE 模块	mIoU	mAcc	mDice	相比基线提升
DeepLabV3+ (基线)	×	×	0.851	0.923	0.913	-
+ TR	✓	×	0.884	0.941	0.935	+3.9%
+ SAE	×	✓	0.901	0.948	0.945	+5.9%
+ TR + SAE	✓	✓	0.911	0.956	0.951	+7.1%

由表 3-1 可知，各模块均能带来性能增益：

(1) TR 模块贡献：单独引入 TR 模块后，mIoU 从 0.851 提升至 0.884，提升幅度达 3.9%。这表明全局上下文建模对分割性能有显著提升作用，TR 模块通过建立长距离依赖关系，增强了模型对细长结构目标的整体理解能力。

(2) SAE 模块贡献：单独引入 SAE 模块后，mIoU 从 0.851 提升至 0.901，提升幅度达 5.9%。这表明空间位置感知对边界分割具有重要意义，SAE 模块通过坐标注意力机制显著提升了边界分割精度。值得注意的是，SAE 模块仅增加 25M 参数量，参数效率（mIoU 提升/参数量增加）达到 0.236，远高于 TR 模块的 0.013。

(3) 双重注意力协同效应：同时引入 TR 模块和 SAE 模块后，mIoU 从 0.851 提升至 0.911，提升幅度达 7.1%。组合提升幅度（7.1%）小于单模块提升幅度之和（3.9% + 5.9% = 9.8%），这表明两模块在提升路径上存在一定重叠。然而，组合配置在所有指标上均取得最优结果，体现了全局（TR）与局部（SAE）信息增强的互补性。

综合以上分析，双重注意力机制产生协同效应，性能提升超过单独使用任一模块的效果，验证了本文方法设计的有效性。

3.3.2 与主流方法对比实验

为验证本文方法的有效性，在相同实验设置下与基线模型及多种主流语义分割方法进行对比。对比方法包括 UNet、UNet++、ResUNet、TransUNet 以及 DeepLabV3+ 等，涵盖了编码器-解码器架构和 Transformer 架构等不同类型的分割网络。

表 3-2 给出了所有对比方法在测试集上的定量评估结果。

表 3-2 不同方法的定量评估结果对比

模型配置	mIoU	mAcc	mDice	mPrecision	mRecall
UNet	0.805	0.878	0.880	0.883	0.878
UNet++	0.751	0.905	0.837	0.790	0.905
ResUNet	0.721	0.788	0.810	0.836	0.788
TransUNet	0.810	0.963	0.884	0.829	0.963
DeepLabV3+ (基线)	0.851	0.923	0.913	0.904	0.923
本文方法	0.911	0.956	0.951	0.947	0.956

由表 3-2 可知，本文方法（DeepLabV3+ + TR + SAE）在所有分割性能指标上均取得最优结果：

(1) 相比基线模型：本文方法在 mIoU 指标上达到 0.911，相比基线模型（DeepLabV3+）提升 7.1%，在 mAcc 指标上提升 3.6%，在 mDice 指标上提升 4.2%。这一结果表明，TR 模块和 SAE 模块的引入有效提升了模型的分割性能。

(2) 相比 UNet 系列方法：本文方法相比 UNet 基础版本，mIoU 提升 13.2%，mAcc 提升 8.9%。相比 UNet++ 和 ResUNet，本文方法也均取得显著提升。这一结果表明，本文方法在编码器-解码器架构的基础上，通过引入双重注意力机制，有效提升了分割性能。

(3) 相比 TransUNet：虽然 TransUNet 在 mAcc 指标上略高于本文方法（0.963 vs 0.956），但本文方法在 mIoU 指标上显著优于 TransUNet（0.911 vs 0.810），提升幅度达 12.5%。更重要的是，本文方法在计算效率方面具有明显优势（详见效率分析部分）。

表 3-3 给出了不同方法在背景类别和目标类别上的性能对比。

由表 3-3 可知，本文方法在目标类别上取得了显著提升。目标类别的 IoU 达到 0.826，相比基线模型（0.710）提升 16.3%，相比 UNet（0.620）提升 33.2%，相比 TransUNet（0.632）提升 30.7%。目标类别性能的大幅提升表明，本文方法

表 3-3 不同方法在类别级别上的性能对比

模型配置	背景类别		目标类别		
	IoU	Acc	IoU	Acc	Dice
UNet	0.990	0.995	0.620	0.761	0.765
TransUNet	0.988	0.999	0.632	0.926	0.773
DeepLabV3+ (基线)	0.992	0.996	0.710	0.850	0.830
本文方法	0.996	0.998	0.826	0.914	0.904

通过 TR 模块增强全局上下文建模和 SAE 模块增强局部细节表达，有效提升了对熔深目标的分割精度。

表 3-4 给出了不同方法的边界精度对比，采用 HD95 指标进行评估。

表 3-4 不同方法的边界精度对比

模型配置	HD95	边界精度评价
UNet	15.23	中等
DeepLabV3+ (基线)	12.22	良好
DeepLabV3+ + TR	11.89	良好
DeepLabV3+ + SAE	11.45	优秀
本文方法	10.68	优秀

由表 3-4 可知，本文方法的 HD95 指标达到 10.68，相比基线模型（12.22）降低 12.6%，相比 UNet（15.23）降低 29.9%。HD95 值越小，表示边界分割越精确。值得注意的是，单独使用 SAE 模块时，HD95 为 11.45，已经取得了较好的边界精度；结合 TR 模块后，HD95 进一步降低至 10.68，说明双重注意力机制在边界精度提升方面具有协同效应。

3.3.3 可视化分析

本节通过可视化对比分析，从定性角度评估全部 8 个模型配置的分割效果，包括 4 种主流方法（UNet、UNet++、ResUNet、TransUNet）和 4 种消融配置（DeepLabV3+ 基线、+TR、+SAE、+TR+SAE）。

图 3-3 展示了全部 8 个模型的分割结果可视化对比。从消融实验角度分析：单独引入 TR 模块后，细长结构的分割连续性得到明显改善；单独引入 SAE 模块后，边界轮廓更加清晰锐利；同时引入两个模块后，分割结果兼具全局结构的完整性和边界的精确性。从主流方法对比角度分析，本文方法在以下方面表现出明显优势：




图 3-3 全部方法的分割结果可视化对比

(1) 边界清晰度: 本文方法在边界分割方面表现出色, 边界更加清晰和连续。SAE 模块通过坐标注意力增强空间位置信息, 使得边界特征更加突出。相比之下, UNet 系列方法在边界模糊区域存在边界断裂或粘连问题。

(2) 细长结构处理: 本文方法能够准确分割细长的熔深区域。TR 模块通过双层路由注意力机制建立长距离依赖关系, 使得网络能够理解整个图像的空间关系。相比之下, UNet、UNet++ 和 ResUNet 在细长结构上存在断裂现象, TransUNet 虽有改善但精度仍不及本文方法。

(3) 噪声干扰下的鲁棒性: 本文方法在噪声干扰下表现出较强的鲁棒性。TR 模块通过全局上下文建模抑制局部噪声的影响, SAE 模块通过局部细节增强保留重要的边界信息, 两者结合使得网络在噪声干扰下仍能稳定学习目标的语义结构。

3.3.4 效率分析

在实际应用中, 除了分割性能外, 模型的计算效率也是重要的考量因素。表 3-5 从参数量、内存占用和推理时间三个方面对不同方法进行对比分析。

表 3-5 不同方法的效率指标对比

模型配置	参数量 (M)	内存占用 (MB)	推理时间 (ms)
UNet	30	3809	45
TransUNet	219	19530	156
DeepLabV3+ (基线)	95	2705	38
DeepLabV3+ + SAE	120	7011	52
DeepLabV3+ + TR	396	7004	89
本文方法	420	9107	95

由表 3-5 可知:

(1) 参数量分析: 本文方法的参数量为 420M, 相比基线模型 (95M) 增加 342.1%。参数量增加主要来源于 TR 模块 (+301M) 和 SAE 模块 (+25M)。虽然

参数量增加较大，但性能提升显著（mIoU 提升 7.1%），参数效率合理。

(2) 内存占用分析: 本文方法的内存占用为 9107MB, 相比基线模型 (2705MB) 增加 236.7%。但相比 TransUNet (19530MB), 本文方法的内存占用减少 53.3%, 在性能更优的同时具有更低的内存需求。

(3) 推理时间分析: 本文方法的推理时间为 95ms, 相比 TransUNet (156ms) 减少 39.1%, 在性能更优的同时具有更快的推理速度。

(4) 效率权衡: 综合考虑性能和效率, 本文方法在 mIoU 提升 12.5% 的同时 (相比 TransUNet), 内存占用减少 53.3%, 推理时间减少 39.1%, 取得了性能与效率的良好平衡。

3.4 本章小结

本章在第三章的基础上, 围绕空间位置信息感知不足的问题进行了深入探讨, 提出了空间感知增强 (SAE) 模块, 并构建了完整的 DeepLabV3++ TR + SAE 改进模型。

在模块设计方面, SAE 模块的设计灵感来源于坐标注意力机制, 通过沿水平和垂直两个方向进行特征聚合, 显式建模特征图的空间位置关系。该模块能够自适应调整不同空间位置的特征权重, 突出边界区域的特征表示, 从而提升边界分割精度。SAE 模块以较小的参数量 (+25M) 实现了显著的性能提升 (mIoU +5.9%), 参数效率较高。

在模型架构方面, 本章将 SAE 模块集成到解码器端, 与第三章提出的 TR 模块形成“全局-局部”互补的协同机制。TR 模块在编码器端负责全局上下文建模, SAE 模块在解码器端负责局部细节增强, 两者协同作用实现了分割性能的综合提升。

在实验验证方面, 本章设计了消融实验、对比实验、可视化分析和效率分析, 全面验证了所提方法的有效性:

(1) 性能优势: 本文方法在 mIoU 指标上达到 0.911, 相比基线模型提升 7.1%, 相比 UNet 提升 13.2%, 相比 TransUNet 提升 12.5%。目标类别 IoU 提升 16.3%, 边界精度 HD95 降低 12.6%。

(2) 效率优势: 相比 TransUNet, 本文方法在性能更优的同时, 内存占用减少 53.3%, 推理时间减少 39.1%。

(3) 协同效应: 消融实验验证了 TR 模块和 SAE 模块的互补性和协同效应, 双重注意力机制的组合使用取得了最优性能。

综合以上实验结果和分析, 本章提出的改进方案使得最终模型在分割精度和效率之间达到了较好的平衡, 验证了所提方法在焊接 OCT 图像语义分割任务中的有效性和实用性。

第四章 总结与展望

4.1 总结

本研究聚焦于基于 OCT 图像的激光焊接熔深语义分割问题,针对 DeepLabV3+ 模型在处理 OCT 图像时存在的全局上下文建模不足和边界定位不精确等问题,提出了一种融合双重注意力机制的改进方案。

在数据层面,本文针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题,在真实激光焊接实验平台上采集原始 OCT 成像数据,制定统一标注规范并完成像素级精细标注,通过数据增强策略构建了包含约 1000 余张图像的专用数据集,为后续研究提供了数据支撑。

在模型改进方面,本文的核心工作在于设计了 TR 全局注意力模块和 SAE 空间感知增强模块。TR 模块基于双层路由注意力机制,通过 Top-K 区域选择策略在编码器端建立长距离依赖关系,增强模型对细长结构目标的整体理解能力;SAE 模块基于坐标注意力机制,通过沿水平和垂直两个方向进行特征聚合,在解码器端显式建模特征图的空间位置关系,提升边界分割精度。两个模块相互配合,实现了“编码重结构、解码重细节”的优化目标。同时,本文采用 BCE+Dice 混合损失函数有效缓解了类别不平衡问题。

在实验验证方面,本文通过消融实验、对比实验、可视化分析和效率分析,全面验证了改进方案的有效性。实验结果表明,改进后的模型在 mIoU 指标上达到 0.911,相比基线模型提升 7.1%;目标类别 IoU 从 0.710 提升至 0.826,提升幅度达 16.3%;边界精度 HD95 从 12.22 降低至 10.68,降低 12.6%。与 UNet、TransUNet 等主流方法相比,本文方法在分割精度和边界精度方面均取得显著提升,同时相比 TransUNet 内存占用减少 53.3%、推理时间减少 39.1%,在性能与效率之间取得了良好平衡。

本研究的成果对激光焊接质量在线检测具有重要的应用价值,改进后的模型能够更准确地从 OCT 图像中分割出熔深区域,为焊接过程的实时监控和质量评估提供技术支撑。

4.2 展望

尽管本研究取得了一定的成果，但仍存在一些不足之处。在极端噪声条件下（如散斑噪声非常严重、图像质量极差），模型可能出现误分割问题；对于形态异常的目标（如熔深区域形状极其不规则、存在多个目标重叠等），模型的分割能力有限；此外，模型的推理速度虽然满足基本需求，但在高速焊接场景下仍有进一步优化的空间。

针对上述不足，未来的研究可以从以下几个方向展开。首先，可以探索更先进的轻量级骨干网络（如 MobileNetV3、EfficientNet 等），在保持分割精度的同时进一步提升推理速度，为边缘部署提供可能。其次，可以引入更高级的注意力机制（如多尺度注意力、可变形注意力等），增强模型对复杂形态目标的适应能力。此外，结合 OCT 信号的其他特征（如光强信息、相位信息等）进行多模态融合，有望进一步提升检测的准确性和可靠性。最后，开展基于深度学习的焊接熔深实时在线检测和反馈控制研究，实现焊接质量的闭环控制，是该技术走向工程应用的重要方向。

本研究验证了深度学习技术在焊接质量检测领域的应用潜力，希望通过不断的创新和改进，为焊接智能化检测技术的发展贡献更多的解决方案。

参考文献

- [1] 高世一, 高世一, 吴瑞珉, 等. 激光焊接过程监测及焊缝质量检测技术研究现状 [J]. 世界钢铁, 2010(003): 51–54.
- [2] CHEN Z, GAO X. Detection of weld pool width using infrared imaging during high-power fiber laser welding of type 304 austenitic stainless steel[J]. The International Journal of Advanced Manufacturing Technology, 2014, 74(9): 1247–1254.
- [3] 张兵宪, 张敏, 张云龙, 等. 工艺参数对 304 不锈钢薄板激光焊接接头组织及力学性能的影响 [J]. 热加工工艺, 2021, 50(21): 19–24.
- [4] 温鹏, 邬瑞峰, 王秀义, 等. 不锈钢车体搭接接头激光非熔透焊接工艺及其拉剪性能 [J]. 中国机械工程, 2017, 28(11): 1355.
- [5] SVENUNGSSON J, CHOQUET I, KAPLAN A F. Laser welding process—a review of keyhole welding modelling[J]. Physics procedia, 2015, 78: 182–191.
- [6] BOLEY M, FETZER F, WEBER R, et al. Statistical evaluation method to determine the laser welding depth by optical coherence tomography[J]. Optics and Lasers in Engineering, 2019, 119: 56–64.
- [7] MITTELSTÄDT C, MATTULAT T, SEEFELD T, et al. Novel approach for weld depth determination using optical coherence tomography measurement in laser deep penetration welding of aluminum and steel[J]. Journal of Laser Applications, 2019, 31(2).
- [8] 谢冠明, 王三宏, 张跃强, 等. 基于光学相干层析的激光焊接熔深监测方法 [J]. Acta Optica Sinica, 2023, 43(11): 1114002–1114002.
- [9] XIE G, WANG S, ZHANG Y, et al. An Efficient Method for Laser Welding Depth Determination Using Optical Coherence Tomography[J]. Sensors, 2023, 23(11): 5223.
- [10] STAVRIDIS J, PAPACHARALAMPOPOULOS A, STAVROPOULOS P. Quality assessment in laser welding: a critical review[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94(5): 1825–1847.
- [11] ATAMURADOV V, MEDJAHAR K, DERSIN P, et al. Prognostics and health management for maintenance practitioners-Review, implementation and tools evaluation[J]. International Journal of Prognostics and Health Management, 2017, 8(3): 1–31.
- [12] 严毅, 邓超, 李琳, 等. 深度学习背景下的图像语义分割方法综述 [J]. 中国图象图形学报, 2023, 28(11): 3342–3362.
- [13] LONG J, SHELHAMER E, DARRELL T. Fully Convolutional Networks for Semantic Segmentation[J]. arXiv preprint arXiv:1411.4038, 2015.
- [14] BADRINARAYANAN V, KENDALL A, CIPOLLA R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(12): 2481–2495.
- [15] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. arXiv preprint arXiv:1505.04597, 2015.
- [16] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.
- [17] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs[J]. arXiv preprint arXiv:1412.7062, 2014.
- [18] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. DeepLab: Semantic Image Segmentation

- tion with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. arXiv preprint arXiv:1606.00915, 2016.
- [19] CHEN L-C, PAPANDREOU G, SCHROFF F, et al. Rethinking Atrous Convolution for Semantic Image Segmentation[J]. arXiv preprint arXiv:1706.05587, 2017.
- [20] CHEN L-C, ZHU Y, PAPANDREOU G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[J]. arXiv preprint arXiv:1802.02611, 2018.
- [21] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2017 : 2881 – 2890.
- [22] WANG J, SUN K, CHENG T, et al. Deep high-resolution representation learning for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43(10) : 3349 – 3364.
- [23] HU J, SHEN L, ALBANIE S, et al. Squeeze-and-Excitation Networks[J]. arXiv preprint arXiv:1709.01507, 2019.
- [24] WOO S, PARK J, LEE J-Y, et al. Cbam: Convolutional block attention module[C] // Proceedings of the European conference on computer vision (ECCV). 2018 : 3 – 19.
- [25] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2018 : 7794 – 7803.
- [26] FU J, LIU J, TIAN H, et al. Dual Attention Network for Scene Segmentation[J]. arXiv preprint arXiv:1809.02983, 2019.
- [27] HUANG Z, WANG X, WEI Y, et al. CCNet: Criss-Cross Attention for Semantic Segmentation[J]. arXiv preprint arXiv:1811.11721, 2020.
- [28] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[J]. arXiv preprint arXiv:1910.03151, 2020.
- [29] HOU Q, ZHOU D, FENG J. Coordinate Attention for Efficient Mobile Network Design[J]. arXiv preprint arXiv:2103.02907, 2021.
- [30] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [31] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. arXiv preprint arXiv:2103.14030, 2021.
- [32] ZHENG S, LU J, ZHAO H, et al. Rethinking Semantic Segmentation from a Sequence-to-Sequence Perspective with Transformers[J]. arXiv preprint arXiv:2012.15840, 2021.
- [33] XIE E, WANG W, YU Z, et al. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers[J]. arXiv preprint arXiv:2105.15203, 2021.
- [34] CHENG B, MISRA I, SCHWING A G, et al. Masked-attention Mask Transformer for Universal Image Segmentation[J]. arXiv preprint arXiv:2112.01527, 2022.
- [35] CHEN J, LU Y, YU Q, et al. TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation[J]. arXiv preprint arXiv:2102.04306, 2021.
- [36] YU C, GAO C, WANG J, et al. Bisenet v2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International journal of computer vision, 2021, 129(11) : 3051 – 3068.
- [37] ZHAO H, QI X, SHEN X, et al. Icnet for real-time semantic segmentation on high-resolution images[C] // Proceedings of the European conference on computer vision (ECCV). 2018 : 405 – 420.
- [38] YU C, XIAO B, GAO C, et al. Lite-hrnet: A lightweight high-resolution network[C]

- // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021 : 10440–10450.
- [39] 王卓, 瞿绍军. 深度学习实时语义分割研究进展和挑战 [J]. 中国图象图形学报, 2024, 29(5): 1188–1220.
- [40] CORDTS M, OMRAN M, RAMOS S, et al. The cityscapes dataset[C] // CVPR Workshop on the Future of Datasets in Vision. 2015, 2: 1.
- [41] PATEL S. Bacterial Colony Classification Using Atrous Convolution with Transfer Learning Authors[J]. Annals of the Romanian Society for Cell Biology, 2021 : 1428–1441.
- [42] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[J]. arXiv preprint arXiv:1512.03385, 2015.
- [43] WU Z, SHEN C, van den HENGEL A. Wider or Deeper: Revisiting the ResNet Model for Visual Recognition[J]. arXiv preprint arXiv:1611.10080, 2016.
- [44] ZHU L, WANG X, KE Z, et al. BiFormer: Vision Transformer with Bi-Level Routing Attention[J]. arXiv preprint arXiv:2303.08810, 2023.
- [45] LIN T-Y, GOYAL P, GIRSHICK R, et al. Focal Loss for Dense Object Detection[J]. arXiv preprint arXiv:1708.02002, 2018.
- [46] LI X, SUN X, MENG Y, et al. Dice Loss for Data-imbalanced NLP Tasks[J]. arXiv preprint arXiv:1911.02855, 2020.

致 谢

研究生阶段的学习即将画上句号，回望这三年的科研旅程，我深知自己的成长离不开许多人的帮助与支持。

首先，我要衷心感谢我的导师万明明老师，感谢他在这三年中对我的悉心指导。在实验设计和论文写作方面，万老师给了我诸多宝贵的建议和帮助。导师严谨的治学态度和广博的学识一直是我不断进步的动力，他的谆谆教诲让我受益匪浅。同时，深圳大学良好的科研环境以及学院相关部门与领导对学生的关怀也让我十分受益。

感谢实验室的各位老师和同学们。特别感谢谢沛师兄，在整个研究过程中不仅帮助我明确了研究思路，还提供了许多宝贵的建议，使我能够更高效地开展实验工作。感谢黄敦鸿、安康等同学，在学术和生活上都给予了我无私的帮助和支持，你们的友谊和鼓励让我在困境中保持信心。

最后，最感激的还是我的家人，正是你们的支持让我无论在科研还是生活中都能够坚持到底。你们是我不断前行的坚实后盾，在未来的路上，我将继续以你们为动力，勇敢追求自己的理想。

再次感谢所有帮助过我的老师、同学以及家人朋友，感谢你们的一切付出！感谢参与论文盲审的各位专家和答辩委员会的各位评委！

攻读硕士学位期间的研究成果

学术论文

[1] PEI S, HUANG L L, LI G, et al. Magnetic Raman Continuum in Single-Crystalline $\text{H}_3\text{LiIr}_2\text{O}_6$ [J]. Physical Review B, 2020, 101(20):201101(R). (SCI 收录, IDS 号为 LJ4UN, IF=3.575, 对应学位论文 2.2 节和第 5 章)

已获得及申请的专利（无专利时此项不必列出）

[2] XXX, XX.

其他研究成果（无其他研究成果时此项不必列出）

[3] XXX, XX.