

分类号	xxxx
UDC	xxxx

学校代码	xxxx
密 级	公开

硕士学位论文

基于 xxxxxxx 分析

学位申请人姓名	xxxxxx
---------	--------

学位申请人学号	xxxxxxxx
---------	----------

专业（领域）名称	xxxxxxxx
----------	----------

学 位 类 别	xxxxxx
---------	--------

学院（部、研究院）	xxxxxx
-----------	--------

导 师 姓 名	xxxxxx
---------	--------

二〇二四年五月

XXX 大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文基于 xxxx 与 xxxx 分析是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律后果由本人承担。

论文作者签名：

日期： 年 月 日

XXX 大学

学位论文使用授权说明

本学位论文作者完全了解深圳大学关于收集、保存、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属深圳大学。学校有权保留学位论文并向国家主管部门或其他机构送交论文的电子版和纸质版，允许论文被查阅和借阅。本人授权深圳大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（涉密学位论文在解密后适用本授权书）

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘要

光学相干断层扫描 (OCT) 图像语义分割是激光焊接熔池检测等工业视觉任务中的关键环节。受散斑噪声、边界模糊以及目标与背景对比不足等因素影响, 基于卷积的分割模型在复杂工况下易出现全局语义理解不足与边界刻画不精的问题, 从而限制分割结果的稳定性与工程可用性。针对上述问题, 本文提出一种基于改进 DeepLabV3+ 的 OCT 图像语义分割方法。

本文方法以 DeepLabV3+ 为基础框架, 在多尺度上下文聚合的基础上引入全局与局部两类注意力建模机制。具体而言, 在 ASPP 输出后嵌入 TR (Transformer Routing) 模块, 通过路由式注意力在可控计算开销下增强长程依赖建模能力, 以提升对目标整体结构与上下文关系的表征; 在解码器高低层特征融合后引入 SAE (Spatial Attention Enhancement) 模块, 通过空间与通道的联合增强强化关键区域响应与边界细节表达, 从而改善细长结构与模糊边界处的分割质量。此外, 采用交叉熵损失与 Dice 损失的组合以缓解类别不平衡带来的训练偏置。

在包含 912 张训练图像与 228 张测试图像的 OCT 数据集上进行实验验证。结果显示, 所提方法的 mIoU 达到 0.911, 较基线 DeepLabV3+ 提升 7.1%。上述结果表明, TR 与 SAE 的联合引入能够在统一的编码器—解码器框架内兼顾全局语义建模与局部细节增强, 为 OCT 图像的高精度语义分割提供一种有效实现途径。

关键词: 语义分割; DeepLabV3+; 注意力机制; OCT 图像; 激光焊接

ABSTRACT

Optical Coherence Tomography (OCT) image semantic segmentation is a key component in industrial vision tasks such as laser welding molten pool inspection. In practical scenarios, speckle noise, blurred boundaries, and weak target–background contrast often lead convolution-based segmentation models to suffer from insufficient global context understanding and inaccurate boundary delineation, thereby limiting robustness and practical usability. To address these issues, this thesis proposes an improved DeepLabV3+-based method for OCT image semantic segmentation.

Built upon the DeepLabV3+ encoder–decoder architecture, the proposed approach introduces both global and local attention modeling on top of multi-scale context aggregation. Specifically, a TR (Transformer Routing) module is inserted after ASPP to enhance long-range dependency modeling and global context representation under controllable computational cost via routing-based attention. In addition, an SAE (Spatial Attention Enhancement) module is applied after decoder feature fusion to strengthen local details and boundary-aware representations through joint spatial and channel enhancement. A hybrid loss combining cross-entropy and Dice loss is further adopted to mitigate training bias caused by class imbalance.

Experiments on an OCT dataset with 912 training images and 228 test images demonstrate that the proposed method achieves an mIoU of 0.911, outperforming the baseline DeepLabV3+ by 7.1%. The results indicate that the joint integration of TR and SAE can balance global semantic modeling and local boundary enhancement within a unified encoder–decoder framework, providing an effective solution for high-precision OCT image segmentation in practical industrial scenarios.

Key words: Semantic Segmentation; DeepLabV3+; Attention Mechanism; OCT Image; Laser Welding

目 录

摘 要	I
ABSTRACT	II
符号和缩略语说明	VI
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	2
1.2.1 激光焊接过程监测技术现状	2
1.2.2 OCT 图像噪声特性及处理方法研究现状	3
1.2.3 图像语义分割算法研究现状	4
1.3 本文主要研究内容	5
1.4 论文组织结构	6
第二章 相关理论与技术基础	8
2.1 OCT 成像原理	8
2.1.1 OCT 成像基本原理	8
2.1.2 OCT 技术分类	9
2.1.3 OCT 在激光焊接中的应用	10
2.1.4 OCT 图像特点	11
2.2 深度学习基础	11
2.2.1 卷积神经网络基础	11
2.2.2 编码器-解码器架构	14
2.2.3 注意力机制基础	14
2.3 语义分割理论基础	15
2.3.1 全卷积网络	15
2.3.2 U-Net 架构	16
2.3.3 DeepLab 系列方法	16
2.3.4 多尺度特征融合策略	18
2.4 焊接 OCT 图像数据集构建	19
2.4.1 OCT 图像采集	19
2.4.2 图像预处理	19
2.4.3 基于 LabelMe 的熔深线段标注	20
2.4.4 数据增强策略	22

2.4.5 数据集划分与统计	23
2.5 语义分割评价指标	24
2.5.1 混淆矩阵	24
2.5.2 像素准确率	25
2.5.3 平均像素准确率	25
2.5.4 交并比	25
2.5.5 平均交并比	26
2.5.6 Dice 系数	26
2.5.7 评价指标的适用场景	26
2.6 本章小结	27
第三章 基于改进 DeepLabV3+ 的焊接 OCT 图像分割算法	29
3.1 DeepLabV3+ 模型的工作原理	29
3.1.1 空洞卷积	30
3.1.2 ASPP 模块	31
3.1.3 编码器-解码器结构	32
3.2 模型的设计与改进	33
3.2.1 模型的改进动机	33
3.2.2 Transformer 注意力模块 (TR) 设计	34
3.2.3 混合损失函数设计	37
3.2.4 改进模型整体结构	38
3.3 实验结果与分析	39
3.3.1 实验环境与参数配置	39
3.3.2 消融实验	40
3.3.3 对比实验	41
3.4 本章小结	42
第四章 基于空间感知增强的模型优化与综合实验	44
4.1 空间感知增强模块 (SAE) 的设计	44
4.1.1 改进动机	44
4.1.2 SAE 模块原理与结构	45
4.1.3 SAE 模块集成方式	47
4.2 改进模型的整体结构	48
4.2.1 完整模型架构	48
4.2.2 各模块协同机制	49

4.3 综合实验与分析	50
4.3.1 消融实验	50
4.3.2 与主流方法对比实验	51
4.3.3 可视化分析	53
4.3.4 效率分析	54
4.4 本章小结	55
第五章 总结与展望	56
5.1 研究成果总结	56
5.2 工作展望	57
参考文献.....	59
致 谢.....	62
攻读硕士学位期间的研究成果	63

符号和缩略语说明

OCT	光学相干断层扫描 (Optical Coherence Tomography)
ASPP	空洞空间金字塔池化 (Atrous Spatial Pyramid Pooling)
TR	变换器路由 (Transformer Routing)
SAE	空间注意力增强 (Spatial Attention Enhancement)
mIoU	平均交并比 (Mean Intersection over Union)
IoU	交并比 (Intersection over Union)
FCN	全卷积网络 (Fully Convolutional Network)
CNN	卷积神经网络 (Convolutional Neural Network)
ResNet	残差网络 (Residual Network)

第一章 绪论

1.1 研究背景及意义

随着现代工业制造向精密化、自动化方向发展，激光焊接技术凭借能量密度高、焊接速度快、热影响区小等特点，在汽车制造与动力电池等高端装备制造领域得到了广泛应用^[1]。在叠焊等典型工艺中，熔深直接影响接头的有效连接与承载能力，是衡量焊接质量的关键指标之一^[1]。然而，激光焊接过程涉及光、机、电、热等多物理场耦合，具有明显的非线性与不稳定性，易产生孔隙、未熔合等缺陷；若仍依赖金相切片等焊后离线检测，往往存在破坏性强、效率低、反馈滞后等问题，难以满足规模化生产的实时质检与闭环控制需求^[1]。因此，面向焊接过程的实时在线监测与熔深稳定获取具有重要的工程价值。

光学相干层析成像（Optical Coherence Tomography, OCT）是一种基于低相干干涉原理的层析成像技术，具有非接触、高轴向分辨率等优势^[2]。在激光焊接场景中，OCT 可通过测量光束获取匙孔（Keyhole）底部反射信息，从而为熔深在线测量提供直接的几何依据，被认为是具有应用潜力的过程监测手段之一^[1]。相较于仅能反映表面辐射或二维表观信息的视觉/光电监测方法，OCT 在表征深度结构方面更具优势^[1]。

尽管 OCT 在焊接监测中具有优势，但在实际应用中仍面临信号不稳定与噪声干扰等挑战：焊接过程中的熔池波动、金属蒸汽与飞溅会降低信号稳定性^[1]；同时，OCT 成像基于低相干干涉，散斑噪声（Speckle Noise）常以随机颗粒纹理形式出现并降低图像信噪比^[2]。如图 1-1 所示，在此条件下，锁孔边缘往往呈现对比度低、边界模糊与形态快速变化等特点，传统阈值分割、边缘检测或简单滤波（如中值滤波、百分位滤波）难以在鲁棒性与边界保持之间取得平衡，进而影响后续熔深估计的稳定性与精度^[1,2]。

针对上述痛点，本文研究面向焊接 OCT 图像的语义分割方法。与传统图像处理流程相比，深度学习分割模型可通过端到端学习获取更具判别性的语义特征与上下文信息，在噪声与弱边界条件下具有更强的鲁棒性^[3-5]。本文以 DeepLabV3+ 为基线^[5]，面向散斑噪声干扰强、锁孔边界模糊与细长结构易断裂等问题，在编码器端增强全局上下文建模，在解码器端强化局部细节表达，从而实现对锁孔区域的高精度分割，为熔深稳定测量提供算法支撑^[1]。




图 1-1 激光焊接 OCT 锁孔图像示例

1.2 国内外研究现状

本节围绕本文研究对象（激光焊接场景下的 OCT 锁孔/熔深信息获取）与研究任务（OCT 图像中锁孔目标的语义分割）展开综述。首先总结激光焊接过程监测与熔深测量的主流技术路线及其局限性；其次梳理 OCT 成像中的散斑噪声特性与典型处理方法，指出“先去噪再分割/测量”的流程在边界保持与实时性方面的不足；最后回顾图像语义分割算法的发展脉络与在 OCT/工业视觉中的应用进展，从而引出本文面向噪声干扰与弱边界条件的端到端抗噪分割思路。

1.2.1 激光焊接过程监测技术现状

激光焊接过程监测手段大体可分为基于光辐射/光谱的光电监测、基于可见光/红外成像的视觉监测、基于声发射/等离子体信号的声学监测，以及融合多源传感的综合监测等^[6,7]。其中，高温计、光电二极管等可对匙孔/熔池温度或光辐射强度进行实时采样，但缺乏空间分辨信息；红外热像仪能够直观呈现温度场分布，却存在分辨率有限、成本较高等不足；光学相机可获取高分辨率的熔池/匙孔二维形态，但仍需后续复杂的图像处理流程^[8,9]。上述方法在一定程度上能够反映焊接稳定性与缺陷趋势，但往往难以直接、稳定地获取锁孔内部几何信息；同时其信号与熔深之间的映射关系受工艺参数、材料状态与飞溅/蒸汽干扰影响显著，导致可迁移性与精度受限。

在此背景下，光学相干层析成像（OCT）凭借其高轴向分辨率（可达微米级）、非接触、可穿透烟尘与金属蒸汽并直接表征锁孔深度结构等优势，被认为是实现熔深在线测量与闭环控制的有前景手段^[1,10,11]。表 1-1 总结了激光焊接过程中常用光学检测技术的特点与局限性。然而，OCT 图像存在噪声强、对比度低、边界模糊等特点，使得锁孔区域的稳定提取仍是亟待解决的关键问题。

表 1-1 激光焊接过程光学检测技术对比

检测技术	检测对象	优点	局限性
高温计	匙孔/熔池温度	结构简单、响应快	无空间信息
红外热像仪	温度场分布	直观呈现温度	分辨率低、成本高
光电传感器	辐射/反射光	采样率高	需复杂参数调整
光学相机	熔池/匙孔形态	分辨率高	需后续图像处理
OCT	匙孔深度结构	微米分辨率、非接触	信号处理复杂

1.2.2 OCT 图像噪声特性及处理方法研究现状

OCT 成像基于低相干干涉，散斑噪声来源于相干叠加与多次散射等因素，常表现为随机颗粒纹理并伴随局部对比度下降，其统计特性与组织/材料表面微结构密切相关^[2]。为提升后续结构识别与测量的稳定性，国内外研究提出了多种 OCT 噪声抑制与质量增强方法，主要包括：**（1）传统滤波与变换域方法**，如中值/均值滤波、各向异性扩散、BM3D 及小波/非局部均值等；**（2）硬件或多帧复合策略**，通过多角度/多次采样实现散斑平均以提升信噪比；**（3）深度学习去噪方法**，利用卷积网络或自编码结构学习噪声分布并恢复结构细节。上述方法为改善可视化质量提供了有效途径，但在锁孔这类**弱边界、细长深孔、形态快速变化**的目标上，单纯追求去噪往往可能带来边界平滑、细节损失与几何偏移；同时，“先去噪再分割/测量”的两阶段流程增加了系统复杂度与推理延迟，不利于在线闭环控制。因此，本文不将“去噪”作为独立处理步骤，而是将散斑与干扰视为成像条件的一部分，探索**端到端的抗噪语义分割**：通过在分割网络内部显式增强全局上下文建模与局部边界细节表达，使模型在噪声干扰下仍能稳定学习锁孔的语义结构与轮廓，从流程上减少对额外预处理的依赖。

1.2.3 图像语义分割算法研究现状

图像语义分割旨在为输入图像的每个像素赋予语义类别标签，是计算机视觉领域的核心任务之一^[12]。从技术演进角度，深度学习语义分割方法大体经历了以下发展阶段：

(1) 基于全卷积网络的端到端分割。Long 等^[3]提出全卷积网络（FCN），首次将图像分类网络改造为逐像素预测结构，奠定了深度语义分割的基础。在此基础上，SegNet^[13]采用对称的编码器-解码器架构，通过最大池化索引进行上采样，在保持空间信息的同时降低了参数量；U-Net^[4]引入跳跃连接融合多尺度特征，在医学影像分割中取得优异效果。

(2) 多尺度上下文建模方法。为捕获不同感受野范围的上下文信息，Yu 等^[14]提出空洞卷积（Dilated/Atrous Convolution），在不增加参数的情况下扩大感受野；DeepLab 系列^[5,15-17]通过空洞空间金字塔池化（ASPP）融合多尺度特征，DeepLabV3+ 进一步结合编码器-解码器结构，在精度与效率间取得平衡；PSP-Net^[18]则采用金字塔池化模块聚合全局上下文。高分辨率网络 HRNet^[19]在整个网络中保持高分辨率表示，有效提升了边界与细节刻画能力。

(3) 注意力机制与 Transformer 方法。为建模长程依赖与突出关键区域特征，注意力机制被广泛引入分割任务。SE 模块^[20]通过通道注意力重校准特征响应；CBAM^[21]结合通道与空间注意力实现双维度特征增强；Non-local^[22]通过自注意力机制捕获像素间的全局依赖关系；Coordinate Attention^[23]在轻量化约束下嵌入位置信息以增强空间感知能力。近年来，Vision Transformer^[24]被引入视觉任务，TransUNet^[25]等混合架构将 Transformer 与 CNN 结合，在医学影像分割中展现出优异的全局建模能力。

(4) 实时与轻量化分割网络。面向工业在线检测等实时性要求较高的场景，BiSeNet V2^[26]、ICNet^[27]等轻量化网络通过双分支设计或特征金字塔策略在速度与精度间寻求平衡^[28]。

在 OCT 相关任务中，研究者多采用 U-Net/DeepLab 类结构进行视网膜层结构或病灶区域分割，也有工作引入注意力机制以提升边界与小目标刻画能力。然而，激光焊接 OCT 锁孔分割与常规医学 OCT 分割在数据分布与目标形态上存在显著差异：其一，散斑噪声与工况扰动更强，导致特征不稳定；其二，锁孔区域往往呈现**细长结构**且边界灰度对比度低，易出现断裂与粘连；其三，在线应

用对推理速度与稳定性提出更高要求。上述特点使得现有通用分割网络直接迁移时可能面临全局结构判断不足与局部边界细节丢失等问题。基于此，本文以 DeepLabV3+ 为基线，分别从**全局上下文**与**局部细节**两方面进行针对性增强，为后续章节提出的 TR 模块与 SAE 模块提供动机与理论依据。

1.3 本文主要研究内容

针对激光焊接 OCT 图像中存在的散斑噪声干扰严重、锁孔目标细小且边界模糊等问题，本文以实现高精度、鲁棒的锁孔语义分割为目标，围绕“数据集构建—网络结构改进—损失函数优化—实验验证”四个方面开展研究工作。本文的主要研究内容如下：




图 1-2 本文方法总体框架图

1. 针对现有开源数据集缺乏工业焊接 OCT 场景数据的问题，构建了面向激光焊接锁孔检测的 OCT 图像语义分割数据集。本文在真实 304 不锈钢激光焊接实验平台上采集原始 OCT 成像数据，涵盖多种功率、速度参数组合下的锁孔形态变化；制定了统一的标注规范，完成了像素级的精细标注，为模型训练与评估提供了坚实的数据基础。
2. 针对 DeepLabV3+ 在 OCT 图像上存在的全局上下文建模不足与局部边界细

节丢失问题，提出了基于双模块增强的改进网络架构（如图 1-2 所示）。本文在编码器-解码器结构的基础上进行双重改进：

- (1) 针对全局上下文建模能力不足的问题，在编码器末端引入 TR (Transformer Routing) 模块。该模块借鉴 BiFormer^[29] 的双层路由稀疏注意力机制，在编码器高层特征上实现内容感知的全局上下文增强，使网络能够聚焦于与锁孔语义相关的关键区域，提升长程依赖建模能力并降低背景噪声干扰。
 - (2) 针对局部边界细节易丢失的问题，在解码器融合阶段引入 SAE (Spatial Attention Enhancement) 模块。该模块在高低层特征融合后引入空间与通道注意力协同增强，参考 Coordinate Attention^[23] 与 SE^[20] 的设计思想，突出边缘与细小结构的特征响应，提升弱边界条件下的分割精细度。
3. 针对前景背景类别不平衡的问题，设计了适应性混合损失函数。由于 OCT 图像中背景区域广大而锁孔目标区域较小，采用交叉熵损失 (Cross Entropy Loss) 与 Dice 损失 (Dice Loss) 相结合的混合损失函数，平衡了模型对不同类别的关注度，有效缓解了类别不平衡对模型训练的负面影响，进一步提升了分割精度。
4. 进行了系统的实验验证与对比分析。在自建数据集上对所提方法进行了全面的实验评估，与 U-Net^[4]、DeepLabV3+^[5]、TransUNet^[25] 等主流分割网络进行对比。实验结果表明，改进后的模型在 mIoU、Dice 系数等关键指标上均取得显著提升。通过消融实验逐一验证了 TR 模块与 SAE 模块对模型性能的贡献，并对分割结果进行了可视化分析，证明了本文方法在散斑噪声与弱边界条件下的鲁棒性与优越性。

1.4 论文组织结构

本文共分为五章，各章节的具体安排如下：

第一章：绪论。阐述了课题的研究背景及意义，分析了激光焊接过程监测面临的挑战及 OCT 技术的应用潜力。综述了国内外在激光焊接监测、OCT 图像去

噪及语义分割算法方面的研究现状，指出了现有研究的不足。最后明确了本文的研究目标、主要研究内容及章节安排。

第二章：相关理论与技术基础。（待补充：介绍 OCT 成像原理、深度学习基础、卷积神经网络、语义分割常用评价指标等。）

第三章：基于改进 DeepLabV3+ 的 OCT 图像语义分割方法。详细阐述本文提出的改进网络架构。重点介绍 DeepLabV3+ 基线模型、TR 全局注意力模块、SAE 空间细节增强模块的设计原理与实现细节，以及混合损失函数的定义。

第四章：实验结果与分析。介绍实验数据集的构建、实验环境与参数设置。展示本文方法与主流对比方法的定量评估结果（如 mIoU、PA 等）及定性可视化效果。通过消融实验深入分析各改进模块对模型性能的贡献，并对实验结果进行讨论。

第五章：总结与展望。总结全文的研究工作与创新点，客观分析现有方法的局限性，并对未来的研究方向（如轻量化部署、多任务协同等）进行展望。

第二章 相关理论与技术基础

本章介绍本文研究所需的相关理论与技术基础，主要包括 OCT 成像原理、深度学习基础、语义分割理论基础以及评价指标等内容，为后续章节的方法设计与实验分析提供理论支撑。

2.1 OCT 成像原理

光学相干层析成像（Optical Coherence Tomography, OCT）是一种基于低相干干涉原理的高分辨率、非侵入性层析成像技术^[30]。该技术最早由 Huang 等人于 1991 年提出^[30]，通过检测参考光束与样品后向散射光之间的干涉信息，实现对生物组织或材料结构的微米级断层成像。OCT 技术无需外源造影剂或样品切片处理，即可实现高分辨率实时成像，在生物医学和工业检测领域具有重要应用价值^[2]。

2.1.1 OCT 成像基本原理

OCT 成像系统基于低相干干涉原理，其核心结构为迈克尔逊干涉仪。系统主要由宽带光源、光纤耦合器、参考臂、样品臂、光电探测器等关键组件构成。宽带光源发出的光经光纤耦合器被分成两束：一束进入参考臂，射向可沿光轴移动的反射镜；另一束进入样品臂，在样品不同深度产生背散射光。这些背散射光和经参考镜反射的参考光在光纤耦合器处发生干涉，被探测器接收。通过分析干涉信号的强度和时延，即可重建样品的深度结构信息^[1]。

光波发生低相干干涉需要满足以下条件：光波相位差恒定、振动频率相同和振动方向一致。在 OCT 系统中，参考臂与样品臂的光程差决定了干涉信号的强度。当光程差小于光源的相干长度时，才能发生有效干涉；当光程差为零时，系统可获得最大干涉强度。OCT 系统的轴向分辨能力主要取决于光源的相干特性，其理论极限值约为相干长度的一半，该特性使得 OCT 技术能够实现微米级的纵向分辨^[2]。

从数学角度分析，设宽带光源对应的电场 E_i 可表示为：

$$E_i = S(k)e^{i(kz - \omega t)} \quad (2-1)$$

其中, $S(k)$ 为电场的振幅, k 为波数, z 为光程, ω 为角频率。电场的振幅 $S(k)$ 可进一步表示为高斯型函数:

$$S(k) = \frac{1}{\Delta k \sqrt{\pi}} e^{-\frac{(k-k_0)^2}{\Delta k^2}} \quad (2-2)$$

其中, k_0 为中心波长 λ_0 的波数, Δk 为频谱带宽。

设参考臂反射光场为 E_R , 样品臂反射光场为 E_S , 则单一波长的光谱干涉信号 $I_D(k)$ 可表示为:

$$I_D(k) \approx |E_R|^2 + |E_S|^2 + 2r_R r_S S(k) \cos[2k(z_R - z_S)] \quad (2-3)$$

其中, r_R 和 r_S 分别为参考臂和样品臂的光束反射率, z_R 和 z_S 分别为参考臂和样品臂的光程长度。干涉信号由直流项和交叉干涉项组成, 交叉干涉项包含了样品的深度信息。对 $I_D(k)$ 进行快速傅里叶变换即可得到相应的深度信息, 从而重建样品的层析结构^[1]。

2.1.2 OCT 技术分类

根据不同的成像原理和数据采集方式, OCT 技术主要分为时域 OCT (Time Domain OCT, TD-OCT) 和频域 OCT (Fourier Domain OCT, FD-OCT) 两大类^[2]。

时域 OCT 是最早提出的 OCT 技术, 通过机械扫描参考臂的延时调制, 逐点扫描获得不同深度处的反射信号。时域 OCT 的成像过程包括两个步骤: 一是通过参考臂的移动实现深度扫描, 从干涉信号中提取样品的深度结构; 二是结合横向扫描, 构建二维或三维层析图像。时域 OCT 通过调节参考臂的扫描范围来灵活设定测量深度, 但由于其深度信息依赖机械扫描, 导致扫描时间较长、成像速度较慢, 并容易受到扫描噪声干扰^[2]。图 2-1 展示了时域 OCT 系统的基本结构。

频域 OCT 通过获取完整的光谱干涉信号, 并利用傅里叶变换重建深度信息, 避免了机械扫描的需求, 显著提高了成像速度。频域 OCT 根据光源和探测方式的差异, 又可分为谱域 OCT (Spectral Domain OCT, SD-OCT) 和扫频 OCT (Swept Source OCT, SS-OCT)。谱域 OCT 使用宽带光源和光谱仪, 在空间域中分离干涉光并获取干涉光谱; 扫频 OCT 采用宽带扫频光源和高速光电探测器, 通过扫频光源在时间域内依次发射不同波长的光, 并利用光电探测器在时间域中分离干涉光谱。相比谱域 OCT, 扫频 OCT 在信噪比、探测灵敏度和系统分辨率方面具有




图 2-1 时域 OCT 系统原理示意图

更高的潜力，尤其适用于高分辨率和大视场成像^[1]。图 2-2 展示了频域 OCT（谱域 OCT）系统的基本结构。




图 2-2 频域 OCT（谱域 OCT）系统原理示意图

2.1.3 OCT 在激光焊接中的应用

在激光焊接场景中，OCT 技术通过测量光束获取匙孔（Keyhole）底部反射信息，从而为熔深在线测量提供直接的几何依据^[1]。相较于仅能反映表面辐射或二维表面信息的视觉/光电监测方法，OCT 在表征深度结构方面更具优势。激光

焊接区域的反射散射光与参考臂的镜面反射光之间相位差并不恒定，因此激光加工区域的散射光与参考臂的反射光不会发生干涉，谱域 OCT 成像系统几乎不受激光加工光束的反射散射光影响，这使得 OCT 技术在激光焊接过程监测中具有独特的应用优势^[1]。

2.1.4 OCT 图像特点

尽管 OCT 具备高分辨率、非侵入性等优势，但在实际应用中仍面临信号不稳定与噪声干扰等挑战。OCT 图像的主要特点包括：

(1) **散斑噪声**：OCT 成像基于低相干干涉原理，散斑噪声来源于相干叠加与多次散射等因素，常表现为随机颗粒纹理并伴随局部对比度下降^[2]。焊接过程中的熔池波动、金属蒸汽与飞溅会进一步降低信号稳定性，加剧散斑噪声的影响^[1]。

(2) **对比度低**：由于散斑噪声的存在，OCT 图像的局部对比度往往较低，特别是在弱反射区域，目标与背景的灰度差异不明显，增加了后续处理的难度。

(3) **边界模糊**：在激光焊接 OCT 图像中，锁孔边缘往往呈现对比度低、边界模糊与形态快速变化等特点，传统阈值分割、边缘检测或简单滤波难以在鲁棒性与边界保持之间取得平衡^[1]。

上述特点使得 OCT 图像中的目标区域（如锁孔）提取成为一项具有挑战性的任务，需要采用更加鲁棒的图像处理方法，这也是本文研究面向 OCT 图像的语义分割方法的重要动机。

2.2 深度学习基础

深度学习作为机器学习的重要分支，通过构建具有多个隐藏层的神经网络，能够自动学习数据的层次化特征表示。在图像处理领域，卷积神经网络（Convolutional Neural Network, CNN）凭借其强大的特征提取能力，已成为语义分割等视觉任务的主流方法。本节介绍深度学习的基础理论，包括卷积神经网络、编码器-解码器架构以及注意力机制等核心概念。

2.2.1 卷积神经网络基础

卷积神经网络是一种专门用于处理具有网格结构数据（如图像）的深度学习模型。CNN 的核心思想是通过局部连接、权值共享和池化操作，有效减少参数

量并提取平移不变的特征。

(1) 卷积层：卷积层是 CNN 的基本组成单元，通过卷积核（滤波器）在输入特征图上滑动，计算局部区域的加权和。设输入特征图为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ ，卷积核为 $\mathbf{K} \in \mathbb{R}^{k \times k \times C}$ ，则卷积操作可表示为：

$$Y_{i,j} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} \sum_{c=0}^{C-1} X_{i+m,j+n,c} \cdot K_{m,n,c} + b \quad (2-4)$$

其中， $Y_{i,j}$ 为输出特征图在位置 (i, j) 的值， b 为偏置项。卷积操作具有局部连接和权值共享的特性，能够有效提取图像的局部特征（如边缘、纹理等），同时大幅减少参数量。如图 2-3 所示，卷积核在输入特征图上滑动，计算每个局部区域的加权和，生成输出特征图。




图 2-3 卷积运算示意图

(2) 池化层：池化层通过下采样操作降低特征图的空间分辨率，减少计算量并增强特征的平移不变性。常用的池化操作包括最大池化（Max Pooling）和平均池化（Average Pooling），如图 2-4 所示。最大池化选择局部区域内的最大值，能够保留显著特征；平均池化计算局部区域的平均值，能够平滑特征响应。

(3) 激活函数：激活函数为网络引入非线性，使网络能够学习复杂的非线性映射关系。常用的激活函数包括：

- **ReLU (Rectified Linear Unit):** $f(x) = \max(0, x)$ ，具有计算简单、梯度稳定等优点，是目前最常用的激活函数。
- **Sigmoid:** $f(x) = \frac{1}{1+e^{-x}}$ ，输出范围在 $(0, 1)$ 之间，常用于二分类任务的输出。




图 2-4 池化运算示意图

层。

- **Softmax:** $f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$, 将输入向量归一化为概率分布, 常用于多分类任务的输出层。

(4) **批归一化:** 批归一化 (Batch Normalization) 通过在训练过程中对每个批次的数据进行归一化, 能够加速网络训练、提高模型稳定性并允许使用更大的学习率^[31]。批归一化的操作可表示为:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta \quad (2-5)$$

其中, μ_B 和 σ_B^2 分别为批次数据的均值和方差, γ 和 β 为可学习的缩放和偏移参数, ϵ 为小常数以防止除零。

(5) **残差连接:** 残差连接 (Residual Connection) 通过将输入直接传递到输出, 解决了深层网络的梯度消失问题, 使得训练更深的网络成为可能^[32]。残差块的结构可表示为:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{x} \quad (2-6)$$

其中, $\mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\})$ 为残差映射, $\mathbf{x}$ 为恒等映射。残差连接使得网络能够学习残差而非完整的映射, 从而简化了优化过程。ResNet 通过引入残差连接, 成功训练了包含数百层的深层网络, 在图像分类、目标检测等任务中取得了显著成果^[32]。

2.2.2 编码器-解码器架构

编码器-解码器（Encoder-Decoder）架构是语义分割任务中常用的网络结构，通过编码器提取多尺度特征，解码器恢复空间分辨率并输出像素级预测结果^[4]。

(1) 编码器: 编码器通常采用预训练的 CNN 骨干网络（如 ResNet、VGG 等），通过逐层卷积和下采样操作，将输入图像转换为高维特征表示。编码过程逐步降低特征图的空间分辨率，同时增加通道数，提取从低级到高级的语义特征。例如，ResNet 编码器通常包含多个阶段（Stage），每个阶段通过卷积和下采样操作，将特征图尺寸减半、通道数加倍，最终得到高维的语义特征表示。

(2) 解码器: 解码器通过上采样和特征融合操作，逐步恢复特征图的空间分辨率，并输出与输入图像尺寸相同的预测结果。上采样操作通常采用双线性插值或转置卷积实现。解码器还通过跳跃连接（Skip Connection）融合编码器不同阶段的特征，结合低层细节信息和高层语义信息，提升分割精度。

(3) 跳跃连接: 跳跃连接将编码器的中间特征直接传递到解码器的对应层，使得解码器能够利用编码器提取的多尺度特征。U-Net 架构通过 U 形的跳跃连接，将编码器的特征图与解码器对应层的特征图进行拼接，有效融合了细节信息和语义信息，在医学图像分割等任务中取得了优异性能^[4]。

2.2.3 注意力机制基础

注意力机制通过动态分配不同权重，使网络能够关注输入数据中的重要部分，从而提升模型的表达能力。在计算机视觉任务中，注意力机制主要包括自注意力、空间注意力和通道注意力等类型。

(1) 自注意力机制: 自注意力（Self-Attention）机制通过计算特征图中不同位置之间的相关性，建立长距离依赖关系^[33]。自注意力的计算过程可表示为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (2-7)$$

其中， $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ 分别为查询（Query）、键（Key）和值（Value）矩阵， d_k 为键向量的维度。自注意力机制能够捕获特征图中任意两个位置之间的依赖关系，不受空间距离限制，在长距离依赖建模方面具有优势。

(2) Transformer 架构: Transformer 架构完全基于自注意力机制，摒弃了传统的卷积和循环结构，通过多头自注意力和前馈网络构建深层网络^[33]。Vision

Transformer (ViT) 将 Transformer 架构应用于图像分类任务，将图像分割为固定大小的图像块 (Patch)，并将每个图像块视为一个序列元素，通过自注意力机制建模图像块之间的关系^[24]。Transformer 架构在图像分割任务中也得到了广泛应用，通过增强长距离依赖建模能力，提升了分割性能。

(3) 空间注意力与通道注意力：空间注意力关注特征图的空间位置信息，通过生成空间权重图，突出重要的空间区域；通道注意力关注特征图的通道维度，通过生成通道权重向量，突出重要的特征通道。空间注意力和通道注意力可以单独使用，也可以组合使用，通过空间和通道维度的双重增强，提升特征的判别能力。本文后续章节提出的 SAE 模块即结合了空间注意力和通道注意力，用于增强局部细节和边界信息。

2.3 语义分割理论基础

语义分割是计算机视觉中的一项重要任务，旨在对图像中的每个像素进行分类，为每个像素分配一个语义类别标签。与图像分类和目标检测不同，语义分割需要在像素级别进行预测，要求模型同时具备强大的特征提取能力和精确的空间定位能力。本节介绍语义分割的发展历程和关键技术，包括全卷积网络、U-Net 架构以及 DeepLab 系列方法。

2.3.1 全卷积网络

全卷积网络 (Fully Convolutional Networks, FCN) 是首个将深度卷积神经网络成功应用于语义分割任务的方法^[3]。FCN 的核心思想是将传统 CNN 中的全连接层替换为卷积层，使得网络能够接受任意尺寸的输入图像，并输出与输入尺寸相同的分割结果。

FCN 通过将预训练的分类网络 (如 VGG、ResNet) 转换为全卷积结构，利用卷积层的平移不变性，实现了端到端的像素级预测。FCN 还引入了跳跃连接机制，通过融合不同尺度的特征图，结合浅层的细节信息和深层的语义信息，提升了分割精度。FCN 的网络结构如图 2-5 所示，其提出标志着深度学习在语义分割领域的成功应用，为后续研究奠定了基础^[3]。

【待插入图片】
FCN 网络结构图
(编码器-解码器结构与跳跃连接)

图 2-5 FCN 网络结构图

2.3.2 U-Net 架构

U-Net 是一种经典的编码器-解码器架构,最初设计用于医学图像分割任务^[4]。U-Net 采用对称的 U 形结构,编码器通过卷积和下采样逐步提取特征,解码器通过上采样和卷积逐步恢复分辨率。

U-Net 的关键创新在于其密集的跳跃连接设计:编码器每一层的特征图都与解码器对应层的特征图进行拼接,使得解码器能够充分利用编码器提取的多尺度特征。这种设计使得 U-Net 在保持高分辨率细节的同时,能够利用深层的语义信息,在医学图像分割等需要精确边界定位的任务中表现出色。U-Net 的网络结构如图 2-6 所示,其成功也启发了后续许多编码器-解码器架构的设计^[4]。

2.3.3 DeepLab 系列方法

DeepLab 系列方法是语义分割领域的重要里程碑,通过引入空洞卷积和空间金字塔池化等技术,显著提升了分割性能。DeepLab 系列的发展历程体现了语义分割技术的演进轨迹。

(1) **DeepLabV1:** DeepLabV1 首次将空洞卷积 (Atrous Convolution) 引入语义分割任务^[15]。空洞卷积通过在卷积核中插入零值,在不增加参数量的情况下扩大感受野,使得网络能够在保持特征图分辨率的同时捕获更大范围的上下文信




图 2-6 U-Net 网络结构图

息。空洞卷积的数学表达可写为：

$$y[i] = \sum_k x[i + r \cdot k] \cdot w[k] \quad (2-8)$$

其中， r 为空洞率（dilation rate），控制感受野的大小。当 $r = 1$ 时，空洞卷积退化为标准卷积；当 $r > 1$ 时，空洞卷积能够在不增加参数量的情况下扩大感受野。

(2) DeepLabV2: DeepLabV2 在 DeepLabV1 的基础上引入了空间金字塔池化（Atrous Spatial Pyramid Pooling, ASPP）模块^[16]。ASPP 模块通过并行使用多个不同空洞率的空洞卷积，在不同尺度上捕获上下文信息，然后将多尺度特征进行融合。ASPP 模块的设计使得网络能够同时关注局部细节和全局上下文，提升了分割性能。

(3) DeepLabV3: DeepLabV3 对 ASPP 模块进行了改进，引入了全局平均池化分支，并优化了空洞率的选择策略^[17]。改进后的 ASPP 模块包含多个并行分支：不同空洞率的空洞卷积分支用于捕获多尺度上下文信息，全局平均池化分支用于捕获全局上下文信息。这些分支的特征经过拼接和融合，形成丰富的多尺度特征表示。

(4) DeepLabV3+: DeepLabV3+ 在 DeepLabV3 的基础上引入了编码器-解码器结构^[5]。DeepLabV3+ 采用 DeepLabV3 的输出作为编码器特征，通过解码器逐步上采样并融合编码器的中间特征，最终输出高分辨率的分割结果。DeepLabV3+ 的解码器设计简洁高效，通过融合低层细节信息和高层语义信息，在保持分割精

度的同时提升了边界定位的准确性。DeepLabV3+ 的网络结构如图 2-7 所示，其是本文方法的基础框架，编码器-解码器结构和 ASPP 模块为本文的改进提供了良好的起点。



图 2-7 DeepLabV3+ 网络结构图

2.3.4 多尺度特征融合策略

多尺度特征融合是语义分割中的关键技术，旨在结合不同尺度的特征信息，提升模型对不同大小目标的处理能力。除了 ASPP 模块外，特征金字塔网络（Feature Pyramid Network, FPN）也是一种重要的多尺度特征融合方法^[34]。

FPN 通过构建特征金字塔，在不同尺度上提取特征，并通过自上而下的路径和横向连接融合多尺度特征。FPN 的设计使得网络能够在不同尺度上检测目标，提升了模型对多尺度目标的处理能力。虽然 FPN 最初设计用于目标检测任务，但其多尺度特征融合的思想在语义分割任务中也得到了广泛应用。

近年来，Transformer 架构也被引入语义分割任务，通过自注意力机制增强长距离依赖建模能力。TransUNet 将 Transformer 作为编码器，结合 U-Net 的解码器结构，在医学图像分割任务中取得了优异性能^[25]。Transformer 架构的引入为语义分割提供了新的思路，但其计算复杂度较高，在实际应用中需要权衡性能与效率。

为了更清晰地对比上述经典语义分割方法的特点，表 2-1 总结了各方法的核心创新点与适用场景。

表 2-1 经典语义分割网络对比

方法	核心创新	优势	局限性
FCN	全卷积替代全连接	端到端像素预测	分辨率损失大
U-Net	对称编码器-解码器	精确边界恢复	感受野有限
DeepLabV1	空洞卷积	保持分辨率扩大感受野	多尺度建模不足
DeepLabV2	ASPP 多尺度池化	多尺度上下文捕获	边界细节丢失
DeepLabV3	改进 ASPP + 全局池化	全局与局部结合	解码器简单
DeepLabV3+	编码器-解码器结构	细节与语义融合	计算量较大
TransUNet	Transformer 编码器	长距离依赖建模	计算复杂度高

2.4 焊接 OCT 图像数据集构建

针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题，本研究构建了面向焊接熔深分割的 OCT 图像数据集。本节详细介绍数据集的构建过程，包括图像采集、预处理、标注、数据增强以及数据集划分等步骤。

2.4.1 OCT 图像采集

本研究的实验数据来源于激光焊接 OCT 在线检测系统。该系统基于谱域 OCT 技术，能够实时获取焊接过程中的熔深信息。在焊接实验中，选用 304 不锈钢作为焊接材料，通过调整焊接功率和焊接速度等工艺参数，采集了多组不同工况下的焊接 OCT 图像数据。

原始 OCT 图像的尺寸不固定，受采集系统参数和扫描范围的影响存在差异。为满足深度学习模型的输入要求，后续预处理过程将统一调整图像尺寸。本研究共采集了约 200 张原始 OCT 图像，涵盖多种焊接工况下的熔深变化情况。

2.4.2 图像预处理

原始 OCT 图像存在噪声干扰、对比度不足等问题，需要进行预处理以提升图像质量。本研究采用的预处理流程如图 2-8 所示，主要包括以下步骤：

(1) **图像裁剪**：原始 OCT 图像包含较大的无效区域，为减少计算量并突出感兴趣区域（Region of Interest, ROI），首先对图像进行裁剪，去除边缘的无效信息，保留包含熔深信号的核心区域。




图 2-8 图像预处理流程图

(2) **噪声抑制**: OCT 图像中存在散斑噪声等干扰, 本研究采用中值滤波方法进行去噪处理。中值滤波能够在保留边缘信息的同时有效抑制椒盐噪声和散斑噪声, 滤波窗口大小设置为 3×3 。

(3) **对比度增强**: 为提高熔深区域与背景的区分度, 采用直方图均衡化方法对图像进行对比度增强。增强后的图像熔深线段边界更加清晰, 有利于后续的标注和分割。

(4) **尺寸调整**: 将预处理后的图像统一调整为 512×512 像素, 采用双线性插值方法进行缩放, 以满足深度学习模型的输入尺寸要求。

(5) **归一化处理**: 将图像像素值从 $[0, 255]$ 归一化到 $[0, 1]$ 范围, 以加速模型收敛并提高训练稳定性。

预处理前后的图像效果对比如图 2-9 所示, 可以看出预处理后图像的噪声明显减少, 熔深区域的对比度显著提升。

2.4.3 基于 LabelMe 的熔深线段标注

本研究采用开源图像标注工具 LabelMe 进行语义分割标签的制作。LabelMe 是由麻省理工学院开发的多边形标注工具, 支持多种标注格式输出, 广泛应用于计算机视觉任务的数据准备工作。

(1) **标注工具介绍**: LabelMe 提供了交互式的多边形绘制功能, 用户可以通过鼠标点击在图像上绘制任意形状的多边形, 将目标区域精确标注出来。标注结果以 JSON 格式存储, 包含图像路径、标注类别、多边形顶点坐标等信息。LabelMe




图 2-9 预处理效果对比

的标注界面如图 2-10 所示。



图 2-10 LabelMe 标注界面

(2) **标注类别定义**：根据焊接 OCT 图像的特点，本研究定义了以下标注类别：

- **熔深线段 (Weld_Depth)**：表示焊接熔池底部的深度轮廓线，是本研究的主要分割目标，在标注时沿熔深轮廓绘制多边形区域。
- **背景 (Background)**：除熔深线段外的所有区域，包括空气区域、材料表面以及噪声区域。

(3) 标注规范：为保证标注的一致性和准确性，制定了以下标注规范：

1. 熔深线段采用多边形方式标注，沿熔池底部轮廓紧密绘制；
2. 对于模糊或不确定的区域，参考相邻帧图像进行判断；
3. 标注边界应尽量精确贴合熔深轮廓，避免标注过大或过小；
4. 所有图像由同一标注人员完成初始标注，以减少主观差异。

(4) 标注质量控制：为确保标注质量，采用双人交叉验证的方式进行质量控制。首先由标注人员完成初始标注，随后由第二人进行检查和修正。对于存在争议的样本，由两人协商确定最终标注结果。

标注完成后，使用 LabelMe 提供的转换脚本将 JSON 格式的标注文件转换为 PNG 格式的掩码图像，供深度学习模型训练使用。标注样例如图 2-11 所示。



图 2-11 标注样例展示

2.4.4 数据增强策略

由于原始标注图像数量有限（约 200 张），为扩充训练数据并提升模型的泛化能力，本研究采用了多种数据增强策略。数据增强操作在线进行，即在每个训练批次中随机应用以下变换，最终将数据集扩充至 1000 余张图像。

数据增强策略的具体配置如表 2-2 所示。

表 2-2 数据增强策略配置

增强类型	增强方法	参数设置
几何变换	随机水平翻转	概率 0.5
	随机垂直翻转	概率 0.5
	随机旋转	角度范围 $[-15^{\circ}, +15^{\circ}]$
	随机缩放	缩放比例 $[0.8, 1.2]$
光学变换	亮度调整	调整范围 $[0.8, 1.2]$
	对比度调整	调整范围 $[0.8, 1.2]$
	高斯噪声	概率 0.3，标准差 0.02

(1) **几何变换**：包括随机水平翻转、随机垂直翻转、随机旋转和随机缩放等操作，用于增加数据的空间多样性，提升模型对不同方向和尺度目标的适应能力。

(2) **光学变换**：包括亮度调整、对比度调整和高斯噪声添加等操作，用于模拟不同光照条件和噪声水平下的图像，增强模型对图像质量变化的鲁棒性。

数据增强的效果示例如图 2-12 所示。




图 2-12 数据增强效果示例

2.4.5 数据集划分与统计

为科学评估模型性能，本研究将数据集按照 8:1:1 的比例划分为训练集、验证集和测试集。划分时遵循以下原则：

- 1. **时序连续性**：来自同一焊接序列的图像不跨集划分，避免信息泄露；

2. **分布一致性**：确保三个子集中不同工况下的样本比例基本一致；
3. **随机性**：在满足上述约束的前提下，采用随机采样方式进行划分。

数据集的详细统计信息如表 2-3 所示。

表 2-3 焊接 OCT 图像数据集统计信息

数据集	原始图像数	增强后图像数	占比	图像尺寸
训练集	160	800	80%	512×512
验证集	20	100	10%	512×512
测试集	20	100	10%	512×512
总计	200	1000	100%	—

训练集用于模型参数的学习与优化；验证集用于超参数调优和早停策略的判断；测试集仅在模型训练完成后进行最终性能评估，以确保评估结果的客观性。

由于熔深线段在图像中所占像素比例较小，数据集存在明显的类别不平衡问题。为缓解这一问题，本研究在损失函数设计中引入了 Dice 损失，以提升模型对小目标区域的分割精度，具体将在第三章进行详细介绍。

2.5 语义分割评价指标

为了客观评估语义分割模型的性能，需要采用合适的评价指标对预测结果进行定量分析。语义分割的评价指标通常基于混淆矩阵（Confusion Matrix）计算，通过比较预测结果与真实标签之间的差异，量化模型的分割精度。本节介绍常用的语义分割评价指标及其计算方法。

2.5.1 混淆矩阵

混淆矩阵是评估分类模型性能的基础工具，用于统计预测结果与真实标签之间的对应关系。对于语义分割任务，混淆矩阵 C 是一个 $N \times N$ 的矩阵，其中 N 为类别数。矩阵元素 C_{ij} 表示真实类别为 i 、预测类别为 j 的像素数量。

基于混淆矩阵，可以计算多种评价指标。对于二分类任务（如本文的锁孔分割任务），混淆矩阵包含四个元素：真正例（True Positive, TP）、假正例（False Positive, FP）、真负例（True Negative, TN）和假负例（False Negative, FN）。

2.5.2 像素准确率

像素准确率（Pixel Accuracy, PA）是最直观的评价指标，表示正确分类的像素占总像素的比例：

$$PA = \frac{\sum_{i=0}^{N-1} C_{ii}}{\sum_{i=0}^{N-1} \sum_{j=0}^{N-1} C_{ij}} \quad (2-9)$$

其中， C_{ii} 为混淆矩阵对角线元素，表示正确分类的像素数；分母为总像素数。PA 的取值范围为 $[0, 1]$ ，值越大表示分割精度越高。

PA 指标计算简单直观，但在类别不平衡的情况下（如背景像素远多于目标像素），PA 可能无法准确反映模型对少数类别的分割性能。例如，在锁孔分割任务中，背景区域通常占据图像的大部分，即使模型将所有像素预测为背景，PA 值也可能较高，但这并不能说明模型的分割性能良好。

2.5.3 平均像素准确率

平均像素准确率（Mean Pixel Accuracy, mPA）通过计算每个类别的像素准确率并取平均，能够更好地反映模型对不同类别的分割性能：

$$mPA = \frac{1}{N} \sum_{i=0}^{N-1} \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}} \quad (2-10)$$

其中， $\frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}}$ 表示类别 i 的像素准确率，即类别 i 中正确分类的像素数占该类别总像素数的比例。mPA 对每个类别赋予相同的权重，能够更好地评估模型在类别不平衡情况下的性能。

2.5.4 交并比

交并比（Intersection over Union, IoU）是语义分割任务中最常用的评价指标之一，表示预测结果与真实标签的交集与并集的比值：

$$IoU_i = \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij} + \sum_{j=0}^{N-1} C_{ji} - C_{ii}} \quad (2-11)$$

其中，分子 C_{ii} 为类别 i 的预测结果与真实标签的交集（正确预测的像素数），分母为两者的并集（预测为类别 i 或真实为类别 i 的像素总数）。IoU 的取值范围为 $[0, 1]$ ，值越大表示分割精度越高。

IoU 指标能够同时考虑预测结果的准确性和完整性，对分割边界的精度更加敏感，因此在语义分割任务中被广泛采用。对于二分类任务，IoU 的计算可简化为：

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (2-12)$$

2.5.5 平均交并比

平均交并比（Mean Intersection over Union, mIoU）通过计算所有类别 IoU 的平均值，综合评估模型的分割性能：

$$\text{mIoU} = \frac{1}{N} \sum_{i=0}^{N-1} \text{IoU}_i \quad (2-13)$$

mIoU 是语义分割任务中最常用的评价指标，能够综合反映模型对不同类别的分割性能。在类别不平衡的情况下，mIoU 比 PA 更能准确反映模型的真实性能。本文实验部分将 mIoU 作为主要评价指标，用于评估不同方法的分割性能。

2.5.6 Dice 系数

Dice 系数（Dice Coefficient）是医学图像分割中常用的评价指标，表示预测结果与真实标签的重叠程度：

$$\text{Dice}_i = \frac{2 \cdot C_{ii}}{2 \cdot C_{ii} + \sum_{j \neq i} C_{ij} + \sum_{j \neq i} C_{ji}} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}} \quad (2-14)$$

Dice 系数的取值范围为 $[0, 1]$ ，值越大表示重叠程度越高。对于二分类任务，Dice 系数与 IoU 之间存在以下关系：

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \quad (2-15)$$

Dice 系数对分割区域的完整性更加敏感，在医学图像分割等需要精确区域分割的任务中应用广泛。本文在损失函数设计中采用了 Dice 损失，用于处理类别不平衡问题。

2.5.7 评价指标的适用场景

不同的评价指标适用于不同的场景和需求：

(1) **PA**: 适用于类别分布相对均衡的场景, 计算简单直观, 但在类别不平衡情况下可能产生误导性结果。

(2) **mPA**: 通过平均各类别的准确率, 能够更好地评估类别不平衡情况下的性能, 但对每个类别赋予相同权重, 可能忽略类别的重要性差异。

(3) **IoU 和 mIoU**: 综合考虑预测结果的准确性和完整性, 对分割边界精度敏感, 是语义分割任务中最常用的评价指标。**mIoU** 能够综合反映模型对不同类别的分割性能, 适用于多类别分割任务。

(4) **Dice 系数**: 对分割区域的完整性更加敏感, 在医学图像分割等需要精确区域分割的任务中应用广泛。**Dice 系数**与 **IoU** 相关但侧重点不同, 可以根据具体任务需求选择合适的指标。

在实际应用中, 通常同时使用多个评价指标, 从不同角度全面评估模型性能。本文实验部分将同时报告 **mIoU**、**PA**、**mPA** 和 **Dice 系数**等指标, 以全面评估所提方法的分割性能。

2.6 本章小结

本章介绍了本文研究所需的相关理论与技术基础, 为后续章节的方法设计与实验分析提供了理论支撑。

首先, 本章介绍了 OCT 成像原理, 包括 OCT 技术的基本原理、技术分类以及在激光焊接中的应用。OCT 技术基于低相干干涉原理, 能够实现微米级的高分辨率层析成像, 在激光焊接场景中可用于锁孔检测和熔深测量。然而, OCT 图像存在散斑噪声、对比度低、边界模糊等特点, 使得目标区域的提取成为一项具有挑战性的任务, 这也为本文研究面向 OCT 图像的语义分割方法提供了重要动机。

其次, 本章介绍了深度学习的基础理论, 包括卷积神经网络、编码器-解码器架构以及注意力机制等核心概念。卷积神经网络通过局部连接、权值共享和池化操作, 能够有效提取图像特征; 编码器-解码器架构通过编码器提取多尺度特征、解码器恢复空间分辨率, 实现了端到端的像素级预测; 注意力机制通过动态分配权重, 使网络能够关注重要信息, 提升了模型的表达能力。这些理论基础为本文方法的设计提供了重要支撑。

再次, 本章回顾了语义分割的发展历程和关键技术, 包括全卷积网络、U-Net

架构以及 DeepLab 系列方法。DeepLabV3+ 作为本文方法的基础框架，通过编码器-解码器结构和 ASPP 模块，实现了多尺度上下文信息的有效捕获。然而，在处理 OCT 图像时，DeepLabV3+ 仍存在全局上下文信息利用不足和局部细节丢失等问题，这为本文的改进提供了方向。

此外，本章详细介绍了焊接 OCT 图像数据集的构建过程。针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题，本研究构建了面向熔深分割的自建数据集。数据集构建包括 OCT 图像采集、预处理（裁剪、去噪、对比度增强、尺寸调整）、基于 LabelMe 的熔深线段标注、数据增强等步骤。通过数据增强策略，将原始 200 张图像扩充至 1000 余张，并按照 8:1:1 的比例划分为训练集、验证集和测试集，为后续模型训练提供了数据基础。

最后，本章介绍了语义分割常用的评价指标，包括像素准确率、平均像素准确率、交并比、平均交并比以及 Dice 系数等。这些评价指标从不同角度量化模型的分割性能，为后续章节的实验评估提供了标准。

基于本章介绍的理论基础和构建的数据集，本文将在第三章提出一种基于改进 DeepLabV3+ 的 OCT 图像语义分割方法。该方法在编码器端引入 TR 模块以增强全局上下文建模能力，在解码器端引入 SAE 模块以增强局部细节和边界信息，从而实现对熔深区域的高精度分割。第四章将基于本章介绍的评价指标，对所提方法进行全面的实验验证和性能分析。

第三章 基于改进 DeepLabV3+ 的焊接 OCT 图像分割算法

激光焊接过程中，熔深是评估焊接质量的关键指标。熔深过小会导致焊接强度不足，熔深过大则可能造成焊穿或烧蚀等问题。传统的熔深测量方法依赖于破坏性金相检测或人工目视检查，效率低下且难以实现在线监测。OCT 技术的引入为激光焊接熔深的非接触式在线检测提供了新的途径，但 OCT 图像存在散斑噪声严重、对比度低、边界模糊等特点，使得熔深区域的自动化提取成为一项具有挑战性的任务。

近年来，基于深度学习的语义分割方法在图像分割领域取得了显著进展。DeepLabV3+ 作为语义分割领域的经典方法，通过编码器-解码器结构和 ASPP 模块实现了多尺度上下文信息的有效捕获^[5]。然而，在处理焊接 OCT 图像时，DeepLabV3+ 仍面临全局上下文建模不足的挑战。ASPP 模块的感受野受限于空洞卷积的局部性，难以建立长距离依赖关系，而 OCT 图像中的熔深区域呈现细长结构，需要网络理解整个图像的空间关系才能实现准确分割。

针对上述问题，本章提出了一种基于 Transformer 注意力机制的改进方案。通过在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块，利用双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力。同时，针对 OCT 图像中前景与背景类别不平衡的问题，设计了 BCE+Dice 混合损失函数。

本章结构如下：3.1 节详细介绍 DeepLabV3+ 基线模型的工作原理；3.2 节阐述模型的改进动机与 TR 模块的设计；3.3 节通过消融实验和对比实验验证所提方法的有效性；3.4 节对本章内容进行总结。

3.1 DeepLabV3+ 模型的工作原理

DeepLabV3+ 是语义分割领域的经典方法，由 Google 团队于 2018 年提出^[5]。该模型结合了空洞卷积、ASPP 模块和编码器-解码器结构，在多尺度上下文信息捕获方面表现出色。本节详细介绍 DeepLabV3+ 的核心组件，为后续改进工作奠定基础。DeepLabV3+ 的整体网络结构如图 3-1 所示。




图 3-1 DeepLabV3+ 网络结构图

3.1.1 空洞卷积

在图像处理领域中，卷积操作是提取图像特征的基础。然而，传统的卷积操作在增加感受野的同时，会导致计算量显著增加以及图像细节的丢失。为了解决这个问题，空洞卷积（Atrous Convolution，又称扩张卷积）应运而生。

空洞卷积是一种特殊的卷积操作，其核心思想是在卷积核中插入空洞，从而在不增加计算量的前提下扩大卷积核的感受野。具体而言，空洞卷积通过在卷积核的相邻元素之间插入一定数量的空洞（即零值），使得卷积核能够在更大的范围内捕捉图像信息。空洞卷积的示意图如图 3-2 所示。




图 3-2 空洞卷积示意图

设输入特征图为 $\mathbf{F}$ ，空洞卷积核为 $\mathbf{W}$ ，空洞率为 r ，则空洞卷积的输出可表

示为:

$$\mathbf{O}[i, j] = \sum_m \sum_n \mathbf{F}[i + r \cdot m, j + r \cdot n] \cdot \mathbf{W}[m, n] \quad (3-1)$$

其中, (i, j) 表示输出特征图的位置坐标, (m, n) 表示卷积核的索引。当 $r = 1$ 时, 空洞卷积退化为标准卷积; 当 $r > 1$ 时, 卷积核的有效感受野扩大为 $(2r - 1) \times k + 1$, 其中 k 为卷积核的原始尺寸。

在 DeepLabV3+ 模型中, 空洞卷积被广泛应用于编码器特征提取阶段。通过不同空洞率的空洞卷积组合, 编码器能够捕捉到不同尺度的图像特征, 为后续的多尺度信息融合提供基础。相比于传统的池化操作, 空洞卷积在扩大感受野的同时能够保持特征图的空间分辨率, 避免了下采样带来的信息损失。

3.1.2 ASPP 模块

ASPP (Atrous Spatial Pyramid Pooling, 空洞空间金字塔池化) 模块是 DeepLabV3+ 的核心组件, 通过多个不同空洞率的并行分支捕获多尺度上下文信息^[17]。ASPP 模块的设计灵感来源于空间金字塔池化 (Spatial Pyramid Pooling, SPP), 但与之不同的是, ASPP 模块使用空洞卷积来替代传统的池化操作。ASPP 模块的结构如图 3-3 所示。




图 3-3 ASPP 模块结构图

本文方法采用深度可分离 ASPP 模块 (DepthwiseSeparableASPPModule), 在保持性能的同时降低计算复杂度。ASPP 模块包含 5 个并行分支:

(1) **1×1 卷积分支**: 使用标准 1×1 卷积, 感受野为 1×1, 用于捕获细节特征。该分支能够保留特征图的原始信息, 避免空洞卷积可能带来的信息丢失。

(2) **3×3 空洞卷积分支 (dilation=12)**: 使用 3×3 空洞卷积, 空洞率为 12, 感受野约为 25×25, 用于捕获局部特征。该分支能够在保持特征图分辨率的同时扩大感受野, 捕获更大范围的上下文信息。

(3) **3×3 空洞卷积分支 (dilation=24)**: 使用 3×3 空洞卷积, 空洞率为 24, 感受野约为 49×49, 用于捕获区域特征。该分支进一步扩大了感受野, 能够捕获更大范围的上下文信息。

(4) **3×3 空洞卷积分支 (dilation=36)**: 使用 3×3 空洞卷积, 空洞率为 36, 感受野约为 73×73, 用于捕获全局特征。该分支具有最大的感受野, 能够捕获更大范围的上下文信息。

(5) **全局平均池化分支**: 对特征图进行全局平均池化, 然后通过 1×1 卷积和双线性插值上采样, 恢复原始尺寸。该分支的感受野为整个特征图, 能够捕获全局上下文信息。

5 个并行分支的输出特征经过通道维度拼接后, 得到多尺度特征表示。以输入特征图尺寸为 16×16×512 为例, 每个分支输出 16×16×512 的特征图, 拼接后得到 16×16×2560 的多尺度特征。随后通过 1×1 卷积降维到 16×16×512, 减少特征维度并融合多尺度信息。

ASPP 模块使用深度可分离卷积降低计算复杂度。深度可分离卷积分为两个步骤: 首先进行深度卷积 (Depthwise Convolution), 对每个通道独立进行卷积操作; 然后进行点卷积 (Pointwise Convolution), 使用 1×1 卷积进行通道融合。深度可分离卷积的参数量和计算量远小于标准卷积, 在保持性能的同时提升了计算效率。

3.1.3 编码器-解码器结构

DeepLabV3+ 采用编码器-解码器架构, 其中编码器负责提取图像的多尺度特征并捕获语义信息, 解码器负责恢复空间分辨率并输出像素级预测结果^[5]。

(1) **编码器**: 本文方法采用 ResNet18-V1c 作为骨干网络^[32]。ResNet18-V1c 是 ResNet 的改进版本, 使用 Deep Stem 结构 (三个连续的 3×3 卷积替换传统的 7×7 卷积) 减少参数量并提升特征提取能力。ResNet18-V1c 包含四个阶段 (Stage),

逐步提取从低级到高级的特征表示：

- Stage 1 输出： $128 \times 128 \times 64$ （保留较多细节信息，用于解码器融合）
- Stage 2 输出： $64 \times 64 \times 128$
- Stage 3 输出： $32 \times 32 \times 256$
- Stage 4 输出： $16 \times 16 \times 512$ （送入 ASPP 模块进行多尺度上下文聚合）

(2) 解码器：解码器通过上采样和特征融合操作，逐步恢复特征图的空间分辨率。具体步骤如下：

1. **高层特征处理：**ASPP 模块输出的高层特征（ $16 \times 16 \times 512$ ）通过双线性插值上采样到 $128 \times 128 \times 512$ ，恢复空间分辨率。
2. **低层特征处理：**编码器 Stage 1 的低层特征（ $128 \times 128 \times 64$ ）通过 1×1 卷积降维到 $128 \times 128 \times 48$ ，减少通道数以匹配高层特征。
3. **特征融合：**将上采样后的高层特征（ $128 \times 128 \times 512$ ）与处理后的低层特征（ $128 \times 128 \times 48$ ）在通道维度进行拼接，得到融合特征（ $128 \times 128 \times 560$ ）。这种设计能够结合低层的细节信息和高层的语义信息，提升分割精度。
4. **分类头：**融合特征经过深度可分离卷积和 1×1 卷积，转换为类别 logits（ $128 \times 128 \times 2$ ），最后通过双线性插值上采样到原始图像尺寸（ $512 \times 512 \times 2$ ），输出像素级类别预测结果。

DeepLabV3+ 的创新之处在于将 DeepLabV3 的输出作为编码器特征，通过解码器融合编码器的中间特征，在保持分割精度的同时提升了边界定位的准确性。本文方法以 DeepLabV3+ 为基础框架，在此基础上引入 TR 模块进一步提升分割性能。

3.2 模型的设计与改进

3.2.1 模型的改进动机

尽管 DeepLabV3+ 在通用语义分割任务中表现出色，但在处理激光焊接 OCT 图像时仍存在以下局限性，这些局限性构成了本文改进工作的直接动机。

(1) 全局上下文建模不足：ASPP 模块通过不同空洞率的并行分支捕获多尺度上下文信息，但其感受野仍受限于空洞卷积的局部性。以 $\text{dilation}=36$ 的最大空洞率为例，其有效感受野约为 73×73 像素，仅覆盖 16×16 特征图的局部区域。然而，OCT 图像中的熔深区域往往呈现细长结构（纵横比可达 1:10 以上），跨越图像的多个区域，需要网络理解整个图像的空间关系才能准确分割。ASPP 模块的局部感受野限制了其对全局结构的理解能力，可能导致细长熔深结构的断裂或误分割。

(2) 类别不平衡问题：OCT 图像中背景区域通常占据 90% 以上的像素，而熔深目标区域仅占 5-10%。标准交叉熵损失对每个像素赋予相同权重，导致模型训练时偏向背景类别，难以充分学习前景特征。

基于上述局限性分析，本文提出针对性的改进方案：在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块，通过双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力；同时设计 BCE+Dice 混合损失函数应对类别不平衡问题。

3.2.2 Transformer 注意力模块（TR）设计

针对 DeepLabV3+ 全局上下文建模不足的问题，本文在 ASPP 模块之后引入 TR（Transformer Routing）全局注意力模块。TR 模块借鉴 BiFormer 的双层路由注意力思想^[29]，通过区域级路由和 TopK 选择机制，仅对最相关的窗口进行注意力计算，在保持全局建模能力的同时将计算复杂度从 $O(n^2)$ 降低到 $O(n^2 \times k/p^2)$ 。TR 模块的结构如图 3-4 所示。

(1) 模块结构

TR 模块主要包括位置编码（深度可分离卷积， 3×3 ）、LayerNorm 归一化、双层路由注意力、MLP（扩展-压缩结构）和残差连接等组件。其中，双层路由注意力是核心创新，通过区域级路由和令牌级注意力两个阶段实现高效的全局上下文建模。

(2) 双层路由注意力机制

双层路由注意力机制是 TR 模块的核心创新，其工作流程如图 3-5 所示，具体包括以下步骤：

步骤一：窗口划分。将输入特征图（ $16 \times 16 \times 2560$ ）按照 4×4 的窗口大小进行

【待插入图片】
TR 模块结构图
(位置编码、LayerNorm、双层路由注意力、MLP、残差连接)

图 3-4 TR 模块结构图

【待插入图片】
双层路由注意力机制示意图
(窗口划分 → 区域级路由 → TopK 选择 → 令牌级注意力)

图 3-5 双层路由注意力机制示意图

划分，得到 16 个窗口（ $4 \times 4 = 16$ ）。每个窗口包含 16 个令牌（token），对应特征图中的 16 个像素位置。

步骤二：区域级路由。对每个窗口的所有令牌求平均，得到区域级查询向量 $\mathbf{Q}_{\text{region}}^{(i)}$ 和键向量 $\mathbf{K}_{\text{region}}^{(i)}$ ，其中 i 表示第 i 个窗口。区域级查询和键向量的计算可表示为：

$$\mathbf{Q}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{Q}_j, \quad \mathbf{K}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{K}_j \quad (3-2)$$

其中， $\mathcal{W}_i$ 表示第 i 个窗口内的所有令牌， $|\mathcal{W}_i|$ 表示窗口内的令牌数量。

计算窗口间的相似度矩阵 $\mathbf{S}$ ，其中 $\mathbf{S}_{ij}$ 表示第 i 个窗口与第 j 个窗口的相似度：

$$\mathbf{S}_{ij} = \frac{\mathbf{Q}_{\text{region}}^{(i)} \cdot \mathbf{K}_{\text{region}}^{(j)}}{\|\mathbf{Q}_{\text{region}}^{(i)}\| \times \|\mathbf{K}_{\text{region}}^{(j)}\|} \quad (3-3)$$

其中， $\cdot$ 表示向量内积， $\|\cdot\|$ 表示向量范数。相似度矩阵 $\mathbf{S}$ 的维度为 16×16 ，表示 16 个窗口之间的相似度关系。

步骤三：TopK 路由选择。对每个窗口，根据相似度矩阵选择 TopK 个最相关的窗口参与注意力计算。本文设置 $k = 4$ ，即每个窗口选择 4 个最相关的窗口：

$$\mathcal{R}_i = \text{TopK}(\mathbf{S}_{i,:}, k = 4) \quad (3-4)$$

其中， $\mathcal{R}_i$ 表示第 i 个窗口选择的相关窗口索引集合， $\mathbf{S}_{i,:}$ 表示相似度矩阵的第 i 行。

步骤四：令牌级注意力。在选定的窗口内进行像素级注意力计算。对于第 i 个窗口，仅对 $\mathcal{R}_i$ 中的窗口进行注意力计算：

$$\text{Attention}(\mathbf{Q}_i, \mathbf{K}_{\mathcal{R}_i}, \mathbf{V}_{\mathcal{R}_i}) = \text{softmax} \left(\frac{\mathbf{Q}_i \mathbf{K}_{\mathcal{R}_i}^T}{\sqrt{d_k}} \right) \mathbf{V}_{\mathcal{R}_i} \quad (3-5)$$

其中， $\mathbf{Q}_i$ 、 $\mathbf{K}_{\mathcal{R}_i}$ 、 $\mathbf{V}_{\mathcal{R}_i}$ 分别表示第 i 个窗口的查询矩阵和选定窗口的键值矩阵， d_k 为键向量的维度。

(3) 复杂度分析

双层路由注意力机制通过 TopK 路由选择，显著降低了计算复杂度。标准自注意力机制的计算复杂度为 $O(n^2)$ ，其中 n 为特征图中的像素数量。对于 16×16 的特征图， $n = 256$ ，标准自注意力的计算复杂度为 $O(256^2) = O(65536)$ 。

双层路由注意力机制的计算复杂度为 $O(n^2 \times k/p^2)$ ，其中 k 为 TopK 值（ $k =$

4), p 为窗口大小 ($p = 4$)。对于 16×16 的特征图, 划分为 16 个窗口, 每个窗口选择 4 个相关窗口, 计算复杂度为 $O(256^2 \times 4/16) = O(16384)$, 相比标准自注意力降低了约 75% 的计算量。

(4) 模块作用小结

TR 模块通过双层路由注意力机制实现三个核心功能: (1) 建立特征图中任意位置之间的长距离依赖关系; (2) 理解整个特征图的空间关系, 更好地处理细长结构目标; (3) 通过 TopK 路由选择降低计算复杂度约 75%。TR 模块的输出特征经过 1×1 卷积降维后 ($16 \times 16 \times 512$), 与编码器的低层特征融合, 为后续解码器提供增强的全局上下文信息。

3.2.3 混合损失函数设计

OCT 图像语义分割任务面临严重的类别不平衡问题: 背景区域通常占据图像的 90% 以上, 而熔深目标区域仅占 5-10%。传统交叉熵损失对每个像素赋予相同权重, 导致模型训练时偏向背景类别。因此, 本文设计混合损失函数, 结合二元交叉熵损失和 Dice 损失, 兼顾像素级精度和区域级一致性。

(1) 二元交叉熵损失

二元交叉熵损失 (BCE Loss) 提供逐像素的梯度信号, 确保模型对每个像素进行准确的类别预测:

$$L_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(p_i)) + (1 - y_i) \log(1 - \sigma(p_i))] \quad (3-6)$$

其中, N 为像素总数, $y_i \in \{0, 1\}$ 为真实标签, p_i 为预测 logits, $\sigma(\cdot)$ 为 Sigmoid 激活函数。

(2) Dice 损失

Dice 损失关注区域重叠, 对类别不平衡问题更加鲁棒:

$$L_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N \sigma(p_i) \cdot y_i + \epsilon}{\sum_{i=1}^N \sigma(p_i) + \sum_{i=1}^N y_i + \epsilon} \quad (3-7)$$

其中, $\epsilon = 10^{-5}$ 为平滑项, 用于防止分母为零。Dice 损失关注预测结果与真实标签的重叠程度, 能够使模型更加关注前景区域的分割精度。

(3) 组合损失函数

将 BCE 损失和 Dice 损失进行加权组合：

$$L_{\text{total}} = \lambda_1 \cdot L_{\text{BCE}} + \lambda_2 \cdot L_{\text{Dice}} \quad (3-8)$$

其中， $\lambda_1 = 2.0$ 和 $\lambda_2 = 2.0$ 分别为 BCE 损失和 Dice 损失的权重。BCE 损失提供逐像素的梯度信号，Dice 损失关注区域重叠，两者组合能够兼顾像素级精度和区域级一致性，从而提升分割性能。

3.2.4 改进模型整体结构

本文提出的改进模型（DeepLabV3+ + TR）的整体结构如图 3-6 所示。相比原始 DeepLabV3+，改进模型在 ASPP 模块之后引入了 TR 全局注意力模块。



图 3-6 改进模型（DeepLabV3+ + TR）整体结构图

数据流可描述为：输入图像（ $512 \times 512 \times 3$ ）→ 编码器（ResNet18-V1c）→ Stage 4 特征（ $16 \times 16 \times 512$ ）→ ASPP 模块（ $16 \times 16 \times 2560$ ）→ TR 模块（ $16 \times 16 \times 2560$ ）→ 1×1 卷积降维（ $16 \times 16 \times 512$ ）→ 解码器融合（ $128 \times 128 \times 560$ ）→ 分类头（ $512 \times 512 \times 2$ ）→ 输出预测。

TR 模块的引入使模型能够在 ASPP 模块输出的多尺度特征基础上，进一步建立长距离依赖关系，增强对细长熔深结构的整体理解能力。通过 TopK 路由机制，TR 模块在提升性能的同时控制了计算开销。

3.3 实验结果与分析

为验证本文所提方法的有效性，本节在自建焊接 OCT 图像数据集上进行了系统的实验评估。实验包括消融实验和对比实验，分别用于验证 TR 模块的有效性以及改进模型与主流方法的性能对比。

3.3.1 实验环境与参数配置

(1) 实验平台

实验环境包括硬件和软件两部分。硬件方面，本文使用了高性能 GPU 和足够的内存来支持模型的训练和推理。软件方面，本文使用了 PyTorch 深度学习框架和 CUDA 加速库来实现模型训练和推理。实验硬件配置如表 3-1 所示，软件配置如表 3-2 所示。

表 3-1 实验硬件配置

配置项	参数
GPU	NVIDIA GeForce RTX 3090
显存	24 GB
CPU	Intel Xeon W-2295
核心/线程数	18 核 36 线程
内存	128 GB DDR4 RAM
存储设备	NVMe SSD

表 3-2 实验软件配置

工具/框架	版本号
操作系统	Ubuntu 20.04 LTS
深度学习框架	PyTorch 1.10.0
分割框架	MMSegmentation
GPU 加速工具	CUDA 11.3, cuDNN 8.2
编程语言	Python 3.8

(2) 训练参数配置

实验参数配置如表 3-3 所示。本文采用 Adam 优化器进行模型训练，学习率采用多项式衰减策略。

(3) 评价指标

本文采用语义分割领域常用的评价指标来衡量模型性能，主要包括：

表 3-3 实验参数配置

参数	设置
训练迭代次数	20,000 次
批量大小	8 (每个 GPU)
优化器	Adam
初始学习率	1×10^{-6}
学习率调度策略	多项式衰减 (power=0.9)
输入图像尺寸	512×512
评估间隔	每 500 次迭代

- **mIoU** (平均交并比): 所有类别 IoU 的平均值, 是评估分割性能的核心指标。
- **mAcc** (平均准确率): 所有类别准确率的平均值。
- **mDice** (平均 Dice 系数): 所有类别 Dice 系数的平均值, 与 IoU 类似但更关注区域重叠。
- **Params** (参数量): 模型的参数数量, 单位为 MB。
- **推理时间**: 处理单张 512×512 图像所需的时间, 单位为 ms。

3.3.2 消融实验

为验证 TR 模块的有效性, 本节设计了消融实验, 对比基线模型 (DeepLabV3+) 与引入 TR 模块后的性能差异。消融实验结果如表 3-4 所示。

表 3-4 TR 模块消融实验结果

模型配置	mIoU	mAcc	mDice	参数量
DeepLabV3+ (基线)	0.851	0.923	0.913	95MB
DeepLabV3+ + TR	0.884	0.941	0.935	396MB
提升	+3.9%	+1.9%	+2.4%	+317%

由表 3-4 可知, 引入 TR 模块后, 模型在 mIoU 指标上从 0.851 提升至 0.884, 提升幅度达 3.9%。这一提升主要归因于 TR 模块通过双层路由注意力机制建立了长距离依赖关系, 增强了模型对全局上下文的理解能力, 使得细长熔深结构能够被更完整地分割。

mAcc 和 mDice 指标分别提升了 1.9% 和 2.4%，表明 TR 模块在提升整体分割精度的同时，也改善了区域预测的一致性。虽然 TR 模块引入了额外的参数量（从 95MB 增加到 396MB），但考虑到性能的显著提升，这一开销是可接受的。

消融实验结果验证了 TR 模块在解决全局上下文建模不足问题上的有效性。通过在 ASPP 输出的多尺度特征上引入全局注意力机制，模型能够更好地理解图像的整体结构，从而提升对细长目标的分割精度。

3.3.3 对比实验

为进一步验证本文方法的优越性，本节将改进模型与多种主流语义分割方法进行对比，包括 U-Net、U-Net++、ResUNet、TransUNet 和原始 DeepLabV3+ 等。对比实验结果如表 4-2 所示。

表 3-5 不同模型在焊接 OCT 数据集上的性能对比

模型	mIoU	mAcc	mDice	参数量	推理时间
UNet	0.805	0.878	0.880	30MB	45ms
UNet++	0.751	0.905	0.837	8.8MB	-
ResUNet	0.721	0.788	0.810	13MB	-
TransUNet	0.810	0.963	0.884	219MB	156ms
DeepLabV3+（基线）	0.851	0.923	0.913	95MB	38ms
DeepLabV3+ + TR	0.884	0.941	0.935	396MB	89ms

从表 4-2 可以看出，本文方法在 mIoU 指标上达到 0.884，显著优于所有对比方法。具体分析如下：

（1）与 U-Net 系列对比：相比 U-Net（mIoU=0.805），本文方法提升了 9.8%；相比 U-Net++（mIoU=0.751）和 ResUNet（mIoU=0.721），提升幅度更为显著。这表明传统的编码器-解码器架构在处理 OCT 图像时存在明显的性能瓶颈，而本文方法通过引入全局注意力机制有效解决了这一问题。

（2）与 TransUNet 对比：TransUNet 采用 Transformer 作为编码器，在 mAcc 指标上表现出色（0.963），但其 mIoU（0.810）仍低于本文方法。此外，TransUNet 的参数量（219MB）和推理时间（156ms）都较大，而本文方法在保持更高 mIoU 的同时，推理时间仅为 89ms，比 TransUNet 快 43%。

（3）与基线模型对比：相比 DeepLabV3+ 基线模型，本文方法在 mIoU、mAcc、mDice 三个核心指标上均有提升，验证了 TR 模块引入的有效性。




图 3-7 分割结果可视化对比

图 3-7 展示了不同模型的分割结果可视化对比。可以看到，本文方法在熔深区域的分割更加完整，边界更加清晰。特别是在细长熔深结构的分割上，本文方法有效避免了断裂现象，这主要得益于 TR 模块对全局上下文的有效建模。

3.4 本章小结

本章围绕焊接 OCT 图像语义分割任务，从模型设计、改进方法到实验验证展开了系统性分析。针对 DeepLabV3+ 在处理 OCT 图像时全局上下文建模不足的问题，提出了一种基于 Transformer 注意力机制的改进方案。

本章的主要工作包括：

1. 详细分析了 DeepLabV3+ 模型的工作原理，包括空洞卷积、ASPP 模块和编码器-解码器结构，为改进工作奠定了理论基础。
2. 设计了 TR 全局注意力模块：通过双层路由注意力机制建立长距离依赖，在保持全局建模能力的同时将计算复杂度降低约 75%。
3. 设计了 BCE+Dice 混合损失函数：兼顾像素级精度和区域级一致性，有效应对类别不平衡问题。

4. 通过消融实验和对比实验验证了所提方法的有效性：TR 模块使 mIoU 提升 3.9% (0.851→0.884)，相比 U-Net 提升 9.8%，相比 TransUNet 提升 9.1%。

实验结果表明，TR 模块能够有效增强模型对全局上下文的建模能力，提升对细长熔深结构的分割精度。然而，在对分割结果的分析中发现，模型在边界区域的细节表达能力仍有提升空间。第四章将进一步引入空间感知增强（SAE）模块，通过坐标注意力机制增强模型对空间位置信息的感知能力，实现更精确的边界分割。

第四章 基于空间感知增强的模型优化与综合实验

在第三章中，本文针对 DeepLabV3+ 模型在处理焊接 OCT 图像时全局上下文建模不足的问题，提出了 TR（Transformer Routing）全局注意力模块，通过双层路由注意力机制有效增强了模型对长距离依赖关系的建模能力。实验结果表明，引入 TR 模块后，模型的 mIoU 从 0.851 提升至 0.884，验证了全局注意力机制对分割性能的提升作用。

然而，在实际应用中，模型仍面临空间位置信息感知不足的挑战。标准的解码器通过简单的特征拼接融合高层语义信息和低层细节信息，但未显式建模特征图中不同空间位置之间的关联。这导致在处理细长结构的熔深区域时，模型难以精确定位目标边界，尤其在边界模糊和噪声干扰的情况下，边界分割精度有待提升。

针对上述问题，本章提出了空间感知增强（Spatial Awareness Enhancement, SAE）模块。该模块的设计灵感来源于坐标注意力机制^[23]，通过显式建模特征图的空间位置关系，增强模型对目标边界和细节区域的感知能力。同时，本章将 SAE 模块与第三章提出的 TR 模块相结合，构建了完整的 DeepLabV3+ + TR + SAE 改进模型，并通过消融实验和对比实验验证其有效性。

本章结构如下：4.1 节详细介绍 SAE 模块的设计动机、原理与集成方式；4.2 节阐述改进模型的整体结构和各模块的协同机制；4.3 节通过消融实验、对比实验、可视化分析和效率分析全面验证所提方法的有效性；4.4 节对本章内容进行总结。

4.1 空间感知增强模块（SAE）的设计

本节详细介绍空间感知增强模块的设计动机、原理与集成方式。SAE 模块通过引入坐标注意力机制，显式建模特征图的空间位置关系，从而增强模型对目标边界的感知能力。

4.1.1 改进动机

在语义分割任务中，精确的边界定位是实现高质量分割的关键。对于焊接 OCT 图像而言，熔深区域往往呈现细长结构，边界对比度低且常受散斑噪声干扰，这对模型的边界分割能力提出了更高要求。

传统的解码器设计主要关注多尺度特征融合，通过跳跃连接将编码器的低层特征与解码器的高层特征进行拼接或相加。虽然这种设计能够恢复空间细节信息，但存在以下局限性：

(1) 空间位置信息丢失：在编码过程中，多次下采样操作导致空间位置信息逐渐丢失。虽然解码器通过上采样恢复空间分辨率，但位置信息的恢复程度有限。

(2) 通道权重均匀分配：传统解码器对所有通道采用均匀权重，未能区分不同通道对边界分割的贡献差异。实际上，某些通道可能包含更丰富的边界信息，应当给予更高权重。

(3) 缺乏方向性感知：对于细长结构的目标，其在水平和垂直方向上的特征分布存在显著差异。传统解码器缺乏对这种方向性差异的显式建模能力。

为了解决上述问题，本文提出在解码器端引入空间感知增强模块，通过坐标注意力机制显式建模特征图的空间位置关系，增强模型对目标边界和细节区域的感知能力。

4.1.2 SAE 模块原理与结构

SAE 模块的核心思想是将空间位置信息嵌入到特征表示中，通过坐标注意力机制实现特征的空间维度重标定。SAE 模块的结构如图 4-1 所示。



图 4-1 SAE 模块结构图

SAE 模块的工作流程可以分为以下几个步骤：

(1) 方向性特征聚合

首先, SAE 模块沿着水平和垂直两个方向分别进行特征聚合, 获取位置敏感的特征描述。给定输入特征图 $X \in \mathbb{R}^{C \times H \times W}$, 水平方向的特征聚合定义为:

$$z_h(h) = \frac{1}{W} \sum_{0 \leq i < W} X(h, i) \quad (4-1)$$

垂直方向的特征聚合定义为:

$$z_w(w) = \frac{1}{H} \sum_{0 \leq j < H} X(j, w) \quad (4-2)$$

其中, $z_h \in \mathbb{R}^{C \times H \times 1}$ 和 $z_w \in \mathbb{R}^{C \times 1 \times W}$ 分别表示水平和垂直方向的聚合特征。这一步骤的关键在于, 它不是简单的全局池化, 而是分别沿着两个方向进行池化, 从而保留了特征图在两个方向上的位置信息。

(2) 坐标注意力生成

接下来, 将水平和垂直方向的聚合特征拼接后, 通过共享的 1×1 卷积进行特征变换:

$$f = \delta(F_{1 \times 1}([z_h, z_w])) \quad (4-3)$$

其中, $[\cdot, \cdot]$ 表示沿空间维度的拼接操作, $F_{1 \times 1}$ 表示 1×1 卷积, δ 表示 BatchNorm 和 ReLU 激活函数。

随后, 将变换后的特征重新分割为水平和垂直两部分, 分别通过独立的 1×1 卷积和 Sigmoid 激活函数生成注意力权重:

$$g_h = \sigma(F_h(f_h)), \quad g_w = \sigma(F_w(f_w)) \quad (4-4)$$

其中, $g_h \in \mathbb{R}^{C \times H \times 1}$ 和 $g_w \in \mathbb{R}^{C \times 1 \times W}$ 分别表示水平和垂直方向的注意力权重, σ 表示 Sigmoid 激活函数。

坐标注意力机制的工作原理如图 4-2 所示。

(3) 特征重标定

最后, 将生成的注意力权重与原始特征图进行逐元素相乘, 实现特征的空间维度重标定:

$$Y = X \odot g_h \odot g_w \quad (4-5)$$




图 4-2 坐标注意力机制示意图

其中， $\odot$ 表示逐元素相乘（广播机制）， $Y \in \mathbb{R}^{C \times H \times W}$ 表示经过空间感知增强后的输出特征。

通过上述过程，SAE 模块能够捕捉特征图在水平和垂直两个方向上的位置信息，并通过注意力权重对不同空间位置的特征进行自适应调整。这种设计使模型能够更准确地定位目标边界，在处理细长形目标和边缘模糊区域时表现出显著优势。

4.1.3 SAE 模块集成方式

SAE 模块被集成到 DeepLabV3+ 的解码器端，具体位置如图 4-3 所示。

在解码器中，SAE 模块的集成方式如下：

(1) 集成位置：SAE 模块位于低层特征经过 1×1 卷积降维之后、与高层特征拼接之前。这一位置选择基于以下考虑：低层特征包含丰富的空间细节信息，但也包含较多噪声；通过 SAE 模块对低层特征进行空间感知增强，可以突出边界相关的重要特征，抑制噪声干扰。

(2) 特征流动：编码器输出的低层特征（来自 ResNet 的 Layer1，通道数为 256）首先经过 1×1 卷积降维至 48 通道，然后输入 SAE 模块进行空间感知增强。增强后的特征与来自 ASPP 和 TR 模块的高层特征进行拼接，最后通过 3×3 卷积和上采样恢复到原始分辨率。

(3) 计算开销：SAE 模块采用轻量化设计，主要包含池化操作和少量 1×1



图 4-3 SAE 模块集成位置示意图

卷积，计算开销较小。实验结果表明，SAE 模块仅增加约 25MB 的参数量，但能带来 5.9% 的 mIoU 提升，参数效率较高。

4.2 改进模型的整体结构

经过第三章和本章的改进后，最终的模型结构如图 4-4 所示。本节详细介绍改进模型的完整架构和各模块的协同机制。

4.2.1 完整模型架构

改进后的模型在原始 DeepLabV3+ 模型的基础上，主要包含以下优化：

(1) 编码器端引入 TR 模块: 在 ASPP 模块之后引入 TR (Transformer Routing) 全局注意力模块，通过双层路由注意力机制建立长距离依赖关系，增强模型对全局上下文的建模能力。TR 模块的输入为 ASPP 模块的输出特征（尺寸为 $\frac{H}{8} \times \frac{W}{8}$ ，通道数为 256），输出为相同尺寸的增强特征。

(2) 解码器端集成 SAE 模块: 在解码器的低层特征处理分支中集成 SAE (Spatial Awareness Enhancement) 模块，通过坐标注意力机制增强空间位置感知能力。SAE 模块对降维后的低层特征（48 通道）进行空间维度重标定，突出边界相关的重要特征。

(3) 混合损失函数: 采用 BCE+Dice 混合损失函数进行训练，有效缓解类别




图 4-4 改进模型（DeepLabV3+ + TR + SAE）整体结构图

不平衡问题，提升模型对目标类别的分割性能。

4.2.2 各模块协同机制

TR 模块和 SAE 模块在模型中分别承担不同的功能，形成”全局-局部”互补的协同机制：

(1) TR 模块的全局建模作用

TR 模块位于编码器端，在 ASPP 模块之后对高层语义特征进行全局上下文增强。通过双层路由注意力机制，TR 模块能够：

- 建立长距离依赖关系，理解图像的全局空间结构
- 捕捉细长结构目标的整体形态，避免断裂和误分割
- 在全局视角下抑制噪声区域的干扰

TR 模块通过 Top-K 区域选择策略，优先关注与查询区域语义相关的关键区域，在保持计算效率的同时实现有效的全局上下文建模。

(2) SAE 模块的局部增强作用

SAE 模块位于解码器端，对低层细节特征进行空间位置感知增强。通过坐标注意力机制，SAE 模块能够：

- 显式建模特征图的空间位置关系，增强位置敏感性
- 自适应调整不同空间位置的特征权重，突出边界区域
- 在水平和垂直两个方向上分别捕捉位置信息，适应细长结构的方向性特征

SAE 模块以较小的计算开销实现显著的边界分割精度提升。

(3) 协同效应

TR 模块和 SAE 模块协同作用，在编码器端增强全局结构理解能力，在解码器端优化局部边界表示，实现了“编码重结构、解码重细节”的优化目标。这种设计使模型能够同时处理全局和局部信息，在保持整体分割准确性的同时，显著提升边界分割精度。

消融实验结果表明，单独使用 TR 模块可提升 mIoU 3.9%，单独使用 SAE 模块可提升 mIoU 5.9%，而同时使用两个模块可提升 mIoU 7.1%，体现了两个模块的互补性和协同效应。

4.3 综合实验与分析

本节对所提出的 DeepLabV3+ + TR + SAE 改进模型进行全面的实验验证与分析。首先通过消融实验验证各模块的贡献，然后与主流方法进行对比实验，接着通过可视化分析定性评估分割效果，最后分析模型的计算效率。

4.3.1 消融实验

为验证各改进模块的有效性，本文设计了消融实验，通过逐项添加模块，分析各模块对模型性能的贡献。消融实验共设计 4 种配置，如表 4-1 所示。

表 4-1 消融实验结果

配置	TR 模块	SAE 模块	mIoU	mAcc	mDice	相比基线提升
DeepLabV3+ (基线)	×	×	0.851	0.923	0.913	-
+ TR	✓	×	0.884	0.941	0.935	+3.9%
+ SAE	×	✓	0.901	0.948	0.945	+5.9%
+ TR + SAE	✓	✓	0.911	0.956	0.951	+7.1%

由表 4-1 可知，各模块均能带来性能增益：

(1) TR 模块贡献：单独引入 TR 模块后，mIoU 从 0.851 提升至 0.884，提升幅度达 3.9%。这表明全局上下文建模对分割性能有显著提升作用，TR 模块通过建立长距离依赖关系，增强了模型对细长结构目标的整体理解能力。

(2) SAE 模块贡献：单独引入 SAE 模块后，mIoU 从 0.851 提升至 0.901，提升幅度达 5.9%。这表明空间位置感知对边界分割具有重要意义，SAE 模块通过坐标注意力机制显著提升了边界分割精度。值得注意的是，SAE 模块仅增加 25MB 参数量，参数效率（mIoU 提升/参数量增加）达到 0.236，远高于 TR 模块的 0.013。

(3) 双重注意力协同效应：同时引入 TR 模块和 SAE 模块后，mIoU 从 0.851 提升至 0.911，提升幅度达 7.1%。组合提升幅度（7.1%）小于单模块提升幅度之和（3.9% + 5.9% = 9.8%），这表明两模块在提升路径上存在一定重叠。然而，组合配置在所有指标上均取得最优结果，体现了全局（TR）与局部（SAE）信息增强的互补性。

综合以上分析，双重注意力机制产生协同效应，性能提升超过单独使用任一模块的效果，验证了本文方法设计的有效性。

4.3.2 与主流方法对比实验

为验证本文方法的有效性，在相同实验设置下与基线模型及多种主流语义分割方法进行对比。对比方法包括 UNet、UNet++、ResUNet、TransUNet 以及 DeepLabV3+ 等，涵盖了编码器-解码器架构和 Transformer 架构等不同类型的分割网络。

表 4-2 给出了所有对比方法在测试集上的定量评估结果。

表 4-2 不同方法的定量评估结果对比

模型配置	mIoU	mAcc	mDice	mPrecision	mRecall
UNet	0.805	0.878	0.880	0.883	0.878
UNet++	0.751	0.905	0.837	0.790	0.905
ResUNet	0.721	0.788	0.810	0.836	0.788
TransUNet	0.810	0.963	0.884	0.829	0.963
DeepLabV3+ (基线)	0.851	0.923	0.913	0.904	0.923
本文方法	0.911	0.956	0.951	0.947	0.956

由表 4-2 可知，本文方法（DeepLabV3+ + TR + SAE）在所有分割性能指标上均取得最优结果：

(1) **相比基线模型**: 本文方法在 mIoU 指标上达到 0.911, 相比基线模型 (DeepLabV3+) 提升 7.1%, 在 mAcc 指标上提升 3.6%, 在 mDice 指标上提升 4.2%。这一结果表明, TR 模块和 SAE 模块的引入有效提升了模型的分割性能。

(2) **相比 UNet 系列方法**: 本文方法相比 UNet 基础版本, mIoU 提升 13.2%, mAcc 提升 8.9%。相比 UNet++ 和 ResUNet, 本文方法也均取得显著提升。这一结果表明, 本文方法在编码器-解码器架构的基础上, 通过引入双重注意力机制, 有效提升了分割性能。

(3) **相比 TransUNet**: 虽然 TransUNet 在 mAcc 指标上略高于本文方法 (0.963 vs 0.956), 但本文方法在 mIoU 指标上显著优于 TransUNet (0.911 vs 0.810), 提升幅度达 12.5%。更重要的是, 本文方法在计算效率方面具有明显优势 (详见效率分析部分)。

表 4-3 给出了不同方法在背景类别和目标类别上的性能对比。

表 4-3 不同方法在类别级别上的性能对比

模型配置	背景类别		目标类别		
	IoU	Acc	IoU	Acc	Dice
UNet	0.990	0.995	0.620	0.761	0.765
TransUNet	0.988	0.999	0.632	0.926	0.773
DeepLabV3+ (基线)	0.992	0.996	0.710	0.850	0.830
本文方法	0.996	0.998	0.826	0.914	0.904

由表 4-3 可知, 本文方法在目标类别上取得了显著提升。目标类别的 IoU 达到 0.826, 相比基线模型 (0.710) 提升 16.3%, 相比 UNet (0.620) 提升 33.2%, 相比 TransUNet (0.632) 提升 30.7%。目标类别性能的大幅提升表明, 本文方法通过 TR 模块增强全局上下文建模和 SAE 模块增强局部细节表达, 有效提升了对熔深目标的分割精度。

表 4-4 给出了不同方法的边界精度对比, 采用 HD95 指标进行评估。

表 4-4 不同方法的边界精度对比

模型配置	HD95	边界精度评价
UNet	15.23	中等
DeepLabV3+ (基线)	12.22	良好
DeepLabV3+ + TR	11.89	良好
DeepLabV3+ + SAE	11.45	优秀
本文方法	10.68	优秀

由表 4-4 可知，本文方法的 HD95 指标达到 10.68，相比基线模型（12.22）降低 12.6%，相比 UNet（15.23）降低 29.9%。HD95 值越小，表示边界分割越精确。值得注意的是，单独使用 SAE 模块时，HD95 为 11.45，已经取得了较好的边界精度；结合 TR 模块后，HD95 进一步降低至 10.68，说明双重注意力机制在边界精度提升方面具有协同效应。

4.3.3 可视化分析

本节通过可视化对比分析，从定性角度评估不同方法的分割效果。图 4-5 展示了不同方法在典型样例上的分割结果。



图 4-5 分割结果可视化对比

通过可视化对比分析，本文方法在以下方面表现出明显优势：

(1) 边界清晰度：本文方法在边界分割方面表现出色，边界更加清晰和连续。SAE 模块通过坐标注意力增强空间位置信息，使得边界特征更加突出，从而提升

了边界分割精度。相比之下，基线方法在边界模糊区域可能出现边界断裂或粘连问题。

(2) 细长结构处理：本文方法在处理细长结构方面表现出色，能够准确分割细长的熔深区域。TR 模块通过双层路由注意力机制建立长距离依赖关系，使得网络能够理解整个图像的空间关系，从而准确分割细长结构。相比之下，基线方法在细长结构上可能出现断裂或误分割问题。

(3) 噪声干扰下的鲁棒性：本文方法在噪声干扰下表现出较强的鲁棒性，能够稳定分割熔深区域。TR 模块通过全局上下文建模抑制局部噪声的影响，SAE 模块通过局部细节增强保留重要的边界信息，两者结合使得网络在噪声干扰下仍能稳定学习目标的语义结构。

4.3.4 效率分析

在实际应用中，除了分割性能外，模型的计算效率也是重要的考量因素。表 4-5 从参数量、内存占用和推理时间三个方面对不同方法进行对比分析。

表 4-5 不同方法的效率指标对比

模型配置	参数量 (MB)	内存占用 (MB)	推理时间 (ms)	FPS
UNet	30	3809	45	22.2
TransUNet	219	19530	156	6.4
DeepLabV3+ (基线)	95	2705	38	26.3
DeepLabV3+ + SAE	120	7011	52	19.2
DeepLabV3+ + TR	396	7004	89	11.2
本文方法	420	9107	95	10.5

由表 4-5 可知：

(1) 参数量分析：本文方法的参数量为 420MB，相比基线模型（95MB）增加 342.1%。参数量增加主要来源于 TR 模块（+301MB）和 SAE 模块（+25MB）。虽然参数量增加较大，但性能提升显著（mIoU 提升 7.1%），参数效率合理。

(2) 内存占用分析：本文方法的内存占用为 9107MB，相比基线模型（2705MB）增加 236.7%。但相比 TransUNet（19530MB），本文方法的内存占用减少 53.3%，在性能更优的同时具有更低的内存需求。

(3) 推理时间分析：本文方法的推理时间为 95ms，FPS 达到 10.5，满足实时应用需求（>10 FPS）。相比 TransUNet（156ms，6.4 FPS），本文方法的推理速度快 39.1%。

(4) 效率权衡: 综合考虑性能和效率, 本文方法在 mIoU 提升 12.5% 的同时 (相比 TransUNet), 内存占用减少 53.3%, 推理时间减少 39.1%, 取得了性能与效率的良好平衡。在实际应用中, 如果对实时性要求更高, 可以选择仅使用 SAE 模块的配置 (FPS 19.2), 虽然性能略有下降, 但推理速度更快。

4.4 本章小结

本章在第三章的基础上, 围绕空间位置信息感知不足的问题进行了深入探讨, 提出了空间感知增强 (SAE) 模块, 并构建了完整的 DeepLabV3++ TR + SAE 改进模型。

在模块设计方面, SAE 模块的设计灵感来源于坐标注意力机制, 通过沿水平和垂直两个方向进行特征聚合, 显式建模特征图的空间位置关系。该模块能够自适应调整不同空间位置的特征权重, 突出边界区域的特征表示, 从而提升边界分割精度。SAE 模块以较小的参数量 (+25MB) 实现了显著的性能提升 (mIoU +5.9%), 参数效率较高。

在模型架构方面, 本章将 SAE 模块集成到解码器端, 与第三章提出的 TR 模块形成“全局-局部”互补的协同机制。TR 模块在编码器端负责全局上下文建模, SAE 模块在解码器端负责局部细节增强, 两者协同作用实现了分割性能的综合提升。

在实验验证方面, 本章设计了消融实验、对比实验、可视化分析和效率分析, 全面验证了所提方法的有效性:

(1) 性能优势: 本文方法在 mIoU 指标上达到 0.911, 相比基线模型提升 7.1%, 相比 UNet 提升 13.2%, 相比 TransUNet 提升 12.5%。目标类别 IoU 提升 16.3%, 边界精度 HD95 降低 12.6%。

(2) 效率优势: 相比 TransUNet, 本文方法在性能更优的同时, 内存占用减少 53.3%, 推理速度快 39.1%, FPS 达到 10.5, 满足实时应用需求。

(3) 协同效应: 消融实验验证了 TR 模块和 SAE 模块的互补性和协同效应, 双重注意力机制的组合使用取得了最优性能。

综合以上实验结果和分析, 本章提出的改进方案使得最终模型在分割精度和效率之间达到了较好的平衡, 验证了所提方法在焊接 OCT 图像语义分割任务中的有效性和实用性。

第五章 总结与展望

激光焊接作为一种高效、精密的连接工艺，在新能源汽车、航空航天等领域得到广泛应用。熔深是评估焊接质量的关键指标，其在线检测对于保障焊接质量具有重要意义。本研究聚焦于基于 OCT 图像的焊接熔深语义分割问题，提出并优化了基于 DeepLabV3+ 的深度学习模型，结合 TR 全局注意力模块和 SAE 空间感知增强模块，旨在提升模型在复杂 OCT 图像场景下的分割精度和边界定位能力。

5.1 研究成果总结

本文的主要研究工作和创新点如下：

(1) 针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题，本文构建了面向焊接熔深分割的 OCT 图像数据集。该数据集包含约 1000 余张经过预处理和数据增强的图像，采用 LabelMe 工具进行像素级标注，按 8:1:1 比例划分为训练集、验证集和测试集，为后续研究提供了数据支撑。

(2) 针对 DeepLabV3+ 模型在处理 OCT 图像时全局上下文建模不足的问题，本文提出了 TR (Transformer Routing) 全局注意力模块。该模块基于双层路由注意力机制，通过 Top-K 区域选择策略建立长距离依赖关系，增强了模型对细长结构目标的整体理解能力。实验表明，TR 模块的引入使 mIoU 提升了 3.9%。

(3) 针对解码器端空间位置信息感知不足的问题，本文提出了 SAE (Spatial Awareness Enhancement) 空间感知增强模块。该模块基于坐标注意力机制，通过沿水平和垂直两个方向进行特征聚合，显式建模特征图的空间位置关系，提升了边界分割精度。SAE 模块仅增加 25MB 参数量，但能带来 5.9% 的 mIoU 提升，参数效率较高。

(4) 将 TR 模块和 SAE 模块相结合，构建了完整的 DeepLabV3++ TR + SAE 改进模型。双重注意力机制在编码器端增强全局结构理解能力，在解码器端优化局部边界表示，实现了“编码重结构、解码重细节”的优化目标。实验结果表明，改进后的模型在 mIoU 指标上达到 0.911，相比基线模型提升 7.1%；目标类别 IoU 从 0.710 提升至 0.826，提升幅度达 16.3%；边界精度 HD95 从 12.22 降低至 10.68，降低 12.6%。

(5) 通过消融实验、对比实验和效率分析，全面验证了所提方法的有效性。

消融实验表明, TR 和 SAE 模块均对性能提升有贡献, 且双重注意力机制产生协同效应。与 UNet、TransUNet 等主流方法相比, 本文方法在分割精度和边界精度方面均取得显著提升; 同时, 相比 TransUNet, 内存占用减少 53.3%, 推理时间减少 39.1%, FPS 达到 10.5, 满足实时应用需求。

本研究的成果对激光焊接质量在线检测具有重要的应用价值。改进后的模型能够更准确地从 OCT 图像中分割出熔深区域, 为焊接过程的实时监控和质量评估提供技术支撑, 推动了深度学习技术在焊接过程监测领域的应用。

5.2 工作展望

尽管本研究取得了一定的成果, 但仍存在一些不足和值得进一步探索的问题:

(1) 在极端噪声条件下 (如散斑噪声非常严重、图像质量极差), 模型可能出现误分割问题。未来可以探索更强的去噪策略或引入对抗训练机制, 提升模型的鲁棒性。

(2) 对于形态异常的目标 (如熔深区域形状极其不规则、存在多个目标重叠等), 模型的分割能力有限。未来可以通过扩大数据集规模、增加数据增强策略来改进。

(3) 模型的实时性虽然满足基本需求 (10.5 FPS), 但仍有优化空间。未来可以探索模型压缩技术 (如知识蒸馏、剪枝、量化等), 在保持性能的同时降低计算开销。

针对上述问题, 未来的研究可以从以下方向展开:

(1) 探索更先进的轻量级骨干网络, 如 MobileNetV3、EfficientNet 等, 在保持分割精度的同时进一步提升推理速度, 降低对计算资源的需求。

(2) 引入更高级的注意力机制, 如多尺度注意力、可变形注意力等, 增强模型对复杂形态目标的适应能力, 提升在边界模糊场景下的分割精度。

(3) 结合 OCT 信号的其他特征 (如光强信息、相位信息等), 进行多模态融合, 提升检测的准确性和可靠性。

(4) 开展基于深度学习的焊接熔深实时在线检测和反馈控制研究, 当检测到熔深异常时, 自动调整焊接参数, 实现焊接质量的闭环控制。

本研究在基于改进 DeepLabV3+ 模型的焊接 OCT 图像语义分割任务方面取

得了一定成果，验证了深度学习技术在焊接质量检测领域的应用潜力。希望通过不断的创新和改进，为焊接智能化检测技术的发展贡献更多的解决方案。

参考文献

- [1] 黄贻蔚. 基于 OCT 的 304 不锈钢激光焊接熔深在线检测研究 [D]. 广州: 广东工业大学, 2024.
- [2] 曾海涛. OCT 图像信号的散斑噪声处理方法研究 [D]. 重庆: 重庆理工大学, 2025.
- [3] LONG J, SHELHAMER E, DARRELL T. Fully Convolutional Networks for Semantic Segmentation[J/OL]. arXiv preprint arXiv:1411.4038, 2015 [2025-12-21].
<https://arxiv.org/abs/1411.4038>.
- [4] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J/OL]. arXiv preprint arXiv:1505.04597, 2015 [2025-12-21].
<https://arxiv.org/abs/1505.04597>.
- [5] CHEN L-C, ZHU Y, PAPANDREOU G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[J/OL]. arXiv preprint arXiv:1802.02611, 2018 [2025-12-21].
<https://arxiv.org/abs/1802.02611>.
- [6] 秦国梁, 林尚扬, 齐秀滨, et al. 激光焊接过程实时监测技术的研究现状及其发展 [J]. 焊接, 2002(10): 5–8.
- [7] STAVRIDIS J, PAPACHARALAMPOPOULOS A, STAVROPOULOS P. Quality assessment in laser welding: a critical review[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94(5): 1825–1847.
- [8] 高世一, 高世一, 吴瑞珉, et al. 激光焊接过程监测及焊缝质量检测技术研究现状 [J]. 世界钢铁, 2010(003): 51–54.
- [9] CHEN Z, GAO X. Detection of weld pool width using infrared imaging during high-power fiber laser welding of type 304 austenitic stainless steel[J]. The International Journal of Advanced Manufacturing Technology, 2014, 74(9): 1247–1254.
- [10] BOLEY M, FETZER F, WEBER R, et al. Statistical evaluation method to determine the laser welding depth by optical coherence tomography[J/OL]. Optics and Lasers in Engineering, 2019, 119: 56–64.
<https://www.sciencedirect.com/science/article/pii/S0143816618317639>.
- [11] MITTELSTÄDT C, MATTULAT T, SEEFELD T, et al. Novel approach for weld depth determination using optical coherence tomography measurement in laser deep penetration welding of aluminum and steel[J]. Journal of Laser Applications, 2019, 31(2).
- [12] 严毅, 邓超, 李琳, et al. 深度学习背景下的图像语义分割方法综述 [J]. 中国图象图形学报, 2023, 28(11): 3342–3362.
- [13] BADRINARAYANAN V, KENDALL A, CIPOLLA R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE transactions on pattern analysis and machine intelligence, 2017, 39(12): 2481–2495.
- [14] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[J]. arXiv preprint arXiv:1511.07122, 2015.
- [15] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs[J/OL]. arXiv preprint arXiv:1412.7062, 2014 [2025-12-21].
<https://arxiv.org/abs/1412.7062>.

-
- [16] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J/OL]. arXiv preprint arXiv:1606.00915, 2016 [2025-12-21].
<https://arxiv.org/abs/1606.00915>.
- [17] CHEN L-C, PAPANDREOU G, SCHROFF F, et al. Rethinking Atrous Convolution for Semantic Image Segmentation[J/OL]. arXiv preprint arXiv:1706.05587, 2017 [2025-12-21].
<https://arxiv.org/abs/1706.05587>.
- [18] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2017 : 2881 – 2890.
- [19] WANG J, SUN K, CHENG T, et al. Deep high-resolution representation learning for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2020, 43(10) : 3349 – 3364.
- [20] HU J, SHEN L, ALBANIE S, et al. Squeeze-and-Excitation Networks[J/OL]. arXiv preprint arXiv:1709.01507, 2019 [2025-12-21].
<https://arxiv.org/abs/1709.01507>.
- [21] WOO S, PARK J, LEE J-Y, et al. Cbam: Convolutional block attention module[C] // Proceedings of the European conference on computer vision (ECCV). 2018 : 3 – 19.
- [22] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C] // Proceedings of the IEEE conference on computer vision and pattern recognition. 2018 : 7794 – 7803.
- [23] HOU Q, ZHOU D, FENG J. Coordinate Attention for Efficient Mobile Network Design[J/OL]. arXiv preprint arXiv:2103.02907, 2021 [2025-12-21].
<https://arxiv.org/abs/2103.02907>.
- [24] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J/OL]. arXiv preprint arXiv:2010.11929, 2020 [2025-12-21].
<https://arxiv.org/abs/2010.11929>.
- [25] CHEN J, LU Y, YU Q, et al. TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation[J/OL]. arXiv preprint arXiv:2102.04306, 2021 [2025-12-21].
<https://arxiv.org/abs/2102.04306>.
- [26] YU C, GAO C, WANG J, et al. Bisenet v2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International journal of computer vision, 2021, 129(11) : 3051 – 3068.
- [27] ZHAO H, QI X, SHEN X, et al. Icnet for real-time semantic segmentation on high-resolution images[C] // Proceedings of the European conference on computer vision (ECCV). 2018 : 405 – 420.
- [28] 王卓, 瞿绍军. 深度学习实时语义分割研究进展和挑战 [J]. 中国图象图形学报, 2024, 29(5): 1188 – 1220.
- [29] ZHU L, WANG X, KE Z, et al. BiFormer: Vision Transformer with Bi-Level Routing Attention[J/OL]. arXiv preprint arXiv:2303.08810, 2023 [2025-12-21].
<https://arxiv.org/abs/2303.08810>.
- [30] HUANG D, SWANSON E A, LIN C P, et al. Optical coherence tomography[J/OL]. Science, 1991, 254(5035): 1178 – 1181.
<http://dx.doi.org/10.1126/science.1957169>.
- [31] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Re-

- ducing Internal Covariate Shift[J/OL]. arXiv preprint arXiv:1502.03167, 2015 [2025-12-21].
<https://arxiv.org/abs/1502.03167>.
- [32] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[J/OL]. arXiv preprint arXiv:1512.03385, 2015 [2025-12-21].
<https://arxiv.org/abs/1512.03385>.
- [33] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J/OL]. arXiv preprint arXiv:1706.03762, 2017 [2025-12-21].
<https://arxiv.org/abs/1706.03762>.
- [34] LIN T-Y, DOLLÁR P, GIRSHICK R, et al. Feature Pyramid Networks for Object Detection[J/OL]. arXiv preprint arXiv:1612.03144, 2016 [2025-12-21].
<https://arxiv.org/abs/1612.03144>.

致 谢

感谢

攻读硕士学位期间的研究成果

学术论文

[1] xxxx, xxxx, xxxx. xxxx. (SCI 收录, 对应学位论文第三章)