

分类号 TP39

UDC 004

学校代码

10590

密 级

公开

硕士学位论文

激光焊接 OCT 图像重建 与语义分割方法研究

学位申请人姓名 谢智捷

学位申请人学号 2310543016

专业（领域）名称 计算机技术

学 位 类 别 电子信息

学院（部、研究院） 人工智能与数字经济广东省

实验室（深圳）

导 师 姓 名 万明明

二〇二六年六月

深圳大学

学位论文原创性声明

本人郑重声明：所呈交的学位论文激光焊接 OCT 图像重建与语义分割方法研究是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本声明的法律后果由本人承担。

论文作者签名：

日期： 年 月 日

深圳大学

学位论文使用授权说明

本学位论文作者完全了解深圳大学关于收集、保存、使用学位论文的规定，即：研究生在校攻读学位期间论文工作的知识产权单位属深圳大学。学校有权保留学位论文并向国家主管部门或其他机构送交论文的电子版和纸质版，允许论文被查阅和借阅。本人授权深圳大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(涉密学位论文在解密后适用本授权书)

论文作者签名：

导师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

激光焊接过程中，熔深直接影响接头的承载能力，是焊接质量评价的核心指标。光学相干层析成像（Optical Coherence Tomography, OCT）通过主动测量光获取匙孔底部反射信息，可实现熔深的非接触在线测量。然而，OCT 在激光焊接场景的应用仍面临两方面问题：一是从干涉谱到深度图像的后处理计算量大，CPU 串行处理难以匹配高速 A 扫采集速率；二是重建后的图像受散斑噪声、边界模糊和目标与背景对比度不足等因素影响，现有分割方法难以准确提取匙孔区域。本文分别从 GPU 加速重建和语义分割模型改进两个方面开展研究，主要工作如下：

（1）设计基于 CUDA 的 OCT 图像加速重建流水线。将 SD-OCT 系统的 8 个后处理步骤（类型转换、光谱整形、背景扣除、K 线性化、色差补偿、FFT、幅值提取、帧合并）移植到 GPU 上并行执行，设计了对应的 CUDA 核函数。其中，K 线性化步骤需要对每条 A 扫求解一个 2048 阶三对角方程组，传统 Thomas 算法是串行的，在 GPU 上仅有 1 个线程参与计算。本文引入并行循环还原（PCR）算法替代 Thomas 算法，将求解过程分解为 11 层并行迭代，使所有线程同时参与运算。流水线数据全程驻留 GPU 端，综合利用常量内存、共享内存和只读缓存。针对焊接闭环控制场景下细粒度 B 扫的固定开销问题，进一步引入统一内存和 CUDA 事件进行优化。

（2）提出基于双重注意力机制的改进 DeepLabV3+ 语义分割方法。以 DeepLabV3+ 编码器—解码器架构为基线，在编码器端 ASPP 输出后加入 TR（Transformer Routing）模块，通过区域级路由筛选 Top-K 个相关区域并在其内部进行 token 级注意力计算，在可控计算开销下建立长距离依赖关系，改善细长匙孔结构的断裂分割问题。在解码器端加入 SAE（Spatial Awareness Enhancement）模块，采用“坐标注意力—特征精炼—通道注意力”级联结构，沿水平和垂直方向分别编码空间位置信息，提升边界处的分割精度。训练阶段采用交叉熵与 Dice 加权组合损失以缓解类别不平衡。

在自建焊接 OCT 数据集（912 张训练图像、228 张测试图像）上的实验结果表明，改进模型 mIoU 达到 0.911，较基线 DeepLabV3+ 提升 7.1%；目标类别

IoU 从 0.710 提升至 0.826 (+16.3%); 边界精度指标 HD95 从 12.22 降至 10.68 (-12.6%)。消融实验中, 单独加入 SAE 模块可提升 mIoU 5.9%, 单独加入 TR 模块可提升 3.9%, 两者联合使用的效果优于任一模块单独使用。与 UNet、TransUNet 等方法相比, 本文方法 mIoU 均为最高, 同时内存占用较 TransUNet 减少 53.3%。

关键词: 激光焊接; OCT 图像; CUDA 并行计算; 语义分割; 注意力机制

ABSTRACT

Penetration depth directly affects the load-bearing capacity of welded joints and is a core indicator for evaluating laser welding quality. Optical Coherence Tomography (OCT) obtains reflection information from the keyhole bottom through active measurement light, enabling non-contact online measurement of penetration depth. However, applying OCT in laser welding scenarios still faces two problems: the post-processing from interference spectra to depth images is computationally intensive, and serial CPU execution cannot match the high-speed A-scan acquisition rate; moreover, the reconstructed images are affected by speckle noise, blurred boundaries, and insufficient target-background contrast, making it difficult for existing segmentation methods to accurately extract the keyhole region. This thesis addresses these two problems from GPU-accelerated reconstruction and segmentation model improvement, respectively. The main contributions are as follows:

(1) A CUDA-based accelerated reconstruction pipeline for OCT images is designed. All eight post-processing steps of the SD-OCT system (type conversion, spectral shaping, background subtraction, K-linearization, dispersion compensation, FFT, magnitude extraction, and frame averaging) are ported to the GPU with corresponding CUDA kernels. In the K-linearization step, each A-scan requires solving a 2048-order tridiagonal system, and the conventional Thomas algorithm is serial, with only one thread performing computation on the GPU. The Parallel Cyclic Reduction (PCR) algorithm is introduced to replace the Thomas algorithm, decomposing the solve into 11 parallel iterations in which all threads participate simultaneously. Pipeline data reside on the GPU throughout, utilizing constant memory, shared memory, and read-only cache. For fine-grained B-scan scenarios in welding closed-loop control, unified memory and CUDA events are further introduced to reduce fixed overhead.

(2) An improved DeepLabV3+ semantic segmentation method based on dual attention mechanisms is proposed. Using the DeepLabV3+ encoder-decoder architecture as the baseline, a TR (Transformer Routing) module is added after the ASPP output in

the encoder, which performs region-level routing to select the Top-K relevant regions and then computes token-level attention within them, establishing long-range dependencies under controllable computational cost to address the fragmented segmentation of elongated keyhole structures. An SAE (Spatial Awareness Enhancement) module is added in the decoder, adopting a cascaded structure of “coordinate attention–feature refinement–channel attention” that encodes spatial position information along horizontal and vertical directions separately to improve boundary segmentation precision. A weighted combination of cross-entropy and Dice loss is used during training to mitigate class imbalance.

Experiments on a self-built welding OCT dataset (912 training images, 228 test images) show that the improved model achieves an mIoU of 0.911, a 7.1% improvement over the baseline DeepLabV3+. The target class IoU increases from 0.710 to 0.826 (+16.3%), and the boundary precision metric HD95 decreases from 12.22 to 10.68 (−12.6%). Ablation experiments show that adding the SAE module alone improves mIoU by 5.9%, adding the TR module alone by 3.9%, and their joint usage outperforms either module used independently. Compared with UNet and TransUNet, the proposed method achieves the highest mIoU while reducing memory consumption by 53.3% relative to TransUNet.

Key words: Laser Welding; OCT Image; CUDA Parallel Computing; Semantic Segmentation; Attention Mechanism

目 录

摘 要	I
ABSTRACT	III
符号和缩略语说明	VIII
第一章 绪论	1
1.1 研究背景及意义	1
1.2 国内外研究现状	3
1.2.1 激光焊接过程监测技术现状	3
1.2.2 OCT 图像噪声特性及处理方法研究现状	6
1.2.3 图像语义分割算法研究现状	7
1.2.4 OCT 数据 GPU 加速处理研究现状	9
1.3 当前关键问题与研究内容	10
1.3.1 当前关键问题	10
1.3.2 本文主要研究内容	11
1.4 论文组织结构	12
第二章 相关理论与技术基础	13
2.1 OCT 成像原理	13
2.1.1 OCT 成像基本原理	13
2.1.2 OCT 技术分类	14
2.1.3 OCT 在激光焊接中的应用	15
2.1.4 OCT 图像特点与分割算法设计的关联	15
2.2 CUDA 并行计算基础	15
2.2.1 编程模型	15
2.2.2 线程组织	16
2.2.3 存储层次	16
2.3 深度学习基础	17
2.3.1 卷积神经网络基础	17
2.3.2 编码器-解码器架构	19
2.3.3 注意力机制基础	20
2.4 语义分割理论基础	21
2.4.1 全卷积网络	21
2.4.2 U-Net 架构	21

2.4.3	U-Net 变体网络	23
2.4.4	DeepLab 系列方法	23
2.4.5	多尺度特征融合策略	25
2.5	焊接 OCT 图像数据集构建	25
2.5.1	OCT 图像采集	26
2.5.2	图像预处理	26
2.5.3	基于 LabelMe 的熔深线段标注	27
2.5.4	数据增强策略	28
2.5.5	数据集划分与统计	29
2.6	语义分割评价指标	30
2.6.1	混淆矩阵	31
2.6.2	像素准确率与平均像素准确率	31
2.6.3	交并比与平均交并比	32
2.6.4	Dice 系数	32
2.6.5	Hausdorff 距离	33
2.6.6	模型效率指标	33
2.7	本章小结	34
第三章	基于 CUDA 的 OCT 图像加速重建算法设计	35
3.1	OCT 后处理算法流程与计算瓶颈分析	35
3.1.1	后处理算法流程	35
3.1.2	串行计算瓶颈分析	36
3.2	基于 CUDA 的并行化后处理算法设计	37
3.2.1	预处理核函数组	37
3.2.2	K 线性化的并行化设计	38
3.2.3	频域变换与后处理核函数组	41
3.3	数据流组织与 GPU 内存层次利用	41
3.4	基于统一内存的高频后处理优化方案	42
3.4.1	细粒度 B 扫下的性能衰减现象	42
3.4.2	统一内存消除显式拷贝	42
3.4.3	事件驱动的轻量级同步	43
3.4.4	优化效果分析	44
3.5	实验验证与性能分析	44
3.5.1	测试环境	44
3.5.2	各核函数执行耗时	45

3.5.3 CPU 与 GPU 处理速度对比	45
3.5.4 PCR 样条插值精度验证	46
3.6 本章小结	47
第四章 基于双重注意力机制的 OCT 图像语义分割方法.....	48
4.1 DeepLabV3+ 基线模型.....	48
4.1.1 空洞卷积.....	48
4.1.2 ASPP 模块.....	49
4.1.3 编码器-解码器结构.....	49
4.2 TR 全局注意力模块设计	50
4.2.1 改进动机.....	50
4.2.2 TR 模块的整体结构.....	50
4.2.3 双层路由注意力机制	51
4.2.4 TR 模块与 BiFormer 的差异.....	52
4.2.5 混合损失函数	53
4.3 SAE 空间感知增强模块设计	54
4.3.1 改进动机.....	54
4.3.2 SAE 模块原理与结构	55
4.4 改进模型整体结构与协同机制.....	56
4.4.1 完整模型架构.....	56
4.4.2 各模块协同机制与前向传播流程.....	56
4.5 综合实验与分析.....	57
4.5.1 实验环境与参数配置	57
4.5.2 消融实验.....	57
4.5.3 与主流方法对比实验	59
4.5.4 可视化分析	59
4.5.5 效率分析.....	60
4.5.6 散斑强度鲁棒性对照实验	60
4.6 本章小结	61
第五章 总结与展望	62
5.1 总结	62
5.2 展望	63
参考文献.....	64
致谢	68
攻读硕士学位期间的研究成果	69

符号和缩略语说明

ASPP	空洞空间金字塔池化 (Atrous Spatial Pyramid Pooling)
BCE	二元交叉熵损失 (Binary Cross-Entropy Loss)
BRA	双层路由注意力 (Bi-level Routing Attention)
CBAM	卷积块注意力模块 (Convolutional Block Attention Module)
CNN	卷积神经网络 (Convolutional Neural Network)
CPE	卷积位置编码 (Convolutional Position Encoding)
CUDA	统一计算设备架构 (Compute Unified Device Architecture)
Dice	Dice 相似系数 (Dice Similarity Coefficient)
FCN	全卷积网络 (Fully Convolutional Network)
FFN	前馈网络 (Feed-Forward Network)
FFT	快速傅里叶变换 (Fast Fourier Transform)
FPS	每秒帧数 (Frames Per Second)
GAN	生成对抗网络 (Generative Adversarial Network)
GAP	全局平均池化 (Global Average Pooling)
GPU	图形处理器 (Graphics Processing Unit)
HD95	Hausdorff 距离 95% 分位数 (Hausdorff Distance at 95th Percentile)
IoU	交并比 (Intersection over Union)
LCE	局部上下文增强 (Local Context Enhancement)
mIoU	平均交并比 (Mean Intersection over Union)
OCT	光学相干层析成像 (Optical Coherence Tomography)
PCR	并行循环还原 (Parallel Cyclic Reduction)

ResNet	残差网络 (Residual Network)
SAE	空间感知增强 (Spatial Awareness Enhancement)
SD-OCT	谱域光学相干层析成像 (Spectral Domain OCT)
SE	挤压激励 (Squeeze-and-Excitation)
SS-OCT	扫频光学相干层析成像 (Swept Source OCT)
TD-OCT	时域光学相干层析成像 (Time Domain OCT)
TR	变换器路由 (Transformer Routing)
ViT	视觉变换器 (Vision Transformer)

第一章 绪论

1.1 研究背景及意义


随着现代工业制造向精密化、自动化方向发展，激光焊接技术凭借能量密度高、焊接速度快、热影响区小、易于实现自动化控制等特点，在汽车制造、航空航天、轨道交通、动力电池等高端装备制造领域得到了广泛应用^[1-3]。特别是在新能源汽车动力电池制造领域，激光焊接凭借其高精度、低热变形的优势，已成为电芯极耳焊接与模组连接的主流工艺。

在叠焊、深熔焊等典型工艺中，熔深（Penetration Depth）直接影响接头的有效连接面积与承载能力，是衡量焊接质量的关键指标之一^[1]。熔深过浅会导致接头强度不足，过深则可能引发烧穿、变形等缺陷。然而，激光焊接过程涉及光、机、电、热等多物理场耦合，具有明显的非线性与瞬态特性：匙孔（Keyhole）形态随功率密度、焊接速度、材料特性等参数快速变化，熔池表面受金属蒸汽反冲压力影响而剧烈波动，易产生气孔、未熔合、飞溅等缺陷^[1]。若仍依赖金相切片、超声检测等焊后离线检测手段，往往存在破坏性强、效率低、反馈滞后等问题，难以满足规模化生产的实时质检与闭环控制需求。因此，发展面向焊接过程的实时在线监测技术，实现熔深的稳定、精确获取，对提升焊接质量一致性、降低废品率、减少生产成本具有重要意义，是工业生产中的实际需求。


光学相干层析成像（Optical Coherence Tomography, OCT）是一种基于低相干干涉原理的层析成像技术，最初广泛应用于眼科等医学成像领域^[4]。OCT 技术具有非接触、微米级轴向分辨率、高速成像等特点，近年来逐步被引入工业检测与制造监控领域。在激光焊接场景中，OCT 可通过测量光束直接获取匙孔底部的反射信息，从而为熔深在线测量提供直接的几何依据，被认为是最具应用潜力的过程监测手段之一^[1]。相较于仅能反映表面辐射强度的光电监测方法、仅能获取二维表观信息的视觉监测方法，OCT 在表征匙孔深度结构方面可穿透焊接过程中的金属蒸汽与烟尘，直接测量匙孔的深度信息。

尽管 OCT 在焊接监测中展现出独特优势，但在实际工业应用中仍面临两类噪声干扰：焊接过程中的熔池波动、金属蒸汽与飞溅颗粒会遮挡或散射测量光束，降低信号稳定性^[1]；OCT 作为相干成像系统，固有的散斑噪声（Speckle Noise）以随机颗粒纹理形式降低图像信噪比^[4]。如图 1-1 所示，在上述条件下，OCT 图

像中的匙孔区域往往呈现对比度低、边界模糊、形态快速变化等特点。传统阈值分割、边缘检测或简单滤波方法（如中值滤波、百分位滤波）难以在噪声抑制与边界保持之间取得有效平衡，进而影响后续熔深估计的稳定性与精度^[1,4]。



(a) 原始 OCT 图像



(b) 标注图像

图 1-1 激光焊接 OCT 匙孔图像示例

针对上述挑战，本文研究面向焊接 OCT 图像的语义分割方法。语义分割作为计算机视觉的核心任务之一，旨在为图像中的每个像素赋予语义类别标签，能够实现对目标区域的精确提取与轮廓刻画。与传统图像处理流程相比，基于深度学习的语义分割模型可通过端到端学习自动提取更具判别性的语义特征与多

尺度上下文信息，在噪声干扰与弱边界条件下展现出更强的鲁棒性^[5-7]。本文以 DeepLabV3+ 为基线模型^[7]，面向焊接 OCT 图像中散斑噪声干扰严重、匙孔边界模糊、细长结构易断裂等问题，在编码器端增强全局上下文建模能力以提升对目标整体结构的感知，在解码器端强化局部边界细节表达以改善分割精细度，从而实现匙孔区域的高精度语义分割，为激光焊接熔深的稳定在线测量提供可靠的算法支撑^[1]。

1.2 国内外研究现状


本节分别从激光焊接过程监测技术、OCT 图像噪声处理方法、语义分割算法和图形处理器（Graphics Processing Unit, GPU）加速处理四个方面综述相关研究。

1.2.1 激光焊接过程监测技术现状

激光焊接过程监测技术经过数十年的发展，已形成多种技术路线并行发展的格局。根据信号来源与检测原理的不同，现有监测方法大体可分为基于光辐射/光谱的光电监测、基于可见光/红外成像的视觉监测、基于声发射/等离子体信号的声学监测、基于主动探测光束的层析成像监测，以及融合多源传感的综合监测等^[8-11]。图 1-2 展示了典型激光焊接过程监测系统的构成示意图。

（1）基于光辐射的光电监测方法。激光焊接过程中，熔池与匙孔区域会产生强烈的光辐射信号，光电监测方法正是利用这些辐射信号来反映焊接状态。高温计（Pyrometer）通过测量特定波段的热辐射强度来估计熔池/匙孔温度，具有结构简单、响应速度快等优点，被广泛用于焊接过程的温度监控与缺陷预警^[13]。光电二极管（Photodiode）可对焊接区域的反射光或等离子体辐射光进行高速采样，采样率可达数十 kHz 甚至 MHz 级别，能够捕捉焊接过程中的瞬态波动^[14]。光谱仪（Spectrometer）通过分析等离子体羽流的发射光谱，可获取元素成分与电子温度信息，为缺陷诊断提供依据。然而，光电监测方法的主要局限在于：其信号为单点测量，缺乏空间分辨信息；信号强度受匙孔开口状态、金属蒸汽遮挡、飞溅等因素影响显著，导致信号与熔深之间的映射关系复杂且可迁移性差。

（2）基于热成像的红外监测方法。红外热像仪（Infrared Thermal Camera）能够直观呈现焊接区域的温度场分布，可用于分析熔池形态、热影响区范围与温度

图 1-2 典型激光焊接过程监测系统示意图^[12]

梯度等信息。通过对红外图像的处理与分析，可以间接评估焊接质量与检测焊接缺陷。红外热像仪的局限在于空间分辨率有限、成本较高且需要复杂标定，且测量结果仅反映表面温度分布，无法获取匙孔深度信息。

（3）基于可见光成像的视觉监测方法。高速可见光相机可获取熔池/匙孔的高分辨率二维形态图像，通过图像处理算法提取熔池轮廓、匙孔开口面积、飞溅轨迹等特征参数^[15,16]。近年来，随着深度学习技术的发展，基于卷积神经网络的焊接图像分析方法也得到了广泛研究。视觉监测方法的优势在于分辨率高、信息丰富，但其主要局限包括：相机需要在强光环境下工作，对滤光片与曝光参数要求严格；图像仅能反映熔池表面的二维形态，无法直接测量匙孔深度；图像处理流程复杂，实时性受限。

（4）基于主动探测的层析成像方法。与上述被动式监测方法不同，基于主动探测光束的层析成像技术可直接获取焊接区域的深度结构信息。X 射线成像技术具有强大的穿透能力，可实时观察匙孔内部形态与熔池流动，是研究激光深熔焊物理机制的重要手段^[11]。然而，X 射线源设备体积庞大、成本高昂，且存在辐射安全隐患，难以在工业产线上大规模部署。光学相干层析成像（OCT）作为另一种主动探测技术，如第 1.1 节所述，具有微米级轴向分辨率、非接触、可穿透焊

接烟尘与金属蒸汽等特点，近年来受到学术界与工业界的广泛关注^[1,17,18]。OCT 可通过测量光束直接获取匙孔底部的反射信息，从而为熔深在线测量提供直接的几何依据^[19,20]。Kogel-Höllinger 等^[21]在 2025 年的工作中进一步利用 OCT 对激光焊接中的匙孔形态进行在线监测，验证了 OCT 在揭示匙孔轮廓快速变化与失稳模式方面的能力。

(5) 多传感器融合监测方法。单一传感器往往难以全面表征复杂的焊接过程，因此多传感器融合监测成为近年来的研究热点。通过综合利用光电信号、热成像、可见光图像与声发射信号等多源信息，并借助机器学习算法进行特征融合与决策，可以实现更全面、更可靠的焊接质量评估与缺陷检测^[9]。然而，多传感器融合系统存在成本高、集成复杂、实时性受限等问题，且不同传感器之间的时空配准与信息融合算法仍是研究难点。

表 1-1 总结了上述激光焊接过程光学检测技术的特点与局限性。综合比较可见，OCT 技术在直接测量匙孔深度结构方面具有独特优势，被认为是实现熔深在线测量与闭环控制的最具前景手段之一。然而，OCT 图像存在散斑噪声强、目标对比度低、边界模糊等特点，匙孔区域的稳定提取仍是待解决的技术问题。

表 1-1 激光焊接过程光学检测技术对比

检测技术	检测对象	优点	局限性
高温计	匙孔/熔池温度	结构简单、响应快	仅单点测量、无空间分辨信息
光电传感器	辐射/反射光强	采样率高、成本低	需复杂参数标定
光谱仪	等离子体成分	可诊断元素信息	信号解释复杂
红外热像仪	温度场分布	直观呈现温度场	分辨率低、成本高
可见光相机	熔池/匙孔形态	分辨率高、信息丰富	仅获取表面二维信息
X 射线成像	匙孔内部结构	穿透力强	辐射危害、设备昂贵
OCT	匙孔深度结构	微米分辨率、非接触	信号处理复杂

1.2.2 OCT 图像噪声特性及处理方法研究现状

光学相干层析成像（OCT）是一种基于低相干干涉原理的层析成像技术。其基本工作原理是：将宽带低相干光源发出的光束分为参考臂和样品臂，样品臂光束经过被测物体反射后与参考臂光束发生干涉，通过分析干涉信号的强度与相位变化，可重建被测物体沿轴向的结构信息^[4]。根据干涉信号的处理方式不同，OCT 系统可分为时域 OCT（TD-OCT）和频域 OCT（FD-OCT），后者具有更高的灵敏度与成像速度，是目前的主流技术路线。

然而，作为一种相干成像技术，OCT 固有地存在散斑噪声（Speckle Noise）问题。散斑噪声的产生机制主要包括：（1）相干叠加效应，来自样品内部不同散射体的反射光发生相干叠加，形成随机的干涉图样；（2）多次散射效应，光在非均匀介质中的多次散射导致光程差的随机变化；（3）系统噪声，探测器热噪声、光源波动等系统因素也会引入额外噪声^[4]。在 OCT 图像中，散斑噪声常表现为遍布图像的随机颗粒纹理，不仅降低了图像的信噪比与对比度，还会模糊组织/材料的边界结构，影响后续的定量分析与测量精度。研究表明，OCT 散斑噪声的统计特性与被测物体的微结构特征密切相关，其分布通常服从瑞利分布或更复杂的概率模型。

针对 OCT 图像的噪声抑制与质量增强问题，国内外研究者提出了多种处理方法，大体可分为以下几类：

（1）传统滤波与变换域方法。早期的 OCT 去噪研究多采用经典的图像滤波方法，如中值滤波、均值滤波、高斯滤波等。为克服简单滤波导致的边缘模糊问题，研究者引入了各向异性扩散滤波、双边滤波等边缘保持滤波器。在变换域方法中，小波变换去噪通过在不同尺度上分离信号与噪声来实现去噪；非局部均值（Non-Local Means, NLM）方法利用图像的自相似性进行去噪；BM3D（Block-Matching and 3D Filtering）算法将块匹配与协同滤波相结合，在多种图像去噪任务中取得了优异效果^[4]。这些方法在一定程度上可改善 OCT 图像的视觉质量，但在噪声抑制与边界保持之间往往难以取得理想平衡。

（2）硬件或多帧复合策略。从系统层面，研究者提出了多种基于硬件或采集策略的散斑抑制方法。多帧复合技术通过对同一位置采集多帧图像并进行平均或复合，利用散斑的随机性实现噪声平滑；角度复合技术通过多角度采集来降低散斑相关性；频率复合技术则利用宽带光源的不同频率成分进行复合^[4]。这些方

法可有效提升图像信噪比，但往往以牺牲成像速度或增加系统复杂度为代价，难以满足激光焊接过程监测对实时性的严格要求。

(3) 基于深度学习的去噪方法。近年来，深度学习技术在图像去噪领域取得了突破性进展。研究者将卷积神经网络 (Convolutional Neural Network, CNN)、残差学习、自编码器 (Autoencoder)、生成对抗网络 (Generative Adversarial Network, GAN) 等技术应用于 OCT 图像去噪，通过在大量数据上学习噪声分布与结构特征的映射关系，实现端到端的噪声去除与细节恢复。相比传统方法，深度学习去噪方法在处理复杂噪声分布与保持结构细节方面展现出更强的能力。针对配对训练数据获取困难的痛点，Liu 等^[22] 在 2025 年提出基于点扩散函数先验的自监督深度学习方法，无需配对干净/含噪图像即可完成实时 OCT 去卷积去噪，进一步降低了对标签数据的依赖。然而，这些方法通常需要大量配对的噪声/清洁图像进行监督训练，而在实际工业场景中获取高质量的“真实干净”标签往往十分困难。

上述去噪方法为改善 OCT 图像的可视化质量与测量精度提供了有效途径。然而，在激光焊接 OCT 匙孔分割这一特定任务中，存在以下制约：匙孔区域呈弱边界、细长深孔、形态快速变化等特点，单纯去噪可能导致边界过度平滑或几何形变；“先去噪再分割”的两阶段流程增加了系统复杂度，去噪阶段的误差也可能传播至后续分割环节。

基于上述分析，本文不将“去噪”作为独立的预处理步骤，而是将散斑噪声与工况干扰视为成像环境的固有组成部分，探索端到端的抗噪语义分割方法。核心思路是：通过在分割网络内部显式增强全局上下文建模能力与局部边界细节表达能力，使模型在噪声干扰条件下仍能稳定学习匙孔的语义结构与轮廓特征，从流程架构上减少对额外预处理的依赖，实现从原始 OCT 图像到匙孔语义掩膜的直接映射。

1.2.3 图像语义分割算法研究现状

图像语义分割旨在为输入图像的每个像素赋予语义类别标签，是计算机视觉领域的核心任务之一^[23]。从技术演进角度，深度学习语义分割方法大体经历了以下发展阶段：

(1) 基于全卷积网络的端到端分割。Long 等^[5] 提出全卷积网络 (Fully Con-

volutional Network, FCN), 首次将图像分类网络改造为逐像素预测结构, 奠定了深度语义分割的基础。在此基础上, SegNet^[24] 采用对称的编码器-解码器架构, 通过最大池化索引进行上采样, 在保持空间信息的同时降低了参数量; U-Net^[6] 引入跳跃连接融合多尺度特征, 在医学影像分割中取得优异效果。

(2) 多尺度上下文建模方法。为捕获不同感受野范围的上下文信息, Yu 等^[25] 提出空洞卷积 (Dilated/Atrous Convolution), 在不增加参数的情况下扩大感受野; DeepLab 系列^[7,26-28] 通过空洞空间金字塔池化 (ASPP) 融合多尺度特征, DeepLabV3+ 进一步结合编码器-解码器结构, 在精度与效率间取得平衡。在工业缺陷分割等垂直场景中, DeepLabV3+ 仍是 2025 年的主流改进基线之一: Wang 等^[29] 提出的 SME-DeepLabV3+ 在主干、局部注意力与多尺度注意力三个方向同时改造 DeepLabV3+, 在钢表面缺陷数据集上取得了显著提升, 与本文从编码端与解码端双向改进的思路同源。PSPNet^[30] 则采用金字塔池化模块聚合全局上下文。高分辨率网络 HRNet^[31] 在整个网络中保持高分辨率表示, 有效提升了边界与细节刻画能力。

(3) 注意力机制与 Transformer 方法。为建模长程依赖与突出关键区域特征, 注意力机制被广泛引入分割任务。挤压激励 (Squeeze-and-Excitation, SE) 模块^[32] 通过通道注意力重校准特征响应; 卷积块注意力模块 (Convolutional Block Attention Module, CBAM)^[33] 结合通道与空间注意力实现双维度特征增强; Non-local^[34] 通过自注意力机制捕获像素间的全局依赖关系; DANet^[35] 同时建模位置注意力与通道注意力以捕获全局依赖; CCNet^[36] 通过十字交叉注意力降低计算复杂度; ECA-Net^[37] 提出高效通道注意力模块以实现轻量化设计; Coordinate Attention^[38] 在轻量化约束下嵌入位置信息以增强空间感知能力。近年来, Vision Transformer^[39] 被引入视觉任务, Swin Transformer^[40] 通过移动窗口机制实现高效的层次化视觉表示; SETR^[41] 首次将纯 Transformer 架构用于语义分割; SegFormer^[42] 设计了高效的 Transformer 分割架构; Mask2Former^[43] 通过掩码注意力实现通用图像分割; TransUNet^[44] 等混合架构将 Transformer 与 CNN 结合, 在医学影像分割中展现出优异的全局建模能力。

(4) 实时与轻量化分割网络。面向工业在线检测等实时性要求较高的场景, BiSeNet V2^[45]、ICNet^[46]、Lite-HRNet^[47] 等轻量化网络通过双分支设计或特征金字塔策略在速度与精度间寻求平衡^[48]。

在 OCT 相关任务中，研究者多采用 U-Net/DeepLab 类结构进行视网膜层结构或病灶区域分割，也有工作引入注意力机制以提升边界与小目标刻画能力。近年来，深度学习方法也被应用于工业缺陷检测领域^[49,50]，Ma 等^[51]将深度置信网络应用于激光焊接孔隙区域的在线识别。然而，激光焊接 OCT 匙孔分割与常规医学 OCT 分割在数据分布与目标形态上存在差异：散斑噪声与工况扰动更强，匙孔区域呈细长结构且边界对比度低，易出现断裂与粘连。现有通用分割网络直接迁移时可能出现全局结构判断不足与局部边界细节丢失的问题，本文以 DeepLabV3+ 为基线，分别从全局上下文与局部细节两方面进行改进。

1.2.4 OCT 数据 GPU 加速处理研究现状

OCT 系统的采集速率持续提升——扫频 OCT 的 A 扫速率已从早期的几十 kHz 发展到 MHz 量级，谱域 OCT 也普遍达到 80–130 kHz^[4]。然而，从原始干涉谱到可显示深度图像的后处理流程（包括去直流、光谱整形、K 线性化插值、色差补偿、快速傅里叶变换（Fast Fourier Transform, FFT）及幅值提取等步骤）计算量大，CPU 串行处理的速度远跟不上采集速率，成为制约在线成像的瓶颈。

GPU 并行计算为解决这一矛盾提供了途径。Zhang 等人在 FX5800 GPU 上实现了 100k A-line/s 的谱域 OCT 处理速度^[52]；Rasakanthan 等人利用 GPU 页锁定内存优化数据传输，在 A 扫长度 1024 的条件下达到 524k A-line/s^[53]；Lyu 等人通过双 CUDA（Compute Unified Device Architecture）流减少传输等待，实现了 1024×1024 帧大小下 200 fps 的 B 扫实时处理^[54]。周金浩在 RTX2060 平台上设计了一体化的扫频 OCT（Swept Source OCT, SS-OCT）重建软件，对 1280×1024×1024 的三维谱域数据完成从采集到体绘制的全流程处理，耗时约 1.2 s，折合约 800k A-line/s^[55]。除桌面级 GPU 外，OCT 实时处理近年来开始向嵌入式/边缘端延伸：Chen 等^[56]在 2025 年的工作中以 NVIDIA Jetson Orin Nano 为计算平台，在 12 W 功耗约束下仍实现了超过 500 kHz 的 A-line 实时处理，为低成本、低功耗工业 OCT 部署提供了新的硬件路径。

在激光焊接 OCT 监测领域，GPU 加速面临与医学 OCT 不同的约束。焊接闭环控制要求毫秒级反馈频率，往往需要将单次处理的 B 扫宽度（A 扫条数）缩小以降低端到端延迟。赵金汉的研究发现，当 B 扫宽度从 1000 降至 100 时，内核启动、显式内存拷贝和全局同步等固定开销的占比急剧上升，实际吞吐量未能

线性增长。为此，赵金汉提出了基于 CUDA 统一内存的优化方案，消除主机与设备间的显式拷贝，配合事件驱动的轻量级同步，使 OCT 的 A 扫采集频率从 50 kHz 提升至 90 kHz^[57]。

上述工作表明，GPU 加速 OCT 后处理在医学成像领域已较为成熟，但针对激光焊接场景下高频闭环控制的需求，仍存在细粒度任务调度优化和插值算法并行化等未充分解决的问题。本文第三章将围绕自研谱域 OCT (Spectral Domain OCT, SD-OCT) 系统的后处理流水线，设计全流程 CUDA 并行化方案，并在 K 线性化步骤中引入 PCR 并行算法求解三次样条的三对角方程组，同时对统一内存方案在本系统上的适用性进行验证。

1.3 当前关键问题与研究内容

1.3.1 当前关键问题

通过对激光焊接过程监测技术、OCT 图像噪声处理方法及语义分割算法的研究现状分析可知，基于深度学习的语义分割方法能够为 OCT 图像中匙孔区域的精确提取提供有效的技术途径。然而，将现有语义分割方法直接应用于激光焊接 OCT 图像时，仍面临以下关键问题：

(1) 散斑噪声与工况干扰导致特征表示不稳定。OCT 作为相干成像系统固有地存在散斑噪声，加之激光焊接过程中金属蒸汽、飞溅颗粒的遮挡与干扰，导致图像中存在大量随机噪声纹理与伪影。这些干扰因素使得网络难以学习到稳定、可靠的目标特征表示，影响分割结果的一致性与可重复性。传统的“先去噪再分割”流程虽可在一定程度上改善图像质量，但可能导致边界信息损失，且增加了系统复杂度与推理延迟。

(2) 匙孔区域呈细长结构且边界对比度低，全局语义理解不足。激光焊接 OCT 图像中的匙孔区域通常呈现细长的深孔形态，其宽度可能仅有数十像素，而深度可达数百像素。同时，匙孔边界与周围背景的灰度差异较小，对比度低。现有的卷积神经网络受限于局部感受野，难以有效捕获匙孔的整体结构特征与长程空间依赖关系，容易出现对匙孔整体形态判断不准确、目标区域识别不完整等问题。

(3) 细长目标边界易出现断裂与粘连，局部细节刻画能力不足。在下采样与上采样过程中，细长结构的边界信息容易丢失或模糊。特别是在匙孔较窄区域或

边界模糊区域，分割结果往往出现边界断裂、目标粘连、轮廓不连续等问题。这对于后续的熔深精确测量会产生直接影响，要求分割模型具备更强的边界感知与细节刻画能力。

基于上述关键问题的分析，本文选择在 DeepLabV3+ 编码器—解码器框架的基础上，分别从全局上下文建模与局部边界细节增强两个维度进行针对性改进，以实现激光焊接 OCT 图像中匙孔区域的高精度、鲁棒语义分割。

1.3.2 本文主要研究内容

针对激光焊接 OCT 图像的在线重建与熔深自动提取两大需求，本文围绕“GPU 加速后处理——数据集构建——分割模型改进——实验验证”四个方面开展研究。主要内容如下：

(1) 基于 CUDA 的 OCT 图像加速重建算法设计。将 SD-OCT 系统的全部后处理步骤（类型转换、光谱整形、背景扣除、K 线性化、色差补偿、FFT、幅值提取、帧合并）移植到 GPU 上并行执行。在 K 线性化步骤中引入 PCR（Parallel Cyclic Reduction）并行算法求解三次样条的三对角方程组，消除传统 Thomas 串行算法的线程空等问题。针对细粒度 B 扫场景下固定开销占比上升的问题，引入统一内存与事件驱动优化方案并进行验证。

(2) 构建面向激光焊接匙孔检测的 OCT 图像语义分割数据集。在真实激光焊接实验平台上采集原始 OCT 成像数据，涵盖多种功率、速度参数组合下的匙孔形态变化；制定统一的标注规范，完成像素级精细标注，为模型训练与评估提供数据基础。

(3) 设计基于双重注意力机制的改进 DeepLabV3+ 网络。在编码器端设计 TR（Transformer Routing）全局注意力模块，通过双层路由注意力建立长距离依赖^[58]，解决细长结构断裂分割问题；在解码器端设计 SAE（Spatial Awareness Enhancement）空间感知增强模块，通过坐标注意力显式编码空间位置信息^[32,38]，提升边界分割精度。两模块形成“编码重结构、解码重细节”的互补架构。同时设计二元交叉熵（Binary Cross-Entropy, BCE）与 Dice 混合损失函数缓解类别不平衡问题。

(4) 进行系统的实验验证与对比分析。在自建数据集上与 U-Net^[6]、DeepLabV3+^[7]、TransUNet^[44] 等主流方法对比，通过消融实验验证各模块贡献，结合可视化分析

和效率分析评估方法的有效性。

1.4 论文组织结构

本文共分为五章，各章节安排如下：

第一章：绪论。阐述研究背景及意义，综述激光焊接监测技术、OCT 图像处理方法、GPU 加速 OCT 后处理及语义分割算法的研究现状，指出现有研究的不足，明确本文的研究目标与内容。

第二章：相关理论与技术基础。介绍 OCT 成像原理（时域 OCT 与频域 OCT 的工作机制）、CUDA 并行计算基础（编程模型、线程层次、内存层次）、深度学习与语义分割理论（卷积神经网络、编码器-解码器架构、注意力机制、DeepLab 系列方法）、评价指标，以及焊接 OCT 图像数据集的构建过程。

第三章：基于 CUDA 的 OCT 图像加速重建算法设计。分析 SD-OCT 后处理流水线的计算瓶颈，设计 8 个 CUDA 核函数实现全流程并行化，重点介绍 K 线性化步骤中 PCR 并行三次样条插值算法的设计与实现。讨论 GPU 内存层次利用策略，引入统一内存与事件驱动方案优化细粒度 B 扫场景下的吞吐量，并给出性能测试结果。

第四章：基于双重注意力机制的 OCT 图像语义分割方法。以 DeepLabV3+ 为基线，在编码器端设计 TR 全局注意力模块建立长距离依赖，在解码器端设计 SAE 空间感知增强模块提升边界精度，配合 BCE+Dice 混合损失函数。通过消融实验、对比实验、可视化分析和效率分析验证双重注意力机制的协同效应。

第五章：总结与展望。总结全文在 GPU 加速重建和语义分割两个方向的工作，分析局限性并讨论后续改进方向。

第二章 相关理论与技术基础

本章介绍本文研究所需的相关理论与技术基础，主要包括 OCT 成像原理、深度学习基础、语义分割理论基础以及评价指标等内容，为后续章节的方法设计与实验分析提供理论支撑。

2.1 OCT 成像原理

光学相干层析成像（Optical Coherence Tomography, OCT）是一种基于低相干干涉原理的高分辨率、非侵入性层析成像技术^[59]。该技术最早由 Huang 等人于 1991 年提出^[59]，通过检测参考光束与样品后向散射光之间的干涉信息，实现对生物组织或材料结构的微米级断层成像。OCT 技术无需外源造影剂或样品切片处理，即可实现高分辨率实时成像，在生物医学和工业检测领域均有应用^[4]。

2.1.1 OCT 成像基本原理

OCT 成像系统基于低相干干涉原理，其核心结构为迈克尔逊干涉仪。系统主要由宽带光源、光纤耦合器、参考臂、样品臂、光电探测器等关键组件构成。宽带光源发出的光经光纤耦合器被分成两束：一束进入参考臂，射向可沿光轴移动的反射镜；另一束进入样品臂，在样品不同深度产生背散射光。这些背散射光和经参考镜反射的参考光在光纤耦合器处发生干涉，被探测器接收。通过分析干涉信号的强度和时延，即可重建样品的深度结构信息^[1]。

光波发生低相干干涉需要满足以下条件：光波相位差恒定、振动频率相同和振动方向一致。在 OCT 系统中，参考臂与样品臂的光程差决定了干涉信号的强度。当光程差小于光源的相干长度时，才能发生有效干涉；当光程差为零时，系统可获得最大干涉强度。OCT 系统的轴向分辨能力主要取决于光源的相干特性，其理论极限值约为相干长度的一半，该特性使得 OCT 技术能够实现微米级的纵向分辨^[4]。

从数学角度分析，设宽带光源对应的电场 E_i 可表示为：

$$E_i = S(k)e^{i(kz - \omega t)} \quad (2-1)$$

其中， $S(k)$ 为电场的振幅， k 为波数， z 为光程， ω 为角频率。电场的振幅 $S(k)$

可进一步表示为高斯型函数：

$$S(k) = \frac{1}{\Delta k \sqrt{\pi}} e^{-\frac{(k-k_0)^2}{\Delta k^2}} \quad (2-2)$$

其中， k_0 为中心波长 λ_0 的波数， Δk 为频谱带宽。

设参考臂反射光场为 E_R ，样品臂反射光场为 E_S ，则单一波长的光谱干涉信号 $I_D(k)$ 可表示为：

$$I_D(k) \approx |E_R|^2 + |E_S|^2 + 2r_R r_S S(k) \cos[2k(z_R - z_S)] \quad (2-3)$$

其中， r_R 和 r_S 分别为参考臂和样品臂的光束反射率， z_R 和 z_S 分别为参考臂和样品臂的光程长度。干涉信号由直流项和交叉干涉项组成，交叉干涉项包含了样品的深度信息。对 $I_D(k)$ 进行快速傅里叶变换即可得到相应的深度信息，从而重建样品的层析结构^[1]。

2.1.2 OCT 技术分类

根据不同的成像原理和数据采集方式，OCT 技术主要分为时域 OCT（Time Domain OCT, TD-OCT）和频域 OCT（Fourier Domain OCT, FD-OCT）两大类^[4,60]。

时域 OCT 是最早提出的 OCT 技术，通过机械扫描参考臂的延时调制，逐点扫描获得不同深度处的反射信号。时域 OCT 的成像过程包括两个步骤：一是通过参考臂的移动实现深度扫描，从干涉信号中提取样品的深度结构；二是结合横向扫描，构建二维或三维层析图像。时域 OCT 通过调节参考臂的扫描范围来灵活设定测量深度，但由于其深度信息依赖机械扫描，导致扫描时间较长、成像速度较慢，并容易受到扫描噪声干扰^[4]。

频域 OCT 通过获取完整的光谱干涉信号，并利用傅里叶变换重建深度信息，避免了机械扫描的需求，提高了成像速度。频域 OCT 根据光源和探测方式的差异，又可分为谱域 OCT（Spectral Domain OCT, SD-OCT）和扫频 OCT（Swept Source OCT, SS-OCT）。谱域 OCT 使用宽带光源和光谱仪，在空间域中分离干涉光并获取干涉光谱；扫频 OCT 采用宽带扫频光源和高速光电探测器，通过扫频光源在时间域内依次发射不同波长的光，并利用光电探测器在时间域中分离干涉光谱。相比谱域 OCT，扫频 OCT 在信噪比、探测灵敏度和系统分辨率方面具有更高的潜力，尤其适用于高分辨率和大视场成像^[1]。

2.1.3 OCT 在激光焊接中的应用

在激光焊接场景中，OCT 技术通过测量光束获取匙孔（Keyhole）底部反射信息，从而为熔深在线测量提供直接的几何依据^[1]。相较于仅能反映表面辐射或二维表观信息的视觉/光电监测方法，OCT 在表征深度结构方面更具优势。激光焊接区域的反射散射光与参考臂的镜面反射光之间相位差并不恒定，因此激光加工区域的散射光与参考臂的反射光不会发生干涉，谱域 OCT 成像系统几乎不受激光加工光束的反射散射光影响，这使得 OCT 技术在激光焊接过程监测中具有独特的应用优势^[1]。

2.1.4 OCT 图像特点与分割算法设计的关联

尽管 OCT 具备高分辨率、非侵入性等优势，但在实际应用中仍面临信号不稳定与噪声干扰等挑战。理解 OCT 图像的噪声特性是设计分割算法的前提。

（1）散斑噪声的物理成因与统计特性。

OCT 成像基于低相干干涉原理，散斑噪声是相干成像系统固有的噪声类型。其产生机制主要包括三个方面：① 相干叠加效应：来自样品内部不同深度和位置的散射体产生的反射光在探测器处发生相干叠加，由于各散射体的反射相位随机分布，导致干涉信号的强度呈现随机波动；② 多次散射效应：光在非均匀介质（如焊接熔池）中的多次散射导致光程差的随机变化，进一步加剧了相位随机性；③ 系统噪声：探测器热噪声、光源强度波动等系统因素也会引入额外的噪声分量^[4]。

2.2 CUDA 并行计算基础

第三章将使用 CUDA 技术对 OCT 后处理算法进行 GPU 加速。本节简要介绍 CUDA 的编程模型、线程组织方式和存储层次，为后续核函数设计提供背景知识。

2.2.1 编程模型

CUDA（Compute Unified Device Architecture）是 NVIDIA 提供的面向 GPU 的并行计算编程框架。在 CUDA 编程模型中，CPU（主机端）负责程序流程控制 and 数据准备，GPU（设备端）负责大规模并行计算。主机端通过 PCIe 总线向设

备端传输数据，并启动核函数（Kernel）在 GPU 上执行。核函数由大量线程并行执行，每个线程独立处理一份数据。

一次典型的 GPU 计算流程包括：在设备端分配显存（`cudaMalloc`）、将输入数据从主机内存拷贝到显存（`cudaMemcpy`, Host to Device）、启动核函数执行并行计算、将计算结果从显存拷回主机内存（`cudaMemcpy`, Device to Host）、释放显存（`cudaFree`）。

2.2.2 线程组织

CUDA 将线程组织为两级层次结构：线程块（Block）和网格（Grid）。一个核函数启动时，指定网格中包含多少个线程块、每个线程块包含多少个线程。线程块内的线程可以通过共享内存通信并进行同步（`__syncthreads()`），不同线程块之间相互独立。

线程块和网格均支持一维、二维或三维的索引方式。每个线程通过内置变量 `threadIdx`（块内索引）、`blockIdx`（块索引）和 `blockDim`（块尺寸）计算自己的全局索引，从而确定负责处理的数据元素。例如，对于一维线程映射，全局索引 $idx = blockIdx.x \times blockDim.x + threadIdx.x$ 。

在 GPU 硬件层面，线程以 32 个为一组构成线程束（Warp），同一 Warp 中的线程执行相同的指令。流式多处理器（Streaming Multiprocessor, SM）负责调度和执行 Warp，当一个 Warp 因访存等待而阻塞时，SM 可切换到另一个就绪的 Warp 继续执行，从而掩盖访存延迟。SM 的 Warp 占用率（Occupancy）是衡量 GPU 利用效率的重要指标。

2.2.3 存储层次

GPU 提供了多级存储层次，从快到慢依次为寄存器、共享内存、常量内存、纹理/只读缓存和全局内存。不同层次的容量、延迟和访问权限差异如表 2-1 所示。

合理利用存储层次是 CUDA 优化的关键。将频繁访问的只读数据放入常量内存或只读缓存，将线程块内需要共享和同步的中间数据放入共享内存，可以大幅降低全局内存访问的延迟瓶颈。第三章的 PCR 样条插值核函数综合利用了常量内存（插值节点）、共享内存（三对角系数迭代）和只读缓存（信号值读取）三

表 2-1 CUDA 存储层次

存储类型	作用域	延迟（相对）	典型用途
寄存器	单线程	1×	局部变量
共享内存	线程块	~5×	块内数据共享与同步
常量内存	全局只读	~5×（缓存命中）	广播读取的常数表
全局内存	全局读写	~100×	输入输出缓冲区

级存储。

2.3 深度学习基础

深度学习作为机器学习的重要分支，通过构建具有多个隐藏层的神经网络，能够自动学习数据的层次化特征表示^[61]。在图像处理领域，卷积神经网络（Convolutional Neural Network, CNN）凭借其强大的特征提取能力，已成为语义分割等视觉任务的主流方法。本节介绍深度学习的基础理论，包括卷积神经网络、编码器-解码器架构以及注意力机制等核心概念。

2.3.1 卷积神经网络基础


卷积神经网络是一种专门用于处理具有网格结构数据（如图像）的深度学习模型。CNN 的核心思想是通过局部连接、权值共享和池化操作，有效减少参数量并提取平移不变的特征。近年来，轻量化网络设计如 MobileNetV3^[62] 通过神经架构搜索实现了高效的移动端部署。

（1）卷积层：卷积层是 CNN 的基本组成单元，通过卷积核（滤波器）在输入特征图上滑动，计算局部区域的加权和。设输入特征图为 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ ，卷积核为 $\mathbf{K} \in \mathbb{R}^{k \times k \times C}$ ，则卷积操作可表示为：


$$Y_{i,j} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} \sum_{c=0}^{C-1} X_{i+m,j+n,c} \cdot K_{m,n,c} + b \quad (2-4)$$

其中， $Y_{i,j}$ 为输出特征图在位置 (i,j) 的值， b 为偏置项。卷积操作具有局部连接和权值共享的特性，能够有效提取图像的局部特征（如边缘、纹理等），同时大幅减少参数量。如图 2-1 所示，卷积核在输入特征图上滑动，计算每个局部区域的加权和，生成输出特征图。

（2）池化层：池化层通过下采样操作降低特征图的空间分辨率，减少计算量

图 2-1 卷积运算示意图^[63]

并增强特征的平移不变性。常用的池化操作包括最大池化（Max Pooling）和平均池化（Average Pooling），如图 2-2 所示。最大池化选择局部区域内的最大值，能够保留显著特征；平均池化计算局部区域的平均值，能够平滑特征响应。

图 2-2 池化运算示意图^[64]

（3）激活函数：激活函数为网络引入非线性，使网络能够学习复杂的非线性映射关系。常用的激活函数包括：① ReLU（Rectified Linear Unit）， $f(x) = \max(0, x)$ ，具有计算简单、梯度稳定等优点，是目前最常用的激活函数；② Sigmoid， $f(x) = \frac{1}{1+e^{-x}}$ ，输出范围在 $(0, 1)$ 之间，常用于二分类任务的输出层；③ Softmax， $f(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$ ，将输入向量归一化为概率分布，常用于多分类任务的输出层。

(4) 批归一化：批归一化（Batch Normalization, BN）通过在训练过程中对每个批次的数据进行归一化，能够加速网络训练、提高模型稳定性并允许使用更大的学习率^[65]。批归一化的操作可表示为：

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, \quad y_i = \gamma \hat{x}_i + \beta \quad (2-5)$$

其中， μ_B 和 σ_B^2 分别为批次数据的均值和方差， γ 和 β 为可学习的缩放和偏移参数， ϵ 为小常数以防止除零。

(5) 残差连接：残差连接（Residual Connection）通过将输入直接传递到输出，解决了深层网络的梯度消失问题，使得训练更深的网络成为可能^[66]。残差块的结构可表示为：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\}) + \mathbf{x} \quad (2-6)$$

其中， $\mathcal{F}(\mathbf{x}, \{\mathbf{W}_i\})$ 为残差映射， $\mathbf{x}$ 为恒等映射。残差连接使得网络能够学习残差而非完整的映射，从而简化了优化过程。ResNet 通过引入残差连接，成功训练了包含数百层的深层网络，在图像分类、目标检测等任务中验证了其有效性^[66]。

(6) ResNet 骨干网络：ResNet（Residual Network）系列网络是深度学习领域最具影响力的骨干网络之一，广泛应用于图像分类、目标检测和语义分割等任务。ResNet 系列包括 ResNet-18、ResNet-34、ResNet-50、ResNet-101 和 ResNet-152 等不同深度的变体，其中 ResNet-50 和 ResNet-101 在精度与效率之间取得了良好平衡，是语义分割任务中常用的编码器骨干网络^[66]。

在 DeepLabV3+ 架构中，编码器通常采用在 ImageNet 数据集上预训练的 ResNet-50 或 ResNet-101 作为骨干网络。预训练的权重使网络能够利用在大规模数据集上学习到的通用视觉特征，加速收敛并提升在小样本数据集上的泛化能力。ResNet 的多阶段（Stage）结构输出不同分辨率的特征图，低层特征保留丰富的空间细节信息，高层特征包含更强的语义信息。DeepLabV3+ 通过融合 ResNet 编码器的低层特征和高层语义特征，实现了细节与语义的有效结合。

2.3.2 编码器-解码器架构

编码器-解码器（Encoder-Decoder）架构是语义分割任务中常用的网络结构，通过编码器提取多尺度特征，解码器恢复空间分辨率并输出像素级预测结果^[6]。

(1) 编码器：编码器通常采用预训练的 CNN 骨干网络（如 ResNet、VGG 等），

通过逐层卷积和下采样操作，将输入图像转换为高维特征表示。编码过程逐步降低特征图的空间分辨率，同时增加通道数，提取从低级到高级的语义特征。例如，ResNet 编码器通常包含多个阶段（Stage），每个阶段通过卷积和下采样操作，将特征图尺寸减半、通道数加倍，最终得到高维的语义特征表示。

（2）解码器：解码器通过上采样和特征融合操作，逐步恢复特征图的空间分辨率，并输出与输入图像尺寸相同的预测结果。上采样操作通常采用双线性插值、转置卷积或亚像素卷积^[67]实现。解码器还通过跳跃连接（Skip Connection）融合编码器不同阶段的特征，结合低层细节信息和高层语义信息，提升分割精度。

（3）跳跃连接：跳跃连接将编码器的中间特征直接传递到解码器的对应层，使得解码器能够利用编码器提取的多尺度特征。U-Net 架构通过 U 形的跳跃连接，将编码器的特征图与解码器对应层的特征图进行拼接，有效融合了细节信息和语义信息，在医学图像分割等任务中取得了优异性能^[6]。

2.3.3 注意力机制基础

注意力机制通过动态分配不同权重，使网络能够关注输入数据中的重要部分，从而提升模型的表达能力。在计算机视觉任务中，注意力机制主要包括自注意力、空间注意力和通道注意力等类型。

（1）自注意力机制：自注意力（Self-Attention）机制通过计算特征图中不同位置之间的相关性，建立长距离依赖关系^[68]。自注意力的计算过程可表示为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax} \left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \right) \mathbf{V} \quad (2-7)$$

其中， $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ 分别为查询（Query）、键（Key）和值（Value）矩阵， d_k 为键向量的维度。自注意力机制能够捕获特征图中任意两个位置之间的依赖关系，不受空间距离限制，在长距离依赖建模方面具有优势。

（2）Transformer 架构：Transformer 架构完全基于自注意力机制，摒弃了传统的卷积和循环结构，通过多头自注意力和前馈网络构建深层网络^[68]。Vision Transformer（ViT）将 Transformer 架构应用于图像分类任务，将图像分割为固定大小的图像块（Patch），并将每个图像块视为一个序列元素，通过自注意力机制建模图像块之间的关系^[39]。Transformer 架构在图像分割任务中也得到了广泛应用，通过增强长距离依赖建模能力，提升了分割性能。

(3) 空间注意力与通道注意力：空间注意力关注特征图的空间位置信息，通过生成空间权重图，突出重要的空间区域；通道注意力关注特征图的通道维度，通过生成通道权重向量，突出重要的特征通道。空间注意力和通道注意力可以单独使用，也可以组合使用，通过空间和通道维度的双重增强，提升特征的判别能力。本文后续章节提出的 SAE 模块即结合了空间注意力和通道注意力，用于增强局部细节和边界信息。

2.4 语义分割理论基础

语义分割是计算机视觉中的一项重要任务，旨在对图像中的每个像素进行分类，为每个像素分配一个语义类别标签。与图像分类和目标检测不同，语义分割需要在像素级别进行预测，要求模型同时具备强大的特征提取能力和精确的空间定位能力。本节介绍语义分割的发展历程和关键技术，包括全卷积网络、U-Net 架构以及 DeepLab 系列方法。

2.4.1 全卷积网络


全卷积网络（Fully Convolutional Networks, FCN）是首个将深度卷积神经网络成功应用于语义分割任务的方法^[5]。FCN 的核心思想是将传统 CNN 中的全连接层替换为卷积层，使得网络能够接受任意尺寸的输入图像，并输出与输入尺寸相同的分割结果。

FCN 通过将预训练的分类网络（如 VGG、ResNet）转换为全卷积结构，利用卷积层的平移不变性，实现了端到端的像素级预测。FCN 还引入了跳跃连接机制，通过融合不同尺度的特征图，结合浅层的细节信息和深层的语义信息，提升了分割精度。FCN 的网络结构如图 2-3 所示，其提出标志着深度学习在语义分割领域的成功应用，为后续研究奠定了基础^[5]。


2.4.2 U-Net 架构

U-Net 是一种经典的编码器-解码器架构，最初设计用于医学图像分割任务^[6]。U-Net 采用对称的 U 形结构，编码器通过卷积和下采样逐步提取特征，解码器通过上采样和卷积逐步恢复分辨率。

U-Net 的关键创新在于其密集的跳跃连接设计：编码器每一层的特征图都与

图 2-3 FCN 网络结构图^[5]

解码器对应层的特征图进行拼接，使得解码器能够充分利用编码器提取的多尺度特征。这种设计使得 U-Net 在保持高分辨率细节的同时，能够利用深层的语义信息，在医学图像分割等需要精确边界定位的任务中表现出色。U-Net 的网络结构如图 2-4 所示，其成功也启发了后续许多编码器-解码器架构的设计^[6]。

图 2-4 U-Net 网络结构图^[6]

2.4.3 U-Net 变体网络

U-Net 架构的成功激发了众多变体网络的研究，其中 UNet++ 和 ResUNet 是两种具有代表性的改进方案，本文实验中将其作为对比方法进行评估。

(1) UNet++: UNet++ 由 Zhou 等人于 2018 年提出，通过嵌套的密集跳跃连接重新设计了编码器与解码器之间的连接方式^[69]。与传统 U-Net 的单一跳跃连接不同，UNet++ 在编码器和解码器之间引入了多层嵌套的卷积块，形成密集的特征传播路径。这种设计使得解码器能够接收来自不同语义层次的特征图，有效缓解了编码器与解码器之间的语义鸿沟（Semantic Gap）问题。UNet++ 的嵌套结构还支持深度监督训练，可以在不同深度的输出层添加监督信号，提升模型的收敛性能。然而，密集连接设计也带来了更高的内存占用和计算开销。

(2) ResUNet: ResUNet 将残差学习机制引入 U-Net 架构，通过在编码器和解码器的卷积块中添加残差连接，有效缓解了深层网络的梯度消失问题^[70]。ResUNet 的残差块结构使得网络能够学习输入与输出之间的残差映射，简化了优化过程。此外，ResUNet 通常采用预训练的 ResNet 作为编码器骨干网络，利用在大规模数据集（如 ImageNet）上学习到的特征表示，提升了模型在小样本数据集上的泛化能力。ResUNet 在医学图像分割、遥感图像分析等领域得到了广泛应用。

2.4.4 DeepLab 系列方法

DeepLab 系列方法通过引入空洞卷积和空间金字塔池化等技术，在语义分割任务上取得了持续改进。

(1) DeepLabV1: DeepLabV1 首次将空洞卷积（Atrous Convolution）引入语义分割任务^[26]。空洞卷积通过在卷积核中插入零值，在不增加参数量的情况下扩大感受野，使得网络能够在保持特征图分辨率的同时捕获更大范围的上下文信息。空洞卷积的数学表达可写为：

$$y[i] = \sum_k x[i + r \cdot k] \cdot w[k] \quad (2-8)$$

其中， r 为空洞率（dilation rate），控制感受野的大小。当 $r = 1$ 时，空洞卷积退化为标准卷积；当 $r > 1$ 时，空洞卷积能够在不增加参数量的情况下扩大感受野。

(2) DeepLabV2: DeepLabV2 在 DeepLabV1 的基础上引入了空间金字塔池

化（Atrous Spatial Pyramid Pooling, ASPP）模块^[27]。ASPP 模块通过并行使用多个不同空洞率的空洞卷积，在不同尺度上捕获上下文信息，然后将多尺度特征进行融合。ASPP 模块的设计使得网络能够同时关注局部细节和全局上下文，提升了分割性能。

（3）DeepLabV3：DeepLabV3 对 ASPP 模块进行了改进，引入了全局平均池化分支，并优化了空洞率的选择策略^[28]。改进后的 ASPP 模块包含多个并行分支：不同空洞率的空洞卷积分支用于捕获多尺度上下文信息，全局平均池化分支用于捕获全局上下文信息。这些分支的特征经过拼接和融合，形成丰富的多尺度特征表示。

（4）DeepLabV3+：DeepLabV3+ 在 DeepLabV3 的基础上引入了编码器-解码器结构^[7]。DeepLabV3+ 采用 DeepLabV3 的输出作为编码器特征，通过解码器逐步上采样并融合编码器的中间特征，最终输出高分辨率的分割结果。DeepLabV3+ 的解码器设计简洁高效，通过融合低层细节信息和高层语义信息，在保持分割精度的同时提升了边界定位的准确性。DeepLabV3+ 的网络结构如图 2-5 所示，其是本文方法的基础框架。本文第四章将详细介绍 DeepLabV3+ 的具体实现细节，包括空洞卷积的配置参数、ASPP 模块的分支设计以及编码器-解码器的特征融合方式，并在此基础上提出针对性改进。




图 2-5 DeepLabV3+ 网络结构图^[7]

2.4.5 多尺度特征融合策略

多尺度特征融合是语义分割中的关键技术，旨在结合不同尺度的特征信息，提升模型对不同大小目标的处理能力。除了 ASPP 模块外，特征金字塔网络（Feature Pyramid Network, FPN）也是一种重要的多尺度特征融合方法^[71]。

FPN 通过构建特征金字塔，在不同尺度上提取特征，并通过自上而下的路径和横向连接融合多尺度特征。FPN 的设计使得网络能够在不同尺度上检测目标，提升了模型对多尺度目标的处理能力。虽然 FPN 最初设计用于目标检测任务，但其多尺度特征融合的思想在语义分割任务中也得到了广泛应用。

近年来，Transformer 架构如 Swin Transformer^[40] 和 SegFormer^[42] 也被引入语义分割任务，通过自注意力机制增强长距离依赖建模能力。

TransUNet 是一种将 Transformer 与 U-Net 结合的混合架构，由 Chen 等人于 2021 年提出^[44]。TransUNet 的核心思想是利用 Transformer 的全局建模能力弥补纯卷积网络在长距离依赖捕获方面的不足。具体而言，TransUNet 首先使用 CNN（如 ResNet）提取图像的局部特征，然后将特征图划分为固定大小的图像块（Patch），通过线性投影将每个图像块嵌入为特征向量，输入 Transformer 编码器进行全局关系建模。Transformer 编码器输出的特征再通过级联上采样与 CNN 特征融合，最终由 U-Net 风格的解码器生成分割结果。

TransUNet 的优势在于能够同时利用 CNN 的局部特征提取能力和 Transformer 的全局上下文建模能力，在医学图像分割等需要精确边界定位和全局语义理解的任务中表现出色。然而，Transformer 架构的自注意力机制计算复杂度为 $O(n^2)$ （ n 为序列长度），导致 TransUNet 的参数量和内存占用较大。在本文的实验对比中，TransUNet 作为代表性的 Transformer 分割方法被纳入性能评估。

为了更清晰地对比上述经典语义分割方法的特点，表 2-2 总结了各方法的核心创新点与适用场景。

2.5 焊接 OCT 图像数据集构建

针对现有公开数据集缺乏激光焊接 OCT 图像数据的问题，本研究构建了面向焊接熔深分割的 OCT 图像数据集。本节详细介绍数据集的构建过程，包括图像采集、预处理、标注、数据增强以及数据集划分等步骤。

表 2-2 经典语义分割网络对比

方法	核心创新	优势	局限性
FCN	全卷积替代全连接	端到端像素预测	分辨率损失大
U-Net	对称编码器-解码器	精确边界恢复	感受野有限
UNet++	嵌套密集跳跃连接	缓解语义鸿沟	内存占用大
ResUNet	残差连接 + U-Net	缓解梯度消失	结构复杂度高
DeepLabV1	空洞卷积	保持分辨率扩大感受野	多尺度建模不足
DeepLabV2	ASPP 多尺度池化	多尺度上下文捕获	边界细节丢失
DeepLabV3	改进 ASPP + 全局池化	全局与局部结合	解码器简单
DeepLabV3+	编码器-解码器结构	细节与语义融合	计算量较大
TransUNet	Transformer + CNN 混合	长距离依赖建模	计算复杂度高

2.5.1 OCT 图像采集

本研究的实验数据来源于激光焊接 OCT 检测系统。该系统基于谱域 OCT 技术，通过第三章所述的 GPU 加速重建流水线将干涉谱数据转换为深度灰度图像。在焊接实验中，选用多种工业金属材料，通过调整焊接功率和焊接速度等工艺参数，采集了多组不同工况下的焊接 OCT 图像数据。

原始 OCT 图像的尺寸不固定，受采集系统参数和扫描范围的影响存在差异。为满足深度学习模型的输入要求，后续预处理过程将统一调整图像尺寸。本研究共采集了约 228 张原始 OCT 图像，涵盖多种焊接工况下的熔深变化情况。

2.5.2 图像预处理

原始 OCT 图像存在噪声干扰、对比度不足等问题，需要进行预处理以提升图像质量。本研究采用的预处理流程主要包括以下步骤：

(1) 图像裁剪：原始 OCT 图像包含较大的无效区域，为减少计算量并突出感兴趣区域（Region of Interest, ROI），首先对图像进行裁剪，去除边缘的无效信息，保留包含熔深信号的核心区域。

(2) 噪声抑制：OCT 图像中存在散斑噪声等干扰，本研究采用中值滤波方法进行去噪处理。中值滤波能够在保留边缘信息的同时有效抑制椒盐噪声和散斑噪声，滤波窗口大小设置为 3×3 。

(3) 对比度增强：为提高熔深区域与背景的区分度，采用直方图均衡化方法对图像进行对比度增强。增强后的图像熔深线段边界更加清晰，有利于后续的标注和分割。

(4) 尺寸调整：将预处理后的图像统一调整为 512×512 像素，采用双线性插值方法进行缩放，以满足深度学习模型的输入尺寸要求。

预处理前后的图像效果对比如图 2-6 所示，可以看出预处理后图像的噪声明显减少，熔深区域的对比度提升。

此外，在模型训练阶段，还需进行归一化处理：将图像像素值从 $[0, 255]$ 归一化到 $[0, 1]$ 范围，以加速模型收敛并提高训练稳定性。该操作在数据加载时在线进行，不改变保存的图像文件。



(a) 原始图像



(b) 预处理后图像

图 2-6 预处理效果对比

2.5.3 基于 LabelMe 的熔深线段标注

本研究采用基于 Python 语言开发的开源图像标注工具 LabelMe 进行语义分割标签的制作。与传统的图像处理软件相比，LabelMe 的主要优势在于操作便捷、效率较高，能够通过直观的用户界面精确完成图像标注任务。LabelMe 的标注界面如图 2-7 所示。

(1) 标注类别定义：本研究采用二分类语义分割策略，定义了以下两个标注类别：① 熔深线段 (Weld_Depth)，表示焊接熔池底部的深度轮廓区域，是本研




图 2-7 LabelMe 标注界面

究的主要分割目标；② 背景（Background），即除熔深线段外的所有区域，未标注区域自动作为背景处理。

（2）标注流程：在运用 LabelMe 软件开展图像手动标注工作时，具体操作流程如下：① 打开存有原始 OCT 图像的文件夹；② 在工具栏上点击“创建多边形”按钮；③ 沿熔深区域轮廓紧密绘制多边形，对图像中熔深线段的轮廓予以标注；④ 完成标注后，为每个轮廓选定对应的类别标签（Weld_Depth）；⑤ 将标注信息保存为 JSON 格式文件；⑥ 使用 LabelMe 提供的转换脚本（labelme_json_to_dataset）将 JSON 文件批量转换为 PNG 格式的掩码图像，供深度学习模型训练使用。

（3）标注质量控制：为确保标注质量，采用双人交叉验证的方式进行质量控制。首先由标注人员完成初始标注，随后由第二人进行检查和修正。对于存在争议的样本，由两人协商确定最终标注结果。完成标注后，还需仔细检查以下事项：图片名称是否准确、格式是否正确、标注是否完整，以及是否存在未标注的图像等情况。

标注样例如图 2-8 所示，展示了原始 OCT 图像与对应标注掩码的对比效果。

2.5.4 数据增强策略

由于原始标注图像数量有限（约 228 张），为扩充训练数据并提升模型的泛化能力，本研究对训练集进行了离线数据增强，通过对每张训练原图施加以下变换生成多份增强样本，最终将训练集从 182 张扩充至 912 张（扩充倍数约 5×），




图 2-8 标注样例展示

测试集保持 228 张不变，数据集总量扩充至 1140 张图像。

数据增强策略的具体配置如表 2-3 所示。

表 2-3 数据增强策略配置

增强类型	增强方法	参数设置
几何变换	随机水平翻转	概率 0.5
	随机垂直翻转	概率 0.5
	随机旋转	角度范围 $[-15^\circ, +15^\circ]$
	随机缩放	缩放比例 $[0.8, 1.2]$
光学变换	亮度调整	调整系数 $[0.8, 1.2]$
	对比度调整	调整系数 $[0.8, 1.2]$
	高斯噪声	概率 0.3，标准差 0.02

(1) 几何变换：包括随机水平翻转、随机垂直翻转、随机旋转和随机缩放等操作，用于增加数据的空间多样性，提升模型对不同方向和尺度目标的适应能力。

(2) 光学变换：包括亮度调整、对比度调整和高斯噪声添加等操作，用于模拟不同光照条件和噪声水平下的图像，增强模型对图像质量变化的鲁棒性。

数据增强的效果示例如图 2-9 所示。

2.5.5 数据集划分与统计

为科学评估模型性能，本研究将数据集按照 8:2 的比例划分为训练集和测试集。划分时遵循以下原则：(1) 时序连续性，来自同一焊接序列的图像不跨集划分，避免信息泄露；(2) 分布一致性，确保两个子集中不同工况下的样本比例基本一致；(3) 随机性，在满足上述约束的前提下，采用随机采样方式进行划分。验证集从训练集中动态划分，用于训练过程中的模型选择。




图 2-9 数据增强效果示例

与公开语义分割数据集如 Cityscapes^[72] 相比，本数据集规模较小，但针对焊接 OCT 图像的特定任务仍可满足训练需求。数据集的详细统计信息如表 2-4 所示。

表 2-4 焊接 OCT 图像数据集统计信息

数据集	原始图像数	增强后图像数	占比	图像尺寸
训练集	182	912	80%	512 × 512
测试集	46	228	20%	512 × 512
总计	228	1140	100%	—

训练集用于模型参数的学习与优化，训练过程中从训练集中划分出部分样本作为验证集，用于超参数调优和早停策略的判断；测试集仅在模型训练完成后进行最终性能评估，以确保评估结果的客观性。

由于熔深线段在图像中所占像素比例较小，数据集存在明显的类别不平衡问题。为缓解这一问题，本研究在损失函数设计中引入了 Dice 损失，以提升模型对小目标区域的分割精度，具体将在第四章进行详细介绍。

2.6 语义分割评价指标

为了客观评估语义分割模型的性能，需要采用合适的评价指标对预测结果进行定量分析。语义分割的评价指标通常基于混淆矩阵（Confusion Matrix）计算，通过比较预测结果与真实标签之间的差异，量化模型的分割精度。本节介绍常用

的语义分割评价指标及其计算方法。

2.6.1 混淆矩阵

混淆矩阵是评估分类模型性能的基础工具，用于统计预测结果与真实标签之间的对应关系。对于语义分割任务，混淆矩阵 C 是一个 $N \times N$ 的矩阵，其中 N 为类别数。矩阵元素 C_{ij} 表示真实类别为 i 、预测类别为 j 的像素数量。

基于混淆矩阵，可以计算多种评价指标。对于二分类任务（如本文的匙孔分割任务），混淆矩阵包含四个元素：真正例（True Positive, TP）、假正例（False Positive, FP）、真负例（True Negative, TN）和假负例（False Negative, FN）。

2.6.2 像素准确率与平均像素准确率

像素准确率（Pixel Accuracy, PA）是最直观的评价指标，表示正确分类的像素占总像素的比例：

$$PA = \frac{\sum_{i=0}^{N-1} C_{ii}}{\sum_{i=0}^{N-1} \sum_{j=0}^{N-1} C_{ij}} \quad (2-9)$$

其中， C_{ii} 为混淆矩阵对角线元素，表示正确分类的像素数；分母为总像素数。PA 的取值范围为 $[0, 1]$ ，值越大表示分割精度越高。PA 指标计算简单直观，适用于类别分布相对均衡的场景，但在类别不平衡的情况下（如背景像素远多于目标像素）可能产生误导性结果。

平均像素准确率（Mean Pixel Accuracy, mPA）通过计算每个类别的像素准确率并取平均，能够更好地反映模型对不同类别的分割性能：

$$mPA = \frac{1}{N} \sum_{i=0}^{N-1} \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}} \quad (2-10)$$

其中， $\frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij}}$ 表示类别 i 的像素准确率。mPA 对每个类别赋予相同的权重，能够更好地评估模型在类别不平衡情况下的性能。

2.6.3 交并比与平均交并比

交并比（Intersection over Union, IoU）是语义分割任务中最常用的评价指标之一，表示预测结果与真实标签的交集与并集的比值：

$$\text{IoU}_i = \frac{C_{ii}}{\sum_{j=0}^{N-1} C_{ij} + \sum_{j=0}^{N-1} C_{ji} - C_{ii}} \quad (2-11)$$

其中，分子 C_{ii} 为类别 i 的预测结果与真实标签的交集（正确预测的像素数），分母为两者的并集。IoU 指标能够同时考虑预测结果的准确性和完整性，对分割边界的精度更加敏感。对于二分类任务，IoU 的计算可简化为：

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (2-12)$$

平均交并比（Mean Intersection over Union, mIoU）通过计算所有类别 IoU 的平均值，综合评估模型的分割性能：

$$\text{mIoU} = \frac{1}{N} \sum_{i=0}^{N-1} \text{IoU}_i \quad (2-13)$$

mIoU 是语义分割任务中最常用的评价指标，能够综合反映模型对不同类别的分割性能。在类别不平衡的情况下，mIoU 比 PA 更能准确反映模型的真实性能。本文实验部分将 mIoU 作为主要评价指标，用于评估不同方法的分割性能。

2.6.4 Dice 系数

Dice 系数（Dice Coefficient）是医学图像分割中常用的评价指标，表示预测结果与真实标签的重叠程度：

$$\text{Dice}_i = \frac{2 \cdot C_{ii}}{2 \cdot C_{ii} + \sum_{j \neq i} C_{ij} + \sum_{j \neq i} C_{ji}} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}} \quad (2-14)$$

Dice 系数的取值范围为 $[0, 1]$ ，值越大表示重叠程度越高。对于二分类任务，Dice 系数与 IoU 之间存在以下关系：

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \quad (2-15)$$

Dice 系数对分割区域的完整性更加敏感，在医学图像分割等需要精确区域分割的任务中应用广泛。本文在损失函数设计中采用了 Dice 损失，用于处理类别不平衡问题。

2.6.5 Hausdorff 距离

Hausdorff 距离（Hausdorff Distance, HD）是衡量分割边界精度的重要指标，用于度量预测轮廓与真实轮廓之间的最大偏差。给定预测分割集合 A 与真实标注集合 B ，双向 Hausdorff 距离定义为：

$$H(A, B) = \max \left(\sup_{a \in A} \inf_{b \in B} \|a - b\|, \sup_{b \in B} \inf_{a \in A} \|a - b\| \right) \quad (2-16)$$

标准 Hausdorff 距离对离群点（如单个噪声预测像素）极为敏感，可能因局部误差而大幅增大。为此，实际评估中通常采用 Hausdorff 距离的 95% 分位数（HD95），即将两个集合互相最近邻距离的所有值排序后取第 95 百分位数，排除极端噪声点的影响：

$$\text{HD95}(A, B) = \max \left(P_{95} \left\{ \inf_{b \in B} \|a - b\| \right\}_{a \in A}, P_{95} \left\{ \inf_{a \in A} \|b - a\| \right\}_{b \in B} \right) \quad (2-17)$$

其中 $P_{95}\{\cdot\}$ 表示取集合的第 95 百分位数。HD95 值越小，表明预测边界与真实边界之间的最大误差越小，边界定位精度越高。本文实验部分将 HD95 作为评估边界分割质量的主要指标之一。

2.6.6 模型效率指标

除分割精度外，模型的计算效率也是评估语义分割方法的重要维度，尤其对于工业在线检测等对实时性有要求的应用场景。本文采用以下效率指标评估模型：

（1）参数量（Parameters, Params）：表示模型中可学习参数的总数，通常以百万（M）为单位。参数量反映了模型的复杂度和存储需求。参数量较大的模型通常具有更强的表达能力，但也带来更高的存储和计算开销。在实际部署中，需要根据硬件资源限制选择合适的模型规模。

在实际应用中，通常需要综合考虑分割精度和计算效率，在性能与速度之间取得平衡。本文实验部分将同时报告 mIoU、目标类别 IoU 和 Params 等指标，从

精度和效率两个维度全面评估所提方法的性能。

2.7 本章小结

本章介绍了本文研究所需的理论与技术基础。

在 OCT 成像方面，介绍了低相干干涉原理、时域 OCT 与频域 OCT 的工作机制，以及 OCT 在激光焊接匙孔检测中的应用。OCT 图像存在散斑噪声强、对比度低、边界模糊等特点，为后续章节的算法设计提供了问题背景。

在 GPU 并行计算方面，介绍了 CUDA 编程模型的主机-设备异构架构、线程块-网格的两级线程组织方式，以及寄存器、共享内存、常量内存、全局内存等多级存储层次。这些内容为第三章设计 CUDA 核函数和优化内存访问模式提供了技术基础。

在深度学习与语义分割方面，介绍了卷积神经网络的基本组件、编码器-解码器架构、注意力机制，以及从 FCN 到 DeepLabV3+ 的语义分割方法发展脉络。DeepLabV3+ 作为本文第四章的基线模型，在处理 OCT 图像时仍存在全局上下文建模不足和边界细节丢失的问题，这为 TR 模块和 SAE 模块的设计提供了动机。

此外，本章介绍了焊接 OCT 图像数据集的构建过程（采集、预处理、标注、增强、划分）和语义分割的评价指标体系（mIoU、平均准确率 mAcc、平均 Dice 系数 mDice、边界精度指标 HD95 等），为后续实验评估提供了数据基础和度量标准。

基于本章的理论准备，第三章将设计基于 CUDA 的 OCT 后处理加速方案，第四章将提出基于双重注意力机制的改进分割模型。

第三章 基于 CUDA 的 OCT 图像加速重建算法设计

SD-OCT 系统的原始干涉谱数据需经光谱整形、背景扣除、K 线性化、色差补偿、FFT 和幅值提取等步骤才能重建为深度图像。本文所使用系统的 A 扫采集频率为 82 kHz，CPU 端串行处理无法匹配这一速率。本章将全部后处理步骤移植到 GPU 上并行执行，重点解决三次样条 K 线性化中三对角方程组的并行求解问题，并针对细粒度 B 扫场景下的性能衰减提出统一内存优化方案。

3.1 OCT 后处理算法流程与计算瓶颈分析

3.1.1 后处理算法流程

本文 SD-OCT 系统的后处理流水线如图 3-1 所示，输入为光谱仪采集的 $M \times N$ 原始干涉谱矩阵（ M 为 A 扫条数， $N = 2048$ 为每条 A 扫的采样点数），输出为同尺寸的深度灰度图像。整条流水线包含以下 8 个步骤：




图 3-1 SD-OCT 后处理流水线

(1) 数据类型转换：将采集卡输出的 16 位无符号整数逐元素转换为 32 位浮点数，为后续数值计算做准备。

(2) 光谱整形（高斯归一化）：OCT 宽带光源的光谱包络通常不是理想的高斯分布，直接做傅里叶变换会在深度域产生旁瓣噪声。本系统采用归一化方法校正光谱包络——以首帧数据的列均值作为实际光谱包络的估计，生成目标高斯分布，计算二者的逐点比值作为归一化系数，后续各帧乘以该系数即完成整形。

(3) 背景扣除（去直流项）：对当前帧的所有 A 扫求列均值，得到与深度无关的直流分量估计，再从每条 A 扫中减去该均值。这一步消除了参考臂反射光和光源功率波动带来的背景偏移。

(4) K 线性化（三次样条插值）：光谱仪的像素与波长之间的映射关系是非线性的，而傅里叶变换要求信号在波数（ k ）空间上均匀采样。K 线性化通过插值将非均匀的波长域采样重新映射到均匀的 k 域网格上。本系统使用三次样条插值以获得较高的重映射精度。

(5) 色差补偿：光在参考臂与样品臂传播时，不同波长成分的群速度差异会引入附加相位，导致深度域信号展宽、分辨率下降。本系统通过预先标定的色差补偿函数 $G_c(k)$ （复数形式）与插值后的信号逐点相乘来校正这一相位畸变。

(6) 快速傅里叶变换（FFT）：对色差补偿后的复数信号做 k 域到深度域（ z 域）的傅里叶变换，一次批量处理 M 条 A 扫。

(7) 幅值提取与灰度映射：取 FFT 结果复数信号的前半部分（正频信息），计算模值并做对数映射，如式 (3-1) 所示，将信号动态范围压缩到适合灰度显示的区间。

$$I[i] = 20 \cdot \log_{10} \left(1 + \sqrt{\text{Re}^2[i] + \text{Im}^2[i]} \right) \quad (3-1)$$

其中 $\text{Re}[i]$ 和 $\text{Im}[i]$ 分别为第 i 个采样点 FFT 输出的实部和虚部。加 1 避免了 $\log_{10}(0)$ 的奇异点，乘以 20 将幅度转换为分贝单位的灰度值，便于从视觉上区分反射强弱。

(8) 帧合并：在 2D B 扫显示模式下，将相邻若干帧的对应像素累加以降低随机噪声，合并系数通常取 2 或 4。

3.1.2 串行计算瓶颈分析

上述 8 个步骤中，计算量最大的是第 (4) 步 K 线性化和第 (6) 步 FFT。K 线性化中的三次样条插值需要先求解一个 N 阶三对角线性方程组（Thomas 算法，时间复杂度 $O(N)$ ），再逐点插值，且每条 A 扫必须独立求解； N 点复数 FFT 的计算复杂度为 $O(N \log N)$ ， M 条 A 扫需批量执行。在 CPU 端串行执行时，这两步合计每帧耗时约数十毫秒，加上其余步骤后总耗时远超 82 kHz 采集速率下每条 A 扫 12.2 μs 的采集周期。GPU 并行计算的引入正是为了打破这一瓶颈—— M 条 A 扫在 GPU 上可同时处理，将整条流水线的耗时压缩到与采集周期相匹配的

量级。

3.2 基于 CUDA 的并行化后处理算法设计

上述 8 个后处理步骤在 GPU 上由 9 个核函数依次执行（表 3-1）。从并行化设计的角度看，这些核函数可分为三类：第一类是逐元素或逐列操作的预处理核函数（类型转换、光谱整形、背景扣除），计算逻辑简单，各 A 扫之间完全独立，并行化的关键在于线程映射效率；第二类是 K 线性化核函数，涉及三对角方程组求解，存在串行依赖，是并行化的主要难点；第三类是频域变换与后处理核函数（色差补偿、FFT、幅值提取、帧合并），借助 cuFFT 库和逐元素运算完成。本节按此分类分别阐述各核函数的设计。

表 3-1 后处理流水线核函数一览

序号	核函数名称	功能	线程映射
1	Uint_Transform_FloatKernel	类型转换	一维，每线程一像素
2	MultiplyKernel	高斯归一化	二维 (N, M)
3	MeanKernel	列均值计算	一维，每线程一列
4	SubKernel	减背景	一维，LoopNum 展开
5	splineInterpKernelV2_optimized_PCR	PCR 样条插值	每 block 一条 A 扫
6	MultiplyKernel（复数）	色差补偿	一维，LoopNum 展开
7	cufftExecC2C	批量 FFT	cuFFT 库函数
8	AmplitudeKernel	幅值提取	一维，LoopNum 展开
9	MergeKernel	帧合并	二维 (32, 8)

3.2.1 预处理核函数组

流水线的前三步——数据类型转换、光谱整形和背景扣除——均属于逐元素或逐列的独立运算， $M \times N$ 个数据点之间不存在跨 A 扫的依赖关系，适合用大规模线程直接映射。

数据类型转换核函数 Uint_Transform_FloatKernel 将采集卡输出的 uint16 数据逐元素转换为 float，每个线程负责一个元素，带边界检查以处理 $M \times N$ 不能被线程块大小整除的情况。该核函数计算量极小，耗时取决于全局内存带宽。

光谱整形分为标定和在线校正两个阶段。标定阶段在首帧数据到达时执行：首先由 MeanKernel 在 GPU 端计算各列均值作为实际光谱包络估计 $\text{base}[i]$ ，然后由核函数 ComputeGaussianAndNormalize 在 GPU 端并行生成目标高斯分布并计

算归一化系数——每个线程计算一个采样点的高斯值 $g[i] = s \cdot \exp\left(-\frac{(i-\mu)^2}{2\sigma^2}\right)$ 并做除法 $gsl[i] = g[i]/base[i]$ ($base[i] = 0$ 时置零)，避免了将均值拷回 CPU 端再计算的额外传输开销。在线校正阶段，核函数 `MultiplyKernel` 以二维线程网格运行，每个线程将一个采样点乘以对应列的归一化系数。由于归一化系数仅依赖列索引，同一列的 M 个线程读取相同地址，可被 L1/L2 缓存复用。

背景扣除由 `MeanKernel` 和 `SubKernel` 协同完成。`MeanKernel` 为 N 列各分配一个线程，每个线程沿 M 条 A 扫方向以步长 N 跨步访问全局内存进行累加求均值。`SubKernel` 采用 `LoopNum` 展开策略：每个线程在一次调用中处理连续 `LoopNum` 个元素，通过取模运算索引到对应列的均值进行减法。这种展开设计将线程总数降低为 $M \times N / \text{LoopNum}$ ，减少了核函数启动开销和线程调度压力，后续的色差补偿核函数和幅值提取核函数也采用了相同的展开策略。

3.2.2 K 线性化的并行化设计

K 线性化是整条流水线中并行化难度最大的步骤。线性插值虽然计算简单、各采样点完全独立，但一阶连续的分段线性函数在节点处导数不连续，重映射误差会降低深度域的轴向分辨率。为获得更高的插值精度，本系统采用三次样条插值，但这引入了一个串行瓶颈：三次样条要求先求解一个 N 阶三对角线性方程组以获得各节点处的二阶导数 $y_2[i]$ ，再利用 y_2 按样条公式逐点插值。

在初始的 GPU 实现中，每个 CUDA block 处理一条 A 扫（ M 条 A 扫对应 M 个 block），三对角求解部分由 block 内 `threadIdx.x == 0` 的单个线程串行执行 Thomas 算法（前向消元 + 回代，共 2×2046 步），结果存入共享内存。所有线程等待求解完成后，再并行执行插值计算——每个线程负责若干个目标 k 值，通过二分查找定位所在区间，代入样条插值公式：

$$y = A \cdot f_k + B \cdot f_{k+1} + \frac{h^2}{6} [(A^3 - A) \cdot y_{2,k} + (B^3 - B) \cdot y_{2,k+1}] \quad (3-2)$$

其中 $A = (\lambda_{k+1} - x)/h$ ， $B = (x - \lambda_k)/h$ ， $h = |\lambda_{k+1} - \lambda_k|$ 。这一实现的问题在于：每个 block 的 256 个线程中，只有 1 个在做三对角求解，其余 255 个线程在同步点处空等，GPU 的并行能力在此阶段利用率不足 0.4%。

为消除这一串行瓶颈，本文引入并行循环还原（Parallel Cyclic Reduction, PCR）算法^[73]替代 Thomas 算法。PCR 通过逐层消去相隔 2^l 的未知量，将 N 个

方程的求解过程分解为 $\log_2 N$ 层并行迭代，每层内所有方程独立更新，可由 block 内的全部线程同时执行。图 3-2 对比了 Thomas 算法与 PCR 算法在一个 block 内的线程利用情况。




图 3-2 Thomas 算法与 PCR 算法的线程利用对比

共享内存布局。PCR 算法需要维护三对角系数 a_i 、 b_i 、 c_i 和右端项 d_i ，以及二阶导数 $y_2[i]$ 和插值节点缓存，共 6 个长度为 N 的 float 数组，合计 48 KB，通过动态共享内存分配。

三对角系数构造。构造阶段并行执行：每个线程处理若干行（步长为 $\text{block-Dim.x} = 256$ ），对于内部节点 $i \in [1, N - 2]$ ，计算间距 $h_{i-1} = |\lambda_i - \lambda_{i-1}|$ 、 $h_i = |\lambda_{i+1} - \lambda_i|$ ，以及差商 $d_1 = (f_{i+1} - f_i)/h_i$ 、 $d_2 = (f_i - f_{i-1})/h_{i-1}$ ，从而设定：

$$a_i = h_{i-1}, \quad b_i = 2(h_{i-1} + h_i), \quad c_i = h_i, \quad d_i = 6(d_1 - d_2) \quad (3-3)$$

边界条件为自然样条，即 $b_0 = b_{N-1} = 1$ ， $a_0 = c_0 = a_{N-1} = c_{N-1} = d_0 = d_{N-1} = 0$ 。

信号值 f_i 通过 `__ldg` 指令走只读缓存路径读取，避免与共享内存写操作产生 bank conflict。插值节点 Lambda1 预先拷入常量内存，在构造阶段由各线程协作加载到共享内存中以加速后续的随机访问。

PCR 迭代消元。构造完成后，进入 $\log_2 N$ 层 PCR 迭代。每层的偏移量 $\text{offset} = 2^l$ ，每个线程对自己负责的行 i 读取左邻居 $(i - \text{offset})$ 和右邻居 $(i + \text{offset})$ 的

系数，按 PCR 消去公式更新：

$$\alpha = a_i/b_{i-\text{offset}}, \quad \gamma = c_i/b_{i+\text{offset}} \quad (3-4)$$

$$b'_i = b_i - c_{i-\text{offset}} \cdot \alpha - a_{i+\text{offset}} \cdot \gamma \quad (3-5)$$

$$d'_i = d_i - d_{i-\text{offset}} \cdot \alpha - d_{i+\text{offset}} \cdot \gamma \quad (3-6)$$

$$a'_i = -a_{i-\text{offset}} \cdot \alpha, \quad c'_i = -c_{i+\text{offset}} \cdot \gamma \quad (3-7)$$

在实现中，每个线程先将当前行及左右邻居的系数从共享内存读入寄存器变量 (a_i 、 b_i 、 c_i 、 d_i 及邻居的对应值)，在寄存器中完成消去计算后再写回共享内存。这种“读 → 算 → 写”的模式减少了对共享内存的重复访问。边界处理上，当邻居索引越界 ($i - \text{offset} < 1$ 或 $i + \text{offset} \geq N - 1$) 时，该行在当前层跳过更新，等待后续层处理。每层迭代结束后通过 `__syncthreads()` 保证所有线程完成写入，再进入下一层。

$\log_2 N$ 层迭代完成后，每行的方程已化简为 $b'_i \cdot y_{2,i} = d'_i$ 的独立形式，各线程直接做除法即可；两端自然边界条件保证 $y_{2,0} = y_{2,N-1} = 0$ 。

并行插值。得到二阶导数 y_2 后，各线程对自己负责的目标 k 值通过二分查找在共享内存中定位所在区间，代入式 (3-2) 计算插值结果。二分查找利用插值节点的降序排列特性，在 $O(\log N)$ 步内完成区间定位。对于边界点 ($k = N - 1$)，直接取原始信号值避免越界访问。

核函数执行配置。每个 block 分配 256 个线程、独立处理一条 A 扫，网格大小等于 M 。通过 `__launch_bounds__` 限制每 SM 最多 4 个活跃 block，确保 48 KB 共享内存不超出 SM 容量，同时维持足够的 warp 占用率。

表 3-2 对比了三个版本的 K 线性化核函数在三对角求解阶段的并行度。

表 3-2 K 线性化核函数版本对比

	线性插值	Thomas 串行样条	PCR 并行样条
三对角求解	不需要	1 线程串行	256 线程并行
求解步数	—	2×2046 步	11 层迭代
插值精度	一阶连续	三阶连续	三阶连续
共享内存用量	无	$2 \times N$ float	$6 \times N$ float

3.2.3 频域变换与后处理核函数组

K 线性化完成后，信号进入频域变换阶段。色差补偿核函数 MutiplyKernel（复数版本）将插值后的实数信号与预先标定的色差补偿系数 $G_c(k)$ 做逐点复数乘法，校正参考臂与样品臂之间的群速度色散。 G_c 的实部和虚部分别由标定文件 Gc_real.txt 和 Gc_imag.txt 读入，在初始化阶段通过 cudaMemcpy 拷贝到设备端，存储为 cufftComplex 类型。核函数中，每个线程通过取模运算 $(ind * LoopNum + i) \% N$ 索引到对应列的 G_c 系数，分别计算实部和虚部的乘积，将实数信号转换为复数信号供后续 FFT 使用。该核函数同样采用 LoopNum 展开策略。

FFT 使用 NVIDIA cuFFT 库^[74]的 cufftExecC2C 函数，以 C2C 模式执行前向变换。FFT 计划通过 cufftPlanMany 一次性创建，使 cuFFT 在一次调用中同时对 M 条 A 扫执行 N 点 FFT，内部自动选择最优的并行分解策略（Cooley-Tukey 或 Bluestein），结果原地写回。

幅值提取核函数 AmplitudeKernel 按式 (3-1) 对 FFT 输出执行取模与对数灰度映射，同样采用 LoopNum 展开。在 2D B 扫显示模式下，帧合并核函数 MergeKernel 以二维线程网格运行（ x 方向对应采样点， y 方向对应输出帧索引），将 M 条 A 扫按每 merge 条为一组在 y 方向循环累加，通过多帧叠加降低随机噪声。合并结果存入临时设备缓冲区，拷贝回主机后释放。

3.3 数据流组织与 GPU 内存层次利用

如图 3-3 所示，一次处理调用中，主机端通过 H2D 拷贝将原始干涉谱数据传入设备端，此后全部核函数在设备端顺序执行，各核函数的输出通过全局内存缓冲区直接传递给下一个核函数，中间不涉及任何 D2H 拷贝，仅在流水线末端将最终结果拷回主机。这种“单次输入、全程设备端、单次输出”的设计将 PCIe 总线传输减至每帧 1 次 H2D + 1 次 D2H。全部设备端缓冲区（输入、中间结果、输出等）在初始化阶段通过 cudaMalloc 一次性分配，处理过程中反复使用，避免了运行时频繁的内存分配开销。

在全局内存之外，流水线根据数据的访问模式利用了三种低延迟存储。插值节点 Lambda1 和待插值坐标 ddLambda 在处理过程中不发生变化，且被所有线程以相同地址读取，拷入常量内存由硬件缓存提供广播访问。PCR 核函数中，三




图 3-3 后处理流水线的设备端数据流

对角系数和二阶导数等 6 个数组需要在 block 内频繁读写和同步，存放在共享内存中（每 block 48 KB）。信号值 f_i 的读取通过 `__ldg` 指令走只读缓存路径，避免与共享内存写操作竞争 L1 缓存容量。

3.4 基于统一内存的高频后处理优化方案

3.4.1 细粒度 B 扫下的性能衰减现象

前述后处理流水线以 M 条 A 扫为一批进行处理。在激光焊接闭环控制场景中，缩小 M 可以缩短端到端延迟、提高反馈频率，但实测发现吞吐量并未随 M 的减小而线性增长。原因在于每次调用 `data_process` 都包含一次 H2D `cudaMemcpy`、一次 `cudaDeviceSynchronize` 和一次 D2H `cudaMemcpy`，这些操作的固定开销（驱动调度、PCIe 握手、流同步等）与 M 无关。当 $M = 1000$ 时，计算时间远大于固定开销；当 M 降至 100 时，计算量缩减为 1/10，但固定开销不变，系统从计算受限转为开销受限。

以 `cudaMemcpy` 为例， $M = 100$ 时单次 H2D 拷贝约 400 KB，实测耗时约 50 μs ； $M = 1000$ 时拷贝约 4 MB，耗时约 150 μs ——数据量增长 10 倍，但耗时仅增长 3 倍，说明固定开销占比在小数据量时尤为突出。

3.4.2 统一内存消除显式拷贝

CUDA 统一内存（Unified Memory）允许 CPU 和 GPU 通过同一指针访问数据，由驱动按需在主机内存与设备显存之间自动迁移内存页，无需程序员显式调

用 `cudaMemcpy` [75]。

在后处理流水线中引入统一内存的方法是：将输入缓冲区 `dvc_img_u` 和输出缓冲区 `dvc_result` 的分配方式从 `cudaMalloc` 改为 `cudaMallocManaged`。CPU 端直接向统一内存指针写入原始数据，随后启动核函数链。GPU 首次访问输入数据时，驱动自动将对应的内存页从主机迁移到设备；处理完成后，CPU 读取输出缓冲区时，驱动自动将结果页迁移回主机。整个过程中不再出现显式的 `cudaMemcpy` 调用。

对于中间缓冲区（`dvc_sub`、`dvc_inter`、`dvc_multiply` 等），由于它们仅在设备端使用，不涉及 CPU 访问，仍保留 `cudaMalloc` 分配以避免不必要的页迁移。图 3-4 对比了传统方案与统一内存方案的调用流程。




图 3-4 传统方案与统一内存方案的数据流与调用流程对比

3.4.3 事件驱动的轻量级同步

原始实现中，FFT 执行后调用 `cudaDeviceSynchronize()` 进行全局同步，阻塞 CPU 线程直至所有 GPU 操作完成。在高频调用场景下，每秒数百次的全局同步累积的阻塞时间占总延迟的比例随 M 减小而上升。替代方案是使用 CUDA 事件 (`cudaEvent`)：在核函数链的关键位置插入 `cudaEventRecord(evt, stream)`，CPU 端仅在需要读取结果时才调用 `cudaEventSynchronize(evt)`。事件同步只等待特定操作而非全部操作，CPU 线程在非必要的同步点可以继续准备下一帧数据。

3.4.4 优化效果分析

表 3-3 给出了不同 B 扫粒度 (M) 下, 传统方案 (显式 `cudaMemcpy` + `cudaDeviceSynchronize`) 与统一内存方案 (`cudaMallocManaged` + `cudaEvent`) 的端到端延迟对比。测试环境为 NVIDIA RTX 4090D GPU, CUDA 12.1, 每个粒度取 10 次测量的均值。

表 3-3 不同 B 扫粒度下的端到端延迟对比 (单位: μs)

B 扫粒度 M	传统方案	统一内存方案	加速比
1000	742	685	1.08
500	498	421	1.18
200	356	268	1.33
100	312	203	1.54
50	289	178	1.62

$M = 100$ 时, 传统方案中两次 `cudaMemcpy` 和一次全局同步的固定开销约占总延迟的 30%, 统一内存方案将该比例降至约 10%。 $M = 1000$ 时计算时间占主导, 两种方案的延迟差异较小。统一内存的页迁移由驱动按需触发, 首次访问时会引入页错误处理延迟; 但在连续采集场景中, 缓冲区的物理页在首帧迁移后即驻留在设备端, 后续帧的迁移开销可忽略。

3.5 实验验证与性能分析

3.5.1 测试环境

实验在表 3-4 所示的环境中进行。

表 3-4 CUDA 后处理测试环境

配置项	参数
GPU	NVIDIA GeForce RTX 4090D (24GB)
CPU	AMD EPYC 9754 128-Core Processor
CUDA Toolkit	12.1
光谱仪 A 扫速率	82 kHz
A 扫采样点数	2048
原始数据类型	uint16 (12 位有效)

3.5.2 各核函数执行耗时

表 3-5 给出了 $M = 1000$ 时各核函数的平均执行耗时（通过 CUDA Event 计时，取 100 次测量的均值）。

表 3-5 各核函数执行耗时 ($M = 1000$)

序号	核函数	功能	执行耗时 (μs)
1	Uint_Transform_FloatKernel	类型转换	38.2
2	MultiplyKernel	高斯归一化	42.5
3	MeanKernel	列均值	28.7
4	SubKernel	减背景	35.1
5	splineInterpKernelV2_optimized_PCR	PCR 样条插值	186.4
6	MultiplyKernel	色差补偿	33.8
7	cufftExecC2C	批量 FFT	52.6
8	AmplitudeKernel	幅值提取	31.3
9	MergeKernel	帧合并	18.9
	H2D 数据传输	输入拷贝	148.5
	D2H 数据传输	输出拷贝	126.3
端到端总计			742.3

PCR 样条插值核函数耗时 $186.4 \mu\text{s}$ ，是所有核函数中最高的，占计算总耗时（不含传输）的 39.8%，这与其 48 KB 共享内存和 11 层迭代的计算密度一致。H2D 和 D2H 数据传输合计 $274.8 \mu\text{s}$ ，占端到端总耗时的 37.0%，说明在 $M = 1000$ 时传输开销已接近计算开销，进一步缩小 M 时传输占比将更为突出（详见 3.4 节）。

3.5.3 CPU 与 GPU 处理速度对比

为量化 GPU 加速效果，在同一数据集上分别使用 MATLAB、C++ 和 CUDA 执行完整的后处理流水线，结果如表 3-6 所示。

表 3-6 不同平台的处理速度对比 ($M = 1000$, $N = 2048$)

硬件平台	软件平台	单帧耗时	折合 A-line/s
CPU	MATLAB	86.3 ms	11.6 k
CPU	C++	52.7 ms	19.0 k
RTX 4090D	CUDA	0.74 ms	1351 k

CUDA 实现相比 MATLAB 加速约 117 倍，相比 C++ 加速约 71 倍，折合处理速率约 1350k A-line/s，远超光谱仪 82 kHz 的采集速率。

3.5.4 PCR 样条插值精度验证

为验证 PCR 并行求解与 Thomas 串行求解的数值一致性，以 MATLAB 的 spline 函数输出为参考，计算 PCR 版本与参考结果之间的最大绝对误差和均方根误差（RMSE）。测试使用 100 条随机生成的 A 扫信号，结果如表 3-7 所示。

表 3-7 PCR 样条插值精度验证

对比项	最大绝对误差	RMSE
PCR vs MATLAB spline	3.8×10^{-5}	1.2×10^{-5}
Thomas vs MATLAB spline	2.1×10^{-5}	8.7×10^{-6}
Linear vs MATLAB spline	4.6×10^{-2}	1.8×10^{-2}

PCR 版本与 MATLAB spline 的最大绝对误差为 3.8×10^{-5} ，RMSE 为 1.2×10^{-5} ，与 Thomas 串行版本（ $2.1 \times 10^{-5} / 8.7 \times 10^{-6}$ ）处于同一量级，二者的微小差异来自浮点运算顺序不同导致的舍入误差累积。线性插值的误差则高出三个数量级（ 4.6×10^{-2} ），验证了三次样条在重映射精度上的优势。

节点间距悬殊场景下的数值稳定性。考虑到焊接过程中匙孔形态可能发生快速变化，需进一步说明节点间距差异极大时 PCR 消元是否会放大舍入误差。从矩阵性质看，自然三次样条所对应的三对角矩阵主对角元为 $2(h_{i-1} + h_i)$ ，非对角元分别为 h_{i-1} 与 h_i ，恒有 $|a_{ii}| > |a_{i,i-1}| + |a_{i,i+1}|$ ，矩阵严格对角占优，因而无论 $h_{\max}/h_{\min}$ 如何变化均非奇异；PCR 的 $\log_2 N$ 层并行消元在严格对角占优矩阵上具有与 Thomas 同阶的数值稳定性。从本系统的实际工作模式看，K 线性化的插值节点 Lambda1 由光谱仪硬件像元布局决定，是固定不变的波长网格，与样品状态、匙孔形态无关，焊接过程中真正发生快速变化的是干涉信号幅值 f_i 而非节点间距 h_i ，实测系统 $h_{\max}/h_{\min} \approx 1.05$ ，远在数值稳态区。为完整验证 PCR 在极端节点间距下的鲁棒性，本文人工合成 4 组非均匀网格使 $h_{\max}/h_{\min} \in \{1, 10, 100, 1000\}$ ，在 100 条 A 扫上分别用 PCR 与 Thomas 求解并以 MATLAB spline 为参考，RMSE 结果如表 3-8 所示。

由表 3-8 可见，随 $h_{\max}/h_{\min}$ 从 1 增大到 1000，PCR 与 Thomas 的 RMSE 同步缓慢上升至 10^{-5} 量级且二者相对差稳定在 $0.3\times$ 左右，PCR 并未表现出舍入误差的显著放大；结合本系统 $h_{\max}/h_{\min} \approx 1.05$ 的实际工况，PCR 求解过程在重建流水线中具备充分的数值稳定性。

表 3-8 不同节点间距比下 PCR 与 Thomas 的数值稳定性对照 (RMSE)

$h_{\max}/h_{\min}$	PCR	Thomas	相对差
1	1.2×10^{-5}	8.7×10^{-6}	$0.38 \times$
10	1.5×10^{-5}	1.1×10^{-5}	$0.36 \times$
100	2.4×10^{-5}	1.8×10^{-5}	$0.33 \times$
1000	4.7×10^{-5}	3.6×10^{-5}	$0.31 \times$

3.6 本章小结

本章将 SD-OCT 系统 82 kHz 采集速率下的全部后处理步骤移植到 GPU 上并行执行，流水线采用“单次输入、全程设备端、单次输出”的数据流设计。在 RTX 4090D 上， $M = 1000$ 时端到端处理耗时约 742 μs ，折合处理速率约 1350k A-line/s，相比 MATLAB 加速约 117 倍，相比 C++ 加速约 71 倍。

在 K 线性化步骤中，本文引入 PCR 并行循环还原算法替代 Thomas 串行算法求解三次样条的三对角方程组，将三对角求解从串行 $O(N)$ 步降低为 $\log_2 N$ 层并行迭代，使 block 内全部 256 个线程参与求解。PCR 版本与 MATLAB spline 的 RMSE 为 1.2×10^{-5} ，与 Thomas 串行版本精度一致，同时消除了 255/256 的线程空等。

针对细粒度 B 扫场景下固定开销占比上升的问题，本文以统一内存消除显式 H2D/D2H 拷贝，以 CUDA 事件替代全局同步。 $M = 50$ 时统一内存方案端到端延迟 178 μs ，相比传统方案 (289 μs) 加速 1.62 倍。

本章流水线输出的深度灰度图像将作为后续章节语义分割方法的输入数据来源。

第四章 基于双重注意力机制的 OCT 图像语义分割方法

OCT 图像存在散斑噪声强、对比度低、边界模糊等特点，给熔深区域的自动化提取带来困难。本章以 DeepLabV3+ 为基线模型，针对 ASPP 模块全局上下文建模不足和解码器边界定位不精确两个问题，分别在编码器端和解码器端引入 TR（Transformer Routing）全局注意力模块和 SAE（Spatial Awareness Enhancement）空间感知增强模块，通过消融实验和对比实验验证所提方法的有效性。

4.1 DeepLabV3+ 基线模型

DeepLabV3+ 由 Google 团队于 2018 年提出^[7]，结合空洞卷积、ASPP 模块和编码器-解码器结构，在多尺度上下文信息捕获方面表现出色。DeepLabV3+ 的整体网络结构已在第二章图 2-5 中详细展示。

4.1.1 空洞卷积

空洞卷积（Atrous Convolution）通过在卷积核的相邻元素之间插入空洞（零值），在不增加计算量的前提下扩大感受野。空洞卷积的示意图如图 4-1 所示。




图 4-1 空洞卷积示意图^[76]

设输入特征图为 $\mathbf{F}$ ，空洞卷积核为 $\mathbf{W}$ ，空洞率为 r ，则空洞卷积的输出可表示为：

$$\mathbf{O}[i, j] = \sum_m \sum_n \mathbf{F}[i + r \cdot m, j + r \cdot n] \cdot \mathbf{W}[m, n] \quad (4-1)$$

其中， (i, j) 表示输出特征图的位置坐标， (m, n) 表示卷积核的索引。当 $r = 1$ 时退化为标准卷积；当 $r > 1$ 时，有效感受野扩大为 $(2r - 1) \times k + 1$ ， k 为卷积核原始尺寸。

4.1.2 ASPP 模块

ASPP (Atrous Spatial Pyramid Pooling) 模块通过多个不同空洞率的并行分支捕获多尺度上下文信息^[28], 结构如图 4-2 所示。




图 4-2 ASPP 模块结构图

本文采用深度可分离 ASPP 模块, 包含 5 个并行分支: 1×1 卷积、 3×3 空洞卷积 (dilation 分别为 12、24、36) 和全局平均池化。5 个分支的输出在通道维度拼接后, 通过 1×1 卷积降维融合。深度可分离卷积将标准卷积分解为深度卷积和点卷积两步, 参数量和计算量大幅降低。

4.1.3 编码器-解码器结构

编码器采用 ResNet18-V1c 作为骨干网络^[66,77], 使用 Deep Stem 结构 (三个 3×3 卷积替代 7×7 卷积)。选择 ResNet18 而非更深的 ResNet50/101, 主要考虑训练集规模有限 (912 张图像), 过深网络在小数据集上易过拟合, 且 OCT 图像为二分类任务, 浅层网络已具备足够的特征提取能力。

解码器通过上采样和特征融合恢复空间分辨率: ASPP 输出的高层特征经双线性插值上采样, 与编码器浅层特征 (经 1×1 卷积降维后) 在通道维度拼接, 再经深度可分离卷积和 1×1 卷积输出像素级预测结果。

4.2 TR 全局注意力模块设计

4.2.1 改进动机

ASPP 模块的感受野受限于空洞卷积的局部性，仅覆盖特征图的局部区域。而 OCT 图像中的熔深区域呈现细长结构（纵横比可达 1:10 以上），跨越图像多个区域，需要网络理解整个图像的空间关系才能准确分割。ASPP 的局部感受野可能导致细长结构的断裂或误分割。

表 4-1 总结了 OCT 图像特点与本文模块设计的对应关系。

表 4-1 OCT 图像特点与模块设计的对应关系

OCT 图像特点	对分割任务的影响	本文解决方案
散斑噪声强	局部特征不稳定，影响边界识别	TR 模块的区域级路由在窗口平均后计算相似度，抑制局部噪声干扰
目标细长	纵横比高，跨越多区域，易断裂	TR 模块的长程依赖建模使网络理解细长结构的整体连续性
边界模糊	对比度低，边界定位困难	SAE 模块的坐标注意力显式编码空间位置，增强边界特征响应
类别不平衡	背景占比 90% 以上，前景学习不充分	BCE+Dice 混合损失函数

4.2.2 TR 模块的整体结构

TR 模块受 BiFormer^[58] 启发，采用 Transformer Block 架构，整体结构如图 4-3 所示。模块接收 ASPP 的拼接输出特征图，经以下三个子模块依次处理：




图 4-3 TR 模块结构图（窗口大小 $S=4$ ，窗口数量 $S^2=16$ ， $\text{TopK}=4$ ）

（1）卷积位置编码（Convolutional Position Encoding, CPE）。使用 3×3 深度可分离卷积为特征图注入隐式位置信息，输出与输入相加，使模型在不依赖固定

位置编码的情况下感知空间位置。

(2) 双层路由注意力 (Bi-level Routing Attention, BRA)。对 LayerNorm 归一化后的特征执行双层路由稀疏注意力 (详见下文)，输出通过残差连接与输入相加。

(3) 前馈网络 (Feed-Forward Network, FFN)。对 LayerNorm 归一化后的特征依次通过线性层 (升维 4 倍)、深度可分离卷积、GELU 激活和线性层 (降维)，输出同样通过残差连接。深度可分离卷积的引入使 FFN 在通道混合的同时保留局部空间信息。

整个模块的前向传播可表示为：

$$\mathbf{X}_1 = \mathbf{X}_0 + \text{CPE}(\mathbf{X}_0) \quad (4-2)$$

$$\mathbf{X}_2 = \mathbf{X}_1 + \text{DropPath}(\text{BRA}(\text{LN}(\mathbf{X}_1))) \quad (4-3)$$

$$\mathbf{X}_3 = \mathbf{X}_2 + \text{DropPath}(\text{FFN}(\text{LN}(\mathbf{X}_2))) \quad (4-4)$$

其中 DropPath 以一定概率随机丢弃整条路径，起到正则化作用。

4.2.3 双层路由注意力机制

双层路由注意力 (Bi-Level Routing Attention, BRA) 是 TR 模块的核心计算单元，通过区域级路由和 TopK 选择机制，仅对最相关的窗口进行注意力计算，将计算复杂度从全局注意力的 $O(n^2)$ 降低到 $O(n^2 \times k/p^2)$ 。其工作流程如图 4-4 所示，包含以下四个步骤。




图 4-4 双层路由注意力机制示意图

步骤一，QKV 投影与窗口划分。输入特征图通过线性层投影为查询 $\mathbf{Q}$ 、键

$\mathbf{K}$ 和值 $\mathbf{V}$ ，然后按 $n_{\text{win}} \times n_{\text{win}}$ 的网格划分为 p^2 个窗口，每个窗口包含 $w \times w$ 个像素。同时，值 $\mathbf{V}$ 经过一个 5×5 深度可分离卷积生成局部上下文增强（Local Context Enhancement, LCE）特征，用于在注意力输出后补充局部细节。

步骤二，区域级路由。对每个窗口内的 $\mathbf{Q}$ 和 $\mathbf{K}$ 分别求空间平均，得到区域级查询和键向量：

$$\mathbf{Q}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{Q}_j, \quad \mathbf{K}_{\text{region}}^{(i)} = \frac{1}{|\mathcal{W}_i|} \sum_{j \in \mathcal{W}_i} \mathbf{K}_j \quad (4-5)$$

计算窗口间的路由相似度矩阵 $\mathbf{S} \in \mathbb{R}^{p^2 \times p^2}$ ，并对每个查询窗口选择 TopK 个最相关的键窗口：

$$\mathbf{S}_{ij} = \frac{\mathbf{Q}_{\text{region}}^{(i)} \cdot (\mathbf{K}_{\text{region}}^{(j)})^T}{\sqrt{d_k}}, \quad \mathcal{R}_i = \text{TopK}(\mathbf{S}_{i,:}, k) \quad (4-6)$$

步骤三，KV 聚集。根据路由索引 $\mathcal{R}_i$ ，从全部窗口中收集被选中的键值对，构成稀疏的 KV 集合 $\mathbf{K}_{\mathcal{R}_i}$ 、 $\mathbf{V}_{\mathcal{R}_i}$ 。未被选中的窗口不参与后续计算，从而减少了注意力矩阵的规模。

步骤四，多头稀疏注意力。在每个查询窗口内，对聚集后的 KV 执行标准的缩放点积多头注意力：

$$\text{Attention}(\mathbf{Q}_i, \mathbf{K}_{\mathcal{R}_i}, \mathbf{V}_{\mathcal{R}_i}) = \text{softmax}\left(\frac{\mathbf{Q}_i \mathbf{K}_{\mathcal{R}_i}^T}{\sqrt{d_k}}\right) \mathbf{V}_{\mathcal{R}_i} \quad (4-7)$$

注意力输出与 LCE 特征相加后，经线性投影恢复到原始维度。

4.2.4 TR 模块与 BiFormer 的差异

本文的 TR 模块与原始 BiFormer 的主要区别在于嵌入位置和参数选择。BiFormer 作为独立的骨干网络使用，而本文将 TR 模块嵌入 ASPP 输出之后，利用 ASPP 已捕获的多尺度特征作为输入，使注意力机制在多尺度语义信息的基础上建立长程依赖。此外，区域级路由中的窗口平均操作对散斑噪声有天然的平滑作用，使路由决策在 OCT 图像的噪声条件下仍能保持稳定。该平滑作用在本章后续散斑强度鲁棒性实验（表 4-10）中已得到量化验证：当散斑方差 σ^2 从 0 增大到 0.10 时，未引入 TR 模块的基线 mIoU 衰减 10.5%，而引入 TR 模块的本文方法仅衰减 5.9%，证明区域级路由对乘性散斑确实起到了显著的低通作用。TopK 取 4、窗口大小取 4×4 、注意力头数取 8 沿用 BiFormer 在语义分割任务上的推荐

配置；其中窗口大小受输入特征图分辨率与典型熔深结构跨度共同约束（ASPP 输出特征图为 64×64 ， 4×4 网格使每窗口覆盖 16×16 像素，恰好与图像中典型熔深条带的横向跨度匹配），本文沿用而未重新调优；为验证 TopK 参数选择在 OCT 数据上的合理性，本文进一步在改进模型上做了 TopK 的一维敏感性对照，结果如表 4-2 所示。

表 4-2 TR 模块 TopK 参数敏感性对照（窗口大小 $S = 4$ ，窗口数量 $S^2 = 16$ ）

TopK	选中比例	mIoU	HD95	推理时间 (ms)
2	12.5%	0.897	11.86	11.2
4	25.0%	0.911	10.68	12.4
6	37.5%	0.910	10.72	14.1
8	50.0%	0.906	10.91	16.0

由表 4-2 可知：TopK = 2 时区域级路由覆盖窗口过少，长程依赖建模不足，mIoU 较 TopK = 4 下降 1.4%、HD95 上升 1.18；TopK = 4 在精度与边界两项指标上同时取得最优；TopK 继续增大到 6、8 后 mIoU 趋于饱和甚至轻微回落（更多被选中的窗口稀释了关键路由权重，并引入噪声窗口的干扰），而推理时间却随选中窗口数线性上升。因此 BiFormer 默认的 TopK = 4 在本文 OCT 数据上恰好处于“精度-效率”拐点，无需重新调优。

4.2.5 混合损失函数

OCT 图像中背景占 90% 以上像素，单一的交叉熵损失容易被背景像素主导。本文采用 BCE 与 Dice 的混合损失：

$$L_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(p_i)) + (1 - y_i) \log(1 - \sigma(p_i))] \quad (4-8)$$

$$L_{\text{Dice}} = 1 - \frac{2 \sum_{i=1}^N \sigma(p_i) \cdot y_i + \epsilon}{\sum_{i=1}^N \sigma(p_i) + \sum_{i=1}^N y_i + \epsilon} \quad (4-9)$$

$$L_{\text{total}} = \lambda_1 \cdot L_{\text{BCE}} + \lambda_2 \cdot L_{\text{Dice}} \quad (4-10)$$

其中 BCE 损失提供稳定的逐像素梯度，Dice 损失直接优化区域重叠度、对前景占比不敏感。

权重选取依据。本文未对 λ_1 、 λ_2 进行精细网格搜索，而是基于“两类损失各

承担一部分梯度信号”的原则在等比与不等比之间做了简单对照。考虑到本文采用 Adam 优化器、初始学习率仅为 1×10^{-6} ，等比权重 $\lambda_1 = \lambda_2$ 可以避免 BCE 或 Dice 单方主导前期梯度，整体放大 2 倍则用于在低学习率下加快收敛、缩小目标类与背景类的梯度量级差。为验证该选取的合理性，在改进模型（DeepLabV3+ + TR + SAE）上对若干组权重做了 mIoU 对照，结果如表 4-3 所示。

表 4-3 BCE/Dice 混合损失权重对照（改进模型）

(λ_1, λ_2)	权重特点	mIoU	HD95
(1, 1)	BCE/Dice 等权、未放大	0.903	11.42
(1, 2)	偏向 Dice、强化区域重叠	0.905	11.18
(2, 1)	偏向 BCE、强化像素监督	0.902	11.36
(2, 2)	等权、整体放大 2 倍（本文）	0.911	10.68
(2, 3)	等权基础上略偏 Dice	0.906	10.97
(3, 3)	等权、整体放大 3 倍	0.908	10.84

由表 4-3 可知，当 $\lambda_1 = \lambda_2$ 时模型整体表现优于不等比配置；整体放大倍数取 2 时 mIoU 与 HD95 同时取得最优，再继续放大到 3 倍后边界精度有所回落，说明过大的损失幅值在小学习率下并不会带来额外收益。综合精度与边界指标，本文选用 $\lambda_1 = \lambda_2 = 2.0$ 作为最终配置。

4.3 SAE 空间感知增强模块设计

4.3.1 改进动机

TR 模块在编码器端增强了全局结构理解，但解码器在恢复空间分辨率时仅通过简单的特征拼接融合高低层信息，缺乏对空间位置关系的显式建模。编码器端的全局信息难以传递至解码器的边界细节恢复环节，导致边界轮廓模糊、局部不连续。

传统解码器存在三个局限：多次下采样导致空间位置信息丢失，恢复有限；所有通道均匀加权，未区分边界通道与非边界通道的贡献差异；缺乏对细长结构在水平和垂直方向上特征分布差异的方向性建模。

4.3.2 SAE 模块原理与结构

SAE 模块在坐标注意力（Coordinate Attention, CA）^[38] 与 SE 通道注意力^[32] 的基础上进行了针对性架构设计，采用“坐标注意力 → 特征精炼 → 多基数通道注意力”的三级级联结构，如图 4-5 所示。模块接收解码器中低层特征与高层特征拼接后的融合特征，每级输出均通过残差连接与输入相加。




图 4-5 SAE 模块结构图

第一级：坐标注意力（Coordinate Attention）。将全局池化解耦为两个方向的一维聚合。给定输入 $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$ ，分别沿水平和垂直方向池化：

$$z_c^h(h) = \frac{1}{W} \sum_{0 \leq i < W} x_c(h, i), \quad z_c^w(w) = \frac{1}{H} \sum_{0 \leq j < H} x_c(j, w) \quad (4-11)$$

得到 $\mathbf{z}^h \in \mathbb{R}^{C \times H \times 1}$ 和 $\mathbf{z}^w \in \mathbb{R}^{C \times 1 \times W}$ ，分别保留了水平和垂直方向的位置信息。将二者沿空间维度拼接后，通过共享 1×1 卷积降维（降维比 $r = 4$ ）、BN 和 h-swish 激活：

$$\mathbf{f} = \text{h-swish}(\text{BN}(F_{1 \times 1}([\mathbf{z}^h; \mathbf{z}^w]))) \quad (4-12)$$

再沿空间维度切分，分别通过独立的 1×1 卷积和 Sigmoid 激活生成方向性注意力权重 $\mathbf{g}^h \in \mathbb{R}^{C \times H \times 1}$ 、 $\mathbf{g}^w \in \mathbb{R}^{C \times 1 \times W}$ ，对输入特征图进行空间重标定：

$$\mathbf{Y}_1 = \mathbf{X} \odot \mathbf{g}^h \odot \mathbf{g}^w + \mathbf{X} \quad (4-13)$$

其中 $\odot$ 表示逐元素乘法（沿对应维度广播）。h-swish 激活函数定义为 $\text{h-swish}(x) = x \cdot \text{ReLU6}(x + 3)/6$ ，相比标准 Sigmoid 计算效率更高。

第二级：特征精炼。坐标注意力的输出经过两层 3×3 卷积（每层后接 BN 和 ReLU），融合邻域上下文信息，输出通过残差连接：

$$\mathbf{Y}_2 = \text{Conv}_{3 \times 3}(\text{Conv}_{3 \times 3}(\mathbf{Y}_1)) + \mathbf{Y}_1 \quad (4-14)$$

该级的作用是将坐标注意力增强后的特征与局部空间上下文进一步融合，弥补一

维池化丢失的局部细节。

第三级：多基数通道注意力（Multi-Cardinality SE）。通过全局平均池化（Global Average Pooling, GAP）将空间维度压缩为 1×1 ，然后使用 κ 个并行的全连接分支，每个分支独立将通道维度从 C 降至 C/r ，经 ReLU 激活后拼接，再通过一个全连接层和 Sigmoid 恢复到 C 维，生成通道权重：

$$\mathbf{s} = \sigma(W_{fc}[\text{ReLU}(W_1\mathbf{p}); \text{ReLU}(W_2\mathbf{p}); \text{ReLU}(W_3\mathbf{p}); \text{ReLU}(W_4\mathbf{p})]) \quad (4-15)$$

其中 $\mathbf{p} = \text{GAP}(\mathbf{Y}_2) \in \mathbb{R}^C$ ， $W_i \in \mathbb{R}^{(C/r) \times C}$ 为第 i 个分支的权重矩阵， $W_{fc} \in \mathbb{R}^{C \times (\kappa \cdot C/r)}$ 为融合层权重，本文取 $\kappa = 4$ ， $r = 4$ 。多个并行分支各自学习不同的通道依赖模式，相比单一 SE 路径提供了更丰富的通道间特征交互。最终输出为：

$$\mathbf{Y}_3 = \mathbf{Y}_2 \odot \mathbf{s} \quad (4-16)$$

SAE 模块集成于 DeepLabV3+ 解码器中低层特征与高层特征拼接之后。该位置的特征同时包含浅层的空间细节和深层的语义信息，在此处引入空间感知增强可以在特征融合阶段突出边界相关响应。模块输出通过残差连接与输入相加，每级均保持梯度流通。

4.4 改进模型整体结构与协同机制

4.4.1 完整模型架构

改进后的模型整体结构如图 4-6 所示，在 DeepLabV3+ 基础上做了三项优化：编码器端在 ASPP 之后引入 TR 模块建立长距离依赖；解码器端在低层特征处理分支中集成 SAE 模块增强空间位置感知；训练时采用 BCE+Dice 混合损失函数缓解类别不平衡。

4.4.2 各模块协同机制与前向传播流程

改进模型的完整前向传播流程如下。输入图像经 ResNet18 编码器提取四级特征，其中第四级特征（ $C = 512$ ）送入 ASPP 模块，5 个分支的输出在通道维度拼接后得到 $C = 2560$ 的特征图。TR 模块在此特征上执行双层路由注意力，通过残差连接输出增强后的全局特征，再经 1×1 瓶颈卷积降维至 $C = 512$ 。该特征




图 4-6 改进模型（DeepLabV3+ + TR + SAE）整体结构图

经双线性插值上采样后，与编码器第一级浅层特征（经 1×1 卷积降维至 $C = 48$ ）在通道维度拼接，得到 $C = 560$ 的融合特征。SAE 模块在此融合特征上依次执行坐标注意力、特征精炼和多基数通道注意力，通过残差连接输出空间增强后的特征。最终经深度可分离卷积和 1×1 分类卷积输出像素级预测。

TR 模块位于编码器端，在高层语义特征上建立长距离依赖，解决细长结构的断裂分割问题；SAE 模块位于解码器端，在融合特征上增强空间位置感知，提升边界定位精度。二者形成“编码端重结构、解码端重细节”的互补架构。消融实验的数据直观地反映了这种互补性：单独使用 TR 可提升 mIoU 3.9%，单独使用 SAE 可提升 5.9%，同时使用可提升 7.1%。

4.5 综合实验与分析

4.5.1 实验环境与参数配置

实验环境与训练参数配置如表 4-4 所示。

评价指标包括 mIoU（平均交并比）、mAcc（平均准确率）、mDice（平均 Dice 系数）和 HD95（Hausdorff 距离 95% 分位数）。

4.5.2 消融实验

表 4-5 给出了 4 种配置的消融实验结果。

TR 模块通过全局依赖建模使 mIoU 从 0.851 提升至 0.884 (+3.9%)，SAE 模

表 4-4 实验环境与训练参数配置

配置项	参数
GPU	NVIDIA GeForce RTX 4090D (24GB) × 1
CPU	AMD EPYC 9754 128-Core Processor (18 vCPU)
内存	60 GB
操作系统	Ubuntu 20.04 LTS
深度学习框架	PyTorch 1.10.0 / MMSegmentation
CUDA	11.3
训练迭代次数	20,000 次
批量大小	8
优化器	Adam (初始学习率 1×10^{-6})
学习率调度	多项式衰减 (power=0.9)
输入尺寸	512×512
评估间隔	每 500 次迭代

表 4-5 消融实验结果

配置	TR 模块	SAE 模块	mIoU	mAcc	mDice	相比基线提升
DeepLabV3+ (基线)	×	×	0.851	0.923	0.913	-
+ TR	✓	×	0.884	0.941	0.935	+3.9%
+ SAE	×	✓	0.901	0.948	0.945	+5.9%
+ TR + SAE	✓	✓	0.911	0.956	0.951	+7.1%

块仅增加约 25M 参数量即实现 mIoU 5.9% 的提升，两模块同时使用达到 0.911 (+7.1%)。组合提升幅度 (7.1%) 小于单模块之和 (9.8%)，说明二者在提升路径上有一定重叠，但组合配置在所有指标上均为最优，体现了全局与局部增强的互补性。

表 4-6 给出了边界精度对比。

表 4-6 消融实验边界精度对比

模型配置	HD95	边界精度评价
DeepLabV3+ (基线)	12.22	良好
DeepLabV3+ + TR	11.89	良好
DeepLabV3+ + SAE	11.45	优秀
本文方法	10.68	优秀

SAE 模块对边界精度的贡献更突出 (HD95 从 12.22 降至 11.45)，结合 TR 后进一步降至 10.68，相比基线降低 12.6%。

4.5.3 与主流方法对比实验

表 4-7 给出了定量对比结果，表 4-8 给出了类别级别的性能对比。

表 4-7 不同方法的定量评估结果对比

模型配置	mIoU	mAcc	mDice	mPrecision	mRecall
UNet	0.805	0.878	0.880	0.883	0.878
UNet++	0.751	0.905	0.837	0.790	0.905
ResUNet	0.721	0.788	0.810	0.836	0.788
TransUNet	0.810	0.963	0.884	0.829	0.963
DeepLabV3+ (基线)	0.851	0.923	0.913	0.904	0.923
本文方法	0.911	0.956	0.951	0.947	0.956

本文方法 mIoU 达到 0.911，相比 UNet 提升 13.2%，相比 TransUNet 提升 12.5%，相比基线提升 7.1%。TransUNet 在 mAcc 上略高（0.963 vs 0.956），但其 mIoU 仅 0.810，且内存占用远大于本文方法（详见效率分析）。

表 4-8 不同方法在类别级别上的性能对比

模型配置	背景类别		目标类别		
	IoU	Acc	IoU	Acc	Dice
UNet	0.990	0.995	0.620	0.761	0.765
UNet++	0.983	0.987	0.518	0.823	0.683
ResUNet	0.985	0.994	0.457	0.581	0.627
TransUNet	0.988	0.999	0.632	0.926	0.773
DeepLabV3+ (基线)	0.992	0.996	0.710	0.850	0.830
本文方法	0.996	0.998	0.826	0.914	0.904

目标类别 IoU 达到 0.826，相比基线（0.710）提升 16.3%，相比 UNet（0.620）提升 33.2%。这一差距主要来自于 TR 模块避免了细长结构断裂、SAE 模块提高了边界定位精度。

4.5.4 可视化分析

图 4-7 展示了全部方法的分割结果可视化对比。

从可视化结果可以看出：UNet 系列在细长结构上出现断裂，TransUNet 有所改善但精度不足；单独加 TR 后连续性改善，单独加 SAE 后边界更锐利，两者同时使用时分割结果兼具全局完整性和边界精确性。




图 4-7 全部方法的分割结果可视化对比

4.5.5 效率分析

表 4-9 从参数量和内存占用两个方面对不同方法进行对比分析。

表 4-9 不同方法的效率指标对比

模型配置	参数量 (M)	内存占用 (MB)
UNet	30	3809
UNet++	8.8	4675
ResUNet	13	4351
TransUNet	219	19530
DeepLabV3+ (基线)	95	2705
本文方法	420	9107

本文方法参数量 420M，相比基线增加 342.1%，但 mIoU 提升 7.1%。与 TransUNet 相比，mIoU 高 12.5% 而内存占用低 53.3% (9107MB vs 19530MB)，这得益于 TR 模块的双层路由稀疏注意力机制减少了中间激活值的存储需求。

4.5.6 散斑强度鲁棒性对照实验

OCT 图像最主要的噪声形式为散斑噪声，其强度随被测样品微结构、成像景深与系统参数变化而波动。为进一步评估改进模型在不同散斑强度下的稳定性，本文在测试集 228 张图像上人工叠加乘性散斑噪声，模拟从“原始 / 轻度 / 中度 / 重度”四档干扰条件。具体地，给定原始图像 I ，按下式生成扰动图像：

$$\tilde{I} = I \cdot (1 + n), \quad n \sim \mathcal{N}(0, \sigma^2) \quad (4-17)$$

其中乘性高斯随机场 n 近似 OCT 散斑的瑞利包络统计，方差 $\sigma^2 \in \{0, 0.02, 0.05, 0.10\}$ 分别对应四档强度。基线 DeepLabV3+ 与本文方法 (DeepLabV3+ + TR + SAE) 使用同一组训练权重直接在扰动测试集上进行推理，不做额外微调，结果如表 4-10 所示。

表 4-10 不同散斑强度下基线与本文方法的鲁棒性对照

σ^2	基线 (DeepLabV3+)		本文方法	
	mIoU	衰减幅度	mIoU	衰减幅度
0	0.851	—	0.911	—
0.02	0.838	-1.5%	0.903	-0.9%
0.05	0.806	-5.3%	0.886	-2.7%
0.10	0.762	-10.5%	0.857	-5.9%

由表 4-10 可见，随散斑强度增大，两模型 mIoU 均出现单调下降，但本文方法在各档强度下的相对衰减幅度均明显小于基线，并保持约一半左右的衰减率（如 $\sigma^2 = 0.10$ 时基线衰减 10.5%、本文方法仅衰减 5.9%）。原因在于：TR 模块在区域级路由阶段对窗口内的 **Q**、**K** 做空间平均，相当于对局部散斑做了天然的低通滤波，使得长程依赖建模不易被局部噪声扰动；SAE 模块沿水平/垂直方向的一维池化与坐标注意力则在解码端继续抑制散斑随机颗粒对边界响应的干扰。综上，所提双重注意力机制对散斑干扰具备明显的抗噪能力。

4.6 本章小结

本章针对焊接 OCT 图像语义分割任务，在 DeepLabV3+ 基线模型上提出了两个互补的注意力模块。TR 模块在编码器端通过双层路由注意力建立长距离依赖，解决细长结构断裂问题，使 mIoU 提升 3.9%。SAE 模块在解码器端通过坐标注意力编码空间位置信息，提升边界分割精度，以 25M 参数量换取 5.9% 的 mIoU 提升。两模块同时使用使 mIoU 达到 0.911 (+7.1%)，目标类别 IoU 达 0.826 (+16.3%)，HD95 降至 10.68 (-12.6%)。相比 TransUNet，本文方法在 mIoU 高 12.5% 的同时内存占用低 53.3%。

第五章 总结与展望

5.1 总结

本文围绕激光焊接 OCT 图像的在线重建与熔深语义分割两个问题展开研究，分别从 GPU 加速后处理和深度学习分割模型改进两个方向给出了解决方案。

在 OCT 图像的 GPU 加速重建方面，本文将 SD-OCT 系统的全部后处理步骤——类型转换、光谱整形、背景扣除、K 线性化、色差补偿、FFT、幅值提取和帧合并——移植到 GPU 上并行执行，设计了 8 个 CUDA 核函数构成完整的处理流水线。其中，针对 K 线性化步骤中三次样条插值的串行瓶颈，引入并行循环还原（PCR）算法将三对角方程组求解从串行 $O(N)$ 步压缩为 11 层并行迭代，消除了原版核函数中 255/256 线程空等的问题。流水线采用“单次输入、全程设备端、单次输出”的数据流设计，综合利用常量内存、共享内存和只读缓存三级存储层次。针对细粒度 B 扫场景下显式内存拷贝与同步操作导致的吞吐量衰减，引入统一内存消除显式 H2D/D2H 拷贝，并以 CUDA 事件替代全局同步，降低了固定开销占比。

在 OCT 图像的语义分割方面，本文以 DeepLabV3+ 为基线模型，针对 OCT 图像散斑噪声强、目标细长、边界模糊和类别不平衡等特点，设计了两个功能互补的注意力模块。TR 全局注意力模块位于编码器端 ASPP 输出之后，受双层路由注意力思想启发，通过区域级路由和 TopK 选择机制建立长距离依赖关系，解决细长熔深结构的断裂分割问题。SAE 空间感知增强模块集成于解码器端，采用“坐标注意力—特征精炼—通道注意力”的级联结构，显式建模特征图的空间位置关系，提升边界分割精度。两个模块形成“编码重结构、解码重细节”的互补架构，配合 BCE+Dice 混合损失函数缓解类别不平衡问题。

实验结果表明，改进后的模型在自建焊接 OCT 数据集上 mIoU 达到 0.911，相比基线模型提升 7.1%；目标类别 IoU 从 0.710 提升至 0.826 (+16.3%)；边界精度 HD95 从 12.22 降低至 10.68 (-12.6%)。与 UNet、TransUNet 等主流方法相比，本文方法 mIoU 高于所有对比方法，同时相比 TransUNet 内存占用减少 53.3%。

5.2 展望

本研究仍存在若干局限。GPU 加速方面，PCR 核函数的共享内存用量接近 SM 上限，限制了每 SM 的活跃 block 数量，后续可尝试混合精度计算或分段求解以降低内存占用。语义分割方面，当前数据集仅覆盖有限的材料种类和工艺参数，模型在未见工况下的泛化能力尚未验证，扩充数据集是提升鲁棒性的直接途径。此外，本文的 GPU 重建与语义分割两个模块目前独立运行，将二者串联部署、实现从干涉谱到分割结果的端到端处理，是后续工程化的方向。

参考文献

- [1] 黄贻蔚. 基于 OCT 的 304 不锈钢激光焊接熔深在线检测研究 [D]. 广州: 广东工业大学, 2024.
- [2] 张旭东, 陈武柱. 激光焊接技术进展及其在汽车制造中的应用 [J]. 世界汽车, 2003(7): 53–56.
- [3] 田曼. 轨道列车用不锈钢激光焊工艺研究 [D]. 武汉: 华中科技大学, 2015.
- [4] 曾海涛. OCT 图像信号的散斑噪声处理方法研究 [D]. 重庆: 重庆理工大学, 2025.
- [5] LONG J, SHELHAMER E, DARRELL T. Fully Convolutional Networks for Semantic Segmentation[J]. arXiv preprint arXiv:1411.4038, 2015.
- [6] RONNEBERGER O, FISCHER P, BROX T. U-Net: Convolutional Networks for Biomedical Image Segmentation[J]. arXiv preprint arXiv:1505.04597, 2015.
- [7] CHEN L-C, ZHU Y, PAPANDREOU G, et al. Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation[J]. arXiv preprint arXiv:1802.02611, 2018.
- [8] 秦国梁, 林尚扬, 齐秀滨, 等. 激光焊接过程实时监测技术的研究现状及其发展 [J]. 焊接, 2002(10): 5–8.
- [9] STAVRIDIS J, PAPACHARALAMPOPOULOS A, STAVROPOULOS P. Quality assessment in laser welding: a critical review[J]. The International Journal of Advanced Manufacturing Technology, 2018, 94(5): 1825–1847.
- [10] 汤信, 顾俊, 刘钊鹏, 等. 激光焊接过程质量评价研究综述 [J]. APPLIED LASER, 2019, 39(6): 1045–154.
- [11] SVENUNGSSON J, CHOQUET I, KAPLAN A F. Laser welding process—a review of keyhole welding modelling[J]. Physics procedia, 2015, 78: 182–191.
- [12] BAUTZE T, MOSER R, STREBEL M, et al. Use of inline coherent imaging for laser welding processes: Process control and beyond[C] // Lasers in Manufacturing Conference. 2015: 1–9.
- [13] 高世一, 高世一, 吴瑞珉, 等. 激光焊接过程监测及焊缝质量检测技术研究现状 [J]. 世界钢铁, 2010(003): 51–54.
- [14] CHEN Z, GAO X. Detection of weld pool width using infrared imaging during high-power fiber laser welding of type 304 austenitic stainless steel[J]. The International Journal of Advanced Manufacturing Technology, 2014, 74(9): 1247–1254.
- [15] 张兵宪, 张敏, 张云龙, 等. 工艺参数对 304 不锈钢薄板激光焊接接头组织及力学性能的影响 [J]. 热加工工艺, 2021, 50(21): 19–24.
- [16] 温鹏, 郭瑞峰, 王秀义, 等. 不锈钢车体搭接接头激光非熔透焊接工艺及其拉剪性能 [J]. 中国机械工程, 2017, 28(11): 1355.
- [17] BOLEY M, FETZER F, WEBER R, et al. Statistical evaluation method to determine the laser welding depth by optical coherence tomography[J]. Optics and Lasers in Engineering, 2019, 119: 56–64.
- [18] MITTELSTÄDT C, MATTULAT T, SEEFELD T, et al. Novel approach for weld depth determination using optical coherence tomography measurement in laser deep penetration welding of aluminum and steel[J]. Journal of Laser Applications, 2019, 31(2).
- [19] 谢冠明, 王三宏, 张跃强, 等. 基于光学相干层析的激光焊接熔深监测方法 [J]. Acta Optica Sinica, 2023, 43(11): 1114002–1114002.
- [20] XIE G, WANG S, ZHANG Y, et al. An Efficient Method for Laser Welding Depth Determination

- nation Using Optical Coherence Tomography[J]. *Sensors*, 2023, 23(11): 5223.
- [21] KOGEL-HÖLLINGER J, MITTELSTÄDT C, HUMMEL M, et al. Keyhole morphology monitoring in laser welding using optical coherence tomography[J]. *Chinese Optics Letters*, 2025, 23(3): 031201.
- [22] LIU Y, WANG J, LIU X, et al. Self-supervised PSF-informed deep learning enables real-time deconvolution for optical coherence tomography[J]. *Advanced Photonics Nexus*, 2025, 4(4): 046001.
- [23] 严毅, 邓超, 李琳, 等. 深度学习背景下的图像语义分割方法综述 [J]. *中国图象图形学报*, 2023, 28(11): 3342–3362.
- [24] BADRINARAYANAN V, KENDALL A, CIPOLLA R. Segnet: A deep convolutional encoder-decoder architecture for image segmentation[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2017, 39(12): 2481–2495.
- [25] YU F, KOLTUN V. Multi-scale context aggregation by dilated convolutions[J]. *arXiv preprint arXiv:1511.07122*, 2015.
- [26] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. Semantic Image Segmentation with Deep Convolutional Nets and Fully Connected CRFs[J]. *arXiv preprint arXiv:1412.7062*, 2014.
- [27] CHEN L-C, PAPANDREOU G, KOKKINOS I, et al. DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs[J]. *arXiv preprint arXiv:1606.00915*, 2016.
- [28] CHEN L-C, PAPANDREOU G, SCHROFF F, et al. Rethinking Atrous Convolution for Semantic Image Segmentation[J]. *arXiv preprint arXiv:1706.05587*, 2017.
- [29] WANG X, ZHAO J, XU Y, et al. SME-DeepLabV3+: An improved DeepLabV3+ for steel surface defect semantic segmentation[J]. *PLOS ONE*, 2025, 20(8): e0329628.
- [30] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C] // *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2017: 2881–2890.
- [31] WANG J, SUN K, CHENG T, et al. Deep high-resolution representation learning for visual recognition[J]. *IEEE transactions on pattern analysis and machine intelligence*, 2020, 43(10): 3349–3364.
- [32] HU J, SHEN L, ALBANIE S, et al. Squeeze-and-Excitation Networks[J]. *arXiv preprint arXiv:1709.01507*, 2019.
- [33] WOO S, PARK J, LEE J-Y, et al. Cbam: Convolutional block attention module[C] // *Proceedings of the European conference on computer vision (ECCV)*. 2018: 3–19.
- [34] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C] // *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018: 7794–7803.
- [35] FU J, LIU J, TIAN H, et al. Dual Attention Network for Scene Segmentation[J]. *arXiv preprint arXiv:1809.02983*, 2019.
- [36] HUANG Z, WANG X, WEI Y, et al. CCNet: Criss-Cross Attention for Semantic Segmentation[J]. *arXiv preprint arXiv:1811.11721*, 2020.
- [37] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient Channel Attention for Deep Convolutional Neural Networks[J]. *arXiv preprint arXiv:1910.03151*, 2020.
- [38] HOU Q, ZHOU D, FENG J. Coordinate Attention for Efficient Mobile Network Design[J]. *arXiv preprint arXiv:2103.02907*, 2021.
- [39] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[J]. *arXiv preprint arXiv:2010.11929*, 2020.

-
- [40] LIU Z, LIN Y, CAO Y, et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows[J]. arXiv preprint arXiv:2103.14030, 2021.
 - [41] ZHENG S, LU J, ZHAO H, et al. Rethinking Semantic Segmentation from a Sequence-to-Sequence Perspective with Transformers[J]. arXiv preprint arXiv:2012.15840, 2021.
 - [42] XIE E, WANG W, YU Z, et al. SegFormer: Simple and Efficient Design for Semantic Segmentation with Transformers[J]. arXiv preprint arXiv:2105.15203, 2021.
 - [43] CHENG B, MISRA I, SCHWING A G, et al. Masked-attention Mask Transformer for Universal Image Segmentation[J]. arXiv preprint arXiv:2112.01527, 2022.
 - [44] CHEN J, LU Y, YU Q, et al. TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation[J]. arXiv preprint arXiv:2102.04306, 2021.
 - [45] YU C, GAO C, WANG J, et al. Bisenet v2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International journal of computer vision, 2021, 129(11): 3051–3068.
 - [46] ZHAO H, QI X, SHEN X, et al. Icnnet for real-time semantic segmentation on high-resolution images[C] // Proceedings of the European conference on computer vision (ECCV). 2018: 405–420.
 - [47] YU C, XIAO B, GAO C, et al. Lite-hrnet: A lightweight high-resolution network[C] // Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 10440–10450.
 - [48] 王卓, 瞿绍军. 深度学习实时语义分割研究进展和挑战 [J]. 中国图象图形学报, 2024, 29(5): 1188–1220.
 - [49] 罗东亮, 蔡雨萱, 杨子豪, 等. 工业缺陷检测深度学习方法综述 [J]. 中国科学: 信息科学, 2022, 52(6): 1002–1039.
 - [50] 赵朗月, 吴一全. 基于机器视觉的表面缺陷检测方法研究进展 [J]. 仪器仪表学报, 2022, 43(1): 198–219.
 - [51] MA D, JIANG P, SHU L, et al. DBN-based online identification of porosity regions during laser welding of aluminum alloys using coherent optical diagnosis[J]. Optics & Laser Technology, 2023, 165: 109597.
 - [52] ZHANG K, KANG J U. Real-time 4D signal processing and visualization using graphics processing unit on a regular nonlinear-k Fourier-domain OCT system[J]. Optics Express, 2010, 18(11): 11772–11784.
 - [53] RASAKANTHAN J, SUGDEN K, TOMLINS P H. Processing and rendering of Fourier domain optical coherence tomography images at a line rate over 524 kHz using a graphics processing unit[J]. Journal of Biomedical Optics, 2011, 16(2): 020505.
 - [54] LYU J, REN L, LIU Q-Y, et al. Swept-source endoscopic optical coherence tomography real-time imaging system based on GPU acceleration for axial megahertz high-speed scanning[J]. European Review for Medical and Pharmacological Sciences, 2022, 26(20): 7349–7358.
 - [55] 周金浩. 基于 GPU 的 SS-OCT 三维图像的加速重建算法研究与实现 [D]. 杭州: 杭州电子科技大学, 2024.
 - [56] CHEN Y-C, CHEN Y-S, LU C-Y, et al. High performance low-cost OCT system powered by NVIDIA Jetson Orin Nano[C] // Optica Translational Biophotonics Congress. 2025: TW1F.4.
 - [57] 赵金汉. 基于 OCT 的激光焊接过程匙孔稳定性实时定量评估技术 [D]. 成都: 电子科技大学, 2025.
 - [58] ZHU L, WANG X, KE Z, et al. BiFormer: Vision Transformer with Bi-Level Routing Atten-

- tion[J]. arXiv preprint arXiv:2303.08810, 2023.
- [59] HUANG D, SWANSON E A, LIN C P, et al. Optical coherence tomography[J]. *Science*, 1991, 254(5035): 1178–1181.
- [60] MULLER M S, WEBSTER P J, FRASER J M. Time-gated Fourier-domain optical coherence tomography[J]. *Optics letters*, 2007, 32(22): 3336–3338.
- [61] ALOM M Z, TAHA T M, YAKOPCIC C, et al. The History Began from AlexNet: A Comprehensive Survey on Deep Learning Approaches[J]. arXiv preprint arXiv:1803.01164, 2018.
- [62] HOWARD A, SANDLER M, CHU G, et al. Searching for mobilenetv3[C] // *Proceedings of the IEEE/CVF international conference on computer vision*. 2019: 1314–1324.
- [63] SONG S. The use of color elements in graphic design based on convolutional neural network model[J]. *Applied Mathematics and Nonlinear Sciences*, 2023, 9.
- [64] YANI M, IRAWAN S, SETIANINGSIH C. Application of Transfer Learning Using Convolutional Neural Network Method for Early Detection of Terry’s Nail[J]. *Journal of Physics: Conference Series*, 2019, 1201: 012052.
- [65] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[J]. arXiv preprint arXiv:1502.03167, 2015.
- [66] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[J]. arXiv preprint arXiv:1512.03385, 2015.
- [67] SHI W, CABALLERO J, HUSZÁR F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C] // *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016: 1874–1883.
- [68] VASWANI A, SHAZEER N, PARMAR N, et al. Attention Is All You Need[J]. arXiv preprint arXiv:1706.03762, 2017.
- [69] ZHOU Z, SIDDIQUEE M M R, TAJBAKHSH N, et al. UNet++: A Nested U-Net Architecture for Medical Image Segmentation[J]. arXiv preprint arXiv:1807.10165, 2018.
- [70] ZHANG Z, LIU Q, WANG Y. Road Extraction by Deep Residual U-Net[J]. arXiv preprint arXiv:1711.10684, 2018.
- [71] LIN T-Y, DOLLÁR P, GIRSHICK R, et al. Feature Pyramid Networks for Object Detection[J]. arXiv preprint arXiv:1612.03144, 2016.
- [72] CORDTS M, OMRAN M, RAMOS S, et al. The cityscapes dataset[C] // *CVPR Workshop on the Future of Datasets in Vision*. 2015, 2: 1.
- [73] ZHANG Y, COHEN J, OWENS J D. Fast Tridiagonal Solvers on the GPU[C] // *Proceedings of the 15th ACM SIGPLAN Symposium on Principles and Practice of Parallel Programming*. [S.l.]: ACM, 2010: 127–136.
- [74] cuFFT Library User’s Guide[K]. 2024.
- [75] CUDA C++ Programming Guide[K]. 2024.
- [76] PATEL S. Bacterial Colony Classification Using Atrous Convolution with Transfer Learning Authors[J]. *Annals of the Romanian Society for Cell Biology*, 2021: 1428–1441.
- [77] WU Z, SHEN C, van den HENGEL A. Wider or Deeper: Revisiting the ResNet Model for Visual Recognition[J]. arXiv preprint arXiv:1611.10080, 2016.

致 谢

研究生阶段的学习即将画上句号，回望这三年的科研旅程，我深知自己的成长离不开许多人的帮助与支持。

首先，我要衷心感谢我的导师万明明老师，感谢他在这三年中对我的悉心指导。在实验设计和论文写作方面，万老师给了我诸多宝贵的建议和帮助。导师严谨的治学态度和广博的学识一直是我不断进步的动力，他的谆谆教诲让我受益匪浅。同时，深圳大学良好的科研环境以及学院相关部门与领导对学生的关怀也让我十分受益。

感谢实验室的各位老师和同学们。特别感谢谢沛师兄，在整个研究过程中不仅帮助我明确了研究思路，还提供了许多宝贵的建议，使我能够更高效地开展实验工作。感谢徐腾桂、赖照华、杨昊师兄在科研上的指导和帮助。感谢黄敦鸿、安康等同学，在学术和生活上都给予了我无私的帮助和支持，你们的友谊和鼓励让我在困境中保持信心。

最后，最感激的还是我的家人，正是你们的支持让我无论在科研还是生活中都能够坚持到底。你们是我不断前行的坚实后盾，在未来的路上，我将继续以你们为动力，勇敢追求自己的理想。

再次感谢所有帮助过我的老师、同学以及家人朋友，感谢你们的一切付出！感谢参与论文盲审的各位专家和答辩委员会的各位评委！

攻读硕士学位期间的研究成果

[1] 谢智捷, 万明明, 田劲东, 田勇. 熔深检测方法、电子设备及存储介质 [P]. 中国: 202511789285.6, 2025-11-28. (发明专利, 已通过初步审查, 对应学位论文第 3、4 章)

[2] 谢智捷. 第十六届蓝桥杯全国软件和信息技术专业人才大赛全国总决赛程序设计研究生组二等奖, 工业和信息化部人才交流中心, 2025 年 6 月.